


USULAN PENELITIAN TUGAS AKHIR S1

**PEMODELAN LAWAN BERBASIS FORECASTING MULTI-LANGKAH
YANG TERPISAH DARI OPTIMISASI REWARD PADA ITERATED
PRISONER'S DILEMMA**

***MULTI-STEP FORECASTING-BASED OPPONENT MODELLING
DECOUPLED FROM REWARD OPTIMIZATION IN THE ITERATED
PRISONER'S DILEMMA***



Faqih Mahardika
21/482551/PA/21039

**PROGRAM STUDI ILMU KOMPUTER
DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA**


2026

SKRIPSI

**PEMODELAN LAWAN BERBASIS FORECASTING MULTI-LANGKAH
YANG TERPISAH DARI OPTIMISASI REWARD PADA ITERATED
PRISONER'S DILEMMA**

***MULTI-STEP FORECASTING-BASED OPPONENT MODELLING
DECOUPLED FROM REWARD OPTIMIZATION IN THE ITERATED
PRISONER'S DILEMMA***

Usulan Penelitian



Faqih Mahardika
21/482551/PA/21039

**PROGRAM STUDI ILMU KOMPUTER
JURUSAN ILMU KOMPUTER DAN ELEKTRONIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA**

2026

HALAMAN PENGESAHAN

USULAN PENELITIAN S1

PEMODELAN LAWAN BERBASIS FORECASTING MULTI-LANGKAH YANG TERPISAH DARI OPTIMISASI REWARD PADA ITERATED PRISONER'S DILEMMA

Telah dipersiapkan dan disusun oleh

Faqih Mahardika
21/482551/PA/21039

Telah dipertahankan di depan Tim Penguji
pada tanggal 8 Mei 2026

Susunan Tim Penguji

Dr. Sri Mulyana, M.Kom.
Pembimbing

Bob, M.Sc.
Ketua Penguji

Eve, Ph.D.
Anggota Penguji

PERNYATAAN

Dengan ini saya menyatakan bahwa dalam Skripsi ini tidak terdapat karya yang pernah diajukan untuk memperoleh gelar kesarjanaan di suatu Perguruan Tinggi, dan sepanjang pengetahuan saya juga tidak terdapat karya atau pendapat yang ditulis atau diterbitkan oleh orang lain, kecuali yang secara tertulis diacu dalam naskah ini dan disebutkan dalam daftar pustaka.

Yogyakarta, 8 Mei 2026

Faqih Mahardika

DAFTAR ISI

HALAMAN SAMPUL	i
Halaman Judul	ii
HALAMAN PENGESAHAN	iii
Halaman Pernyataan	iv
DAFTAR ISI	v
DAFTAR TABEL	viii
DAFTAR GAMBAR	ix
I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Batasan Penelitian	2
1.4 Tujuan Penelitian	3
1.5 Manfaat Penelitian	3
1.6 Sistematika Penelitian	4
II TINJAUAN PUSTAKA	5
2.0.1 Asumsi Perilaku Lawan dalam pemodelan lawan untuk <i>Repeated Games</i>	5
2.0.2 Pendekatan metodologis dalam pemodelan lawan untuk <i>Repeated Games</i>	7
2.0.3 Bagaimana efektivitas strategi pemodelan lawan dievaluasi dalam <i>Repeated Games</i> ?	9
III LANDASAN TEORI	13
3.1 Dilema Sosial	13
3.2 Game Theory	13
3.3 Prisoner's Dilemma	14
3.4 Iterated Prisoner's Dilemma	14

3.4.1	Finite Horizon	14
3.4.2	Definisi Riwayat Interaksi pada mekanisme online	15
3.4.3	Informasi tidak lengkap dan Pembentukan kepercayaan	16
3.5	Pemodelan Lawan	16
3.6	Long Short-Term Memory (LSTM)	17
3.6.1	Forget Gate	17
3.6.2	Input Gate	17
3.6.3	Candidate Cell State	18
3.6.4	Cell State (Memori Jangka Panjang)	18
3.6.5	Output Gate	18
3.6.6	Hidden State Update	19
3.7	Prediksi Multi-Langkah	19
3.7.1	Peramalan Rekursif dan Simulasi Monte Carlo (Horizon Tetap)	19
3.7.2	Dari Akurasi Prediksi ke Kinerja Strategis	20
3.7.3	Pemisahan Pemodelan Lawan	23
3.7.4	professor forcing	24
3.7.5	Fungsi Objektif Negative Log-Likelihood	25
3.7.6	Rank Order Centroid (ROC)	26
IV	ANALISIS DAN PERANCANGAN	28
4.1	Deskripsi Umum	28
4.2	Formulasi Masalah	29
4.3	Spesifikasi Lingkungan	29
4.3.1	Setup Permainan	30
4.4	Desain Populasi Strategi Lawan	30
4.4.1	Tujuan Eksperimental dari Heterogenitas Populasi	31
4.4.2	Proporsi dan Skema Sampling	31
4.4.3	Implikasi terhadap Evaluasi Multi-Step Forecasting	32
4.4.4	Kategorisasi Perilaku Strategi	32
4.5	Prosedur dan Simulasi Generasi Data	32
4.5.1	Konfigurasi Episode	32
4.5.2	Mekanisme Trembling Hand	33
4.5.3	Struktur Penyimpanan Data	33
4.5.4	Implikasi terhadap Multi-Step Forecasting	34
4.6	Representasi dan Persiapan Dataset	34

4.6.1	Representasi Dasar Aksi	34
4.6.2	Augmentasi Simetri Peran	35
4.6.3	Pembentukan Sampel Prediksi	35
4.6.4	Pengacakan dan Pembagian Data	35
4.6.5	Implikasi terhadap Evaluasi Model	36
4.7	Perancangan Model Prediksi Lawan	36
4.7.1	Model Satu Langkah	37
4.7.2	Model Multi Langkah	37
4.7.3	Perbedaan Konseptual Kedua Model	38
4.7.4	Evaluasi Generalisasi	38
4.8	Protokol Pelatihan	38
4.8.1	Pelatihan Satu Langkah	38
4.8.2	Pelatihan Multi Langkah	39
4.9	Protokol Evaluasi	41
4.9.1	Evaluasi Terpisah (Decoupled)	41
4.9.2	Evaluasi Terpasang (Coupled)	42
4.9.3	Validasi dan Pengujian	42
4.10	Analisis Eksperimen	43
4.10.1	Akumulasi Error Multi-Langkah	43
4.10.2	Sensitivitas terhadap Perubahan Fase Strategi	44
4.10.3	Strategi Deterministik vs Adaptif	44
4.10.4	Pelaporan Hasil	44
V	JADWAL PENELITIAN	46
5.1	Jadwal Penelitian	46
5.1.1	Tahapan Penelitian	46
5.1.2	Rencana Waktu Pelaksanaan	49
5.1.3	Dependensi dan Risiko	50
VI	KESIMPULAN DAN SARAN	52
	DAFTAR PUSTAKA	53
	LAMPIRAN	56

DAFTAR TABEL

2.1	Asumsi perilaku lawan berdasarkan dependensi perilaku yang dapat diamati.	6
2.2	Lingkungan evaluasi dan metrik dalam penelitian	10
2.3	Ringkasan Penelitian Terkait	11
3.1	Payoff Matrix Prisoner's Dilemma	14
5.1	Rencana Jadwal Penelitian (2 Bulan / 8 Minggu)	50

DAFTAR GAMBAR

3.1	Diagram metodologi.	17
4.1	Diagram metodologi.	28

Pendekatan *opponent modelling* dalam permainan berulang umumnya diformulasikan sebagai prediksi satu-langkah terhadap aksi lawan, meskipun interaksi strategis berlangsung dalam horizon yang panjang dan bersifat sekuensial. Kondisi ini berpotensi menimbulkan ketidaksesuaian antara objektif pembelajaran model lawan dan kebutuhan perencanaan multi-langkah agen.

Penelitian ini mengkaji peran horizon prediksi dalam konteks *Iterated Prisoner's Dilemma* dengan mengimplementasikan modul pemodelan lawan berbasis *k-step forecasting* yang dilatih menggunakan kesalahan prediksi distribusi aksi teramati. Analisis difokuskan pada akurasi prediksi multi-langkah, dinamika propagasi kesalahan, serta implikasinya terhadap interaksi strategis jangka pendek.

Hasil eksperimen menunjukkan bahwa perluasan horizon prediksi dapat memberikan representasi yang lebih kaya terhadap pola strategi lawan yang bergantung pada trajectory interaksi, meskipun disertai trade-off dalam stabilitas dan kompleksitas pembelajaran. Temuan ini menyoroti pentingnya mempertimbangkan keselarasan antara objektif prediksi dan horizon perencanaan dalam perancangan sistem *opponent modelling* untuk permainan berulang.

Opponent modelling in repeated games is commonly formulated as a one-step prediction problem, despite the fact that strategic interactions unfold over long and sequential horizons. This formulation may introduce a mismatch between the learning objective of the opponent model and the multi-step planning requirements of the agent.

This study investigates the role of prediction horizon in the context of the Iterated Prisoner’s Dilemma by implementing a k -step forecasting module trained using prediction loss over observed action distributions. The analysis focuses on multi-step prediction accuracy, error propagation across steps, and its implications for short-term strategic interaction.

Experimental results indicate that extending the prediction horizon can provide a more informative representation of opponent strategies that depend on interaction trajectories, although it introduces trade-offs in terms of learning stability and model complexity. These findings highlight the importance of aligning prediction objectives with planning horizons in the design of opponent modelling frameworks for repeated strategic settings.

BAB I

PENDAHULUAN

1.1 Latar Belakang

Interaksi strategis berulang merupakan permasalahan fundamental dalam lingkungan sosial ataupun *multi-agent reinforcement learning* (MARL) Hernandez-Leal et al. 2019. Dalam lingkungan multi-agen, setiap agen tidak hanya beradaptasi terhadap lingkungan, tetapi juga terhadap agen lain yang turut belajar. Kondisi ini menjadikan dinamika pembelajaran bersifat non-stasioner dan sangat bergantung pada pola interaksi historis.

Iterated Prisoner's Dilemma (IPD) Axelrod dan Hamilton 1981 merupakan kerangka klasik untuk menganalisis dinamika tersebut. Dalam IPD, strategi tidak hanya ditentukan oleh aksi pada satu langkah, tetapi oleh pola respons yang berkembang sepanjang beberapa putaran. Banyak strategi deterministik maupun adaptif—seperti *Tit-for-Tat* dan variasinya—memperlihatkan struktur perilaku yang baru terlihat dalam rentang beberapa langkah interaksi.

Dalam literatur *opponent modelling*, pendekatan yang umum digunakan adalah prediksi satu langkah ke depan (*one-step prediction*) Nashed dan Zilberstein 2022. Model dilatih untuk meminimalkan kesalahan prediksi terhadap aksi lawan pada langkah berikutnya. Meskipun pendekatan ini konsisten dengan formulasi supervised learning standar, terdapat potensi ketidaksesuaian antara objektif pelatihan satu-langkah dan kebutuhan pengambilan keputusan dalam permainan berulang.

Dalam repeated games, keputusan agen pada waktu t tidak hanya bergantung pada distribusi aksi lawan pada waktu $t + 1$, tetapi juga pada konsekuensi strategis dalam beberapa langkah berikutnya. Strategi tertentu mungkin tidak optimal secara satu-langkah, namun menguntungkan secara multi-langkah. Dengan demikian, akurasi prediksi satu-langkah tidak selalu berbanding lurus dengan kualitas perencanaan strategis.

Selain itu, penggunaan prediksi secara recursive untuk menghasilkan trajectory multi-langkah berpotensi menimbulkan propagasi kesalahan (*error propagation*). Kesalahan kecil pada prediksi awal dapat terakumulasi dan mengurangi kualitas estimasi pada horizon yang lebih panjang. Hal ini menimbulkan pertanyaan metodologis mengenai bagaimana horizon prediksi (k) sebaiknya dipilih dan bagaima-

mana kualitas prediksi pada berbagai horizon memengaruhi kinerja strategis agen.

Berdasarkan kondisi tersebut, terdapat kebutuhan untuk secara sistematis menganalisis hubungan antara horizon prediksi dan kualitas pengambilan keputusan dalam IPD@. Secara khusus, penting untuk mengevaluasi apakah prediksi multi-langkah jangka pendek (k -step forecasting) memberikan representasi strategi lawan yang lebih selaras dengan kebutuhan perencanaan dibandingkan prediksi satu-langkah.

Dalam penelitian ini, pemisahan modul pemodelan lawan dari optimisasi reward diposisikan sebagai keputusan arsitektural untuk mengisolasi efek horizon forecasting terhadap kualitas prediksi dan dampaknya terhadap performa strategis. Dengan pemisahan ini, analisis dapat difokuskan pada hubungan antara akurasi prediksi multi-langkah, propagasi kesalahan, dan perolehan payoff dalam permainan berulang.

1.2 Rumusan Masalah

Dalam permainan berulang seperti *Iterated Prisoner's Dilemma*, interaksi antar-agen secara konseptual dipandang memiliki horizon yang panjang dan keputusan bersifat saling bergantung antar-langkah. Namun, dalam praktik *opponent modelling*, prediksi perilaku lawan sering diformulasikan sebagai prediksi satu-langkah (*one-step prediction*) yang dioptimalkan berdasarkan kesalahan prediksi jangka pendek.

Perbedaan antara horizon interaksi yang bersifat sekuensial dan objektif pembelajaran yang miopik tersebut menunjukkan adanya potensi ketidaksesuaian antara tujuan perencanaan strategis dan mekanisme pembelajaran model lawan. Kondisi ini dapat membatasi representasi pola strategi yang bergantung pada beberapa langkah interaksi serta memengaruhi dinamika adaptasi yang terbentuk selama permainan berlangsung.

1.3 Batasan Penelitian

Agar ruang lingkup penelitian tetap terfokus dan implementasi eksperimental terkendali, penelitian ini dibatasi pada:

1. Lingkungan *Iterated Prisoner's Dilemma* (IPD) dengan struktur payoff standar dan interaksi berulang dalam horizon tetap.
2. Lawan adaptif yang algoritmanya tidak diketahui oleh agen, namun dibatasi pada kelas pembelajaran daring seperti *Hedge*, *Online Mirror Descent*.

3. Analisis difokuskan pada prediksi trajectory aksi lawan dalam horizon terbatas (k -step forecasting), tanpa membahas konvergensi jangka panjang atau sifat asimtotik strategi.
4. Penelitian tidak melakukan inferensi terhadap struktur algoritma internal lawan, melainkan memodelkan distribusi aksi berdasarkan observasi historis.
5. Evaluasi difokuskan pada hubungan antara akurasi prediksi multi-langkah, propagasi kesalahan, dan perolehan payoff strategis, tanpa merancang algoritma eksplorasi baru.

1.4 Tujuan Penelitian

Penelitian ini bertujuan untuk:

1. Menganalisis kesesuaian antara objektif prediksi satu-langkah (*one-step prediction*) dan kebutuhan perencanaan strategis multi-langkah dalam permainan berulang seperti IPD@.
2. Mengembangkan dan mengimplementasikan mekanisme prediksi trajectory aksi lawan dalam horizon terbatas (k -step forecasting).
3. Mengevaluasi pengaruh panjang horizon prediksi (k) terhadap akurasi prediksi, propagasi kesalahan, dan perolehan payoff strategis.
4. Membandingkan pendekatan recursive forecasting dan direct multi-step forecasting dalam konteks stabilitas prediksi dan dampaknya terhadap performa agen.

1.5 Manfaat Penelitian

Manfaat dan kontribusi yang diharapkan dari penelitian ini adalah sebagai berikut:

1. Memberikan analisis konseptual dan empiris mengenai potensi ketidaksesuaian antara objektif prediksi satu-langkah dan kebutuhan perencanaan strategis dalam permainan berulang.

2. Menyediakan evaluasi sistematis mengenai pengaruh horizon prediksi (k) terhadap kualitas trajectory forecasting dan dampaknya terhadap strategic payoff.
3. Memberikan perbandingan empiris antara pendekatan recursive dan direct multi-step forecasting dalam konteks interaksi strategis berulang.
4. Menyediakan dasar eksperimental untuk memahami hubungan antara prediction accuracy dan kualitas pengambilan keputusan dalam repeated games.

1.6 Sistematika Penelitian

1. Bab 1: Pendahuluan: Latar belakang, rumusan masalah, batasan, tujuan, manfaat, dan sistematika penelitian.
2. Bab 2: Tinjauan Pustaka: Kajian literatur terkait opponent modelling, IPD, dan pendekatan pembelajaran daring.
3. Bab 3: Kerangka Teoritis: Formulasi masalah, definisi formal belief dan forecasting loss, serta arsitektur umum.
4. Bab 4: Metode Penelitian: Desain eksperimen, algoritma, dan prosedur evaluasi.
5. Bab 5: Jadwal Penelitian: gant chart, depedensi, dan risiko.
6. Bab 6: Kesimpulan dan Saran.

BAB II

TINJAUAN PUSTAKA

Bagian ini mensintesis temuan utama dari studi yang ditinjau dengan tujuan mengidentifikasi pola asumsi perilaku lawan serta implikasinya terhadap desain metodologis pemodelan lawan dalam *repeated games*. Sintesis difokuskan pada dimensi perilaku yang dapat diamati dari riwayat interaksi, alih-alih pada asumsi internal seperti struktur optimisasi reward atau arsitektur pembelajaran yang digunakan.

Pendekatan ini penting karena dalam banyak karya terdahulu, pemodelan perilaku lawan sering kali tidak dipisahkan secara konseptual dari proses optimisasi kebijakan agen. Akibatnya, representasi perilaku lawan terenkapsulasi di dalam parameter kebijakan atau fungsi nilai, sehingga sulit untuk mengevaluasi kualitas prediksi perilaku secara independen dari reward yang dicapai. Untuk mengidentifikasi celah tersebut secara sistematis, tinjauan ini mengabstraksikan asumsi perilaku lawan pada tingkat eksternal yang dapat diinferensi dari *interaction traces*.

2.0.1 Asumsi Perilaku Lawan dalam pemodelan lawan untuk *Repeated Games*

Untuk mengoperasionalkan asumsi perilaku lawan secara konsisten pada pengaturan permainan yang beragam, tinjauan ini mengkarakterisasi perilaku berdasarkan dependensi yang dapat diamati dari riwayat interaksi. Secara khusus, aksi lawan dianalisis berdasarkan apakah ia:

1. Bervariasi lintas kondisi lingkungan dalam permainan yang sama,
2. Dimediasi oleh dinamika tingkat populasi,
3. Merespons secara langsung aksi agen,
4. Menunjukkan divergensi aksi pada riwayat interaksi terkini yang ekuivalen.

Kriteria-kriteria ini sepenuhnya berbasis observasi eksternal dan tidak mengasumsikan akses terhadap model internal, mekanisme pembelajaran, maupun fungsi objektif lawan. Dengan demikian, kategorisasi ini bukan taksonomi formal algoritma, melainkan kerangka analitis untuk memungkinkan perbandingan lintas paradigma pembelajaran.

Dalam studi yang tidak menyatakan asumsi perilaku secara eksplisit, klasifikasi diturunkan secara konservatif dari desain eksperimen dan dinamika interaksi yang dilaporkan. Hasil kategorisasi dirangkum pada Tabel 2.1.

Tabel 2.1 Asumsi perilaku lawan berdasarkan dependensi perilaku yang dapat diamati.

Referensi	Lingkungan	Populasi	Agen	divergensi
Jin et al. 2025	—	—	✓	—
Gómez et al. 2025	—	✓	—	—
Elhamer et al. 2020	—	✓	✓	—
Qiao et al. 2024	—	—	✓	✓
Lv et al. 2023	—	—	✓	✓
Li et al. 2025	—	—	✓	✓
Freire et al. 2023	—	—	✓	✓
Hu et al. 2023	—	—	✓	✓
Wang et al. 2019	—	—	✓	✓
De Weerd et al. 2022	—	—	✓	✓
Perera et al. 2025	—	✓	✓	✓
Zhu et al. 2025	✓	✓	—	✓
Di et al. 2023	✓	✓	✓	✓

Catatan:

Lingkungan — perilaku bervariasi lintas lingkungan dalam permainan yang sama;

Populasi — perilaku dimediasi oleh interaksi tingkat populasi;

Agen — perilaku merespons secara langsung aksi agen;

Divergen — divergensi aksi terjadi pada riwayat interaksi terkini yang ekuivalen.

Tanda centang menunjukkan adanya dependensi.

Sejumlah pola konsisten muncul dari Tabel 2.1. Mayoritas studi terkini mengasumsikan lawan yang responsif terhadap aksi agen serta menunjukkan divergensi perilaku pada riwayat interaksi yang setara. Hal ini mencerminkan pergeseran fokus riset dari optimisasi terhadap strategi lawan yang tetap menuju interaksi dengan lawan yang adaptif dan dinamis.

2.0.2 Pendekatan metodologis dalam pemodelan lawan untuk *Repeated Games*

Distribusi asumsi perilaku lawan pada Tabel 2.1 mencerminkan pergeseran metodologis yang lebih luas dalam riset pemodelan lawan, dari pengaturan dengan asumsi lawan yang tetap dan terkontrol menuju lawan yang adaptif, heterogen, dan berperilaku tidak stasioner. Namun, karakterisasi berbasis asumsi perilaku semata belum menjelaskan bagaimana kompleksitas tersebut dihadapi secara komputasional di sisi agen. Untuk itu, Tabel ?? mereorganisasi studi-studi terdahulu berdasarkan paradigma pemodelan dominan dan mekanisme pembelajaran yang digunakan oleh agen.

Pendekatan-pendekatan tersebut dapat dibedakan lebih lanjut berdasarkan apakah adaptasi terhadap lawan ditangani secara eksplisit atau implisit. Paradigma pemodelan lawan yang eksplisit—seperti *gradient-based opponent shaping* Qiao et al. 2024; Hu et al. 2023; Wang et al. 2019, *recursive belief reasoning* Freire et al. 2023; De Weerd et al. 2022, serta *system identification* Li et al. 2025—secara langsung membangun representasi internal perilaku lawan untuk memprediksi atau memengaruhi respons lawan di masa depan. Sebaliknya, pendekatan implisit, termasuk *reactive reinforcement learning* Lv et al. 2023, *population-based training* Perera et al. 2025, dinamika evolusioner Zhu et al. 2025; Di et al. 2023; Elhamer et al. 2020, dan *bandit-based learning-in-games* Gómez et al. 2025, beradaptasi terhadap lawan tanpa mempertahankan model perilaku lawan yang terpisah.

Meskipun pendekatan berbasis *reinforcement learning* dan *policy-gradient* mendominasi literatur terkini, paradigma tersebut umumnya mengintegrasikan pemodelan lawan ke dalam proses optimisasi kebijakan agen. Representasi dinamika lawan terenkapsulasi dalam parameter kebijakan atau fungsi nilai, sehingga sulit untuk dievaluasi secara terpisah. Konsekuensinya, kualitas prediksi perilaku lawan tidak dapat dianalisis secara independen dari performa reward agen, dan kemampuan untuk melakukan proyeksi eksplisit terhadap respons lawan pada beberapa langkah ke depan menjadi terbatas.

Meskipun asumsi perilaku lawan semakin kompleks, pendekatan metodologis yang digunakan sering kali tetap mengintegrasikan pemodelan lawan secara langsung ke dalam proses optimisasi reward. Dalam konfigurasi semacam ini, dinamika perilaku lawan tidak dipelajari sebagai proses prediktif yang berdiri sendiri, melainkan sebagai bagian dari parameter kebijakan agen. Konsekuensinya, kemampuan agen untuk mengantisipasi evolusi perilaku lawan dalam beberapa langkah ke depan tidak

selalu dianalisis secara eksplisit.

Kondisi ini menunjukkan adanya ruang konseptual untuk pendekatan yang memperlakukan perilaku lawan sebagai proses sekuensial yang dapat dipelajari secara terpisah dari optimisasi reward, serta dievaluasi berdasarkan kualitas prediksi terhadap lintasan aksi di masa depan, bukan semata-mata berdasarkan payoff agregat jangka panjang. Pendekatan semacam ini secara alami menekankan pentingnya *forecasting* multi-langkah dalam menghadapi dinamika interaksi berulang, terutama ketika keputusan pada fase awal interaksi memiliki implikasi strategis terhadap lintasan berikutnya.

Dalam konteks ini, pendekatan berbasis model sekuensial memori seperti *Long Short-Term Memory* (LSTM) menawarkan alternatif metodologis yang berbeda. LSTM dapat dipandang sebagai pendekatan yang memodelkan perilaku lawan sebagai proses dinamis berbasis riwayat interaksi. Aksi agen diperlakukan sebagai sinyal eksogen, sementara urutan aksi lawan dipelajari sebagai keluaran yang bergantung pada dependensi temporal jangka pendek maupun jangka panjang.

Berbeda dengan paradigma yang menggabungkan pemodelan lawan ke dalam optimisasi kebijakan, pendekatan ini secara eksplisit melakukan *decoupling* antara model prediktif perilaku lawan dan mekanisme pengambilan keputusan agen. Model LSTM dilatih untuk meminimalkan kesalahan prediksi perilaku lawan tanpa melibatkan sinyal reward agen. Dengan demikian, kualitas model lawan dapat dievaluasi secara independen menggunakan metrik prediksi sekuensial, sebelum diintegrasikan ke dalam proses pengambilan keputusan.

Selain itu, struktur rekuren pada LSTM memungkinkan *forecast* multi-langkah (*multi-step forecasting*) terhadap aksi lawan memanfaatkan skema prediksi rekursif atau *rolling horizon*. Kemampuan ini relevan dalam *repeated games*, di mana keputusan optimal agen sering kali bergantung pada ekspektasi terhadap respons lawan tidak hanya pada langkah berikutnya, tetapi juga pada beberapa langkah interaksi selanjutnya. Dengan menyediakan estimasi lintasan perilaku lawan pada horizon terbatas, agen dapat melakukan evaluasi strategi secara lebih prospektif dibandingkan pendekatan satu-langkah.

Karakteristik *decoupling* dan kemampuan *multi-step forecasting* tersebut menjadikan pendekatan berbasis LSTM metodologis berbeda dari pendekatan berbasis pembelajaran kebijakan terintegrasi. Secara khusus, pemisahan ini meningkatkan transparansi analitis, fleksibilitas integrasi dengan berbagai skema pengambilan keputusan (misalnya *best response*, simulasi berbasis skenario, atau perencanaan horizon

terbatas), serta memungkinkan eksperimen terkontrol untuk menganalisis pengaruh kualitas prediksi lawan terhadap performa agen.

Literatur yang sepenuhnya memisahkan pembelajaran model lawan dari sinyal reward kebijakan masih relatif terbatas, khususnya dalam konteks *repeated games* dengan lawan adaptif dan tidak stasioner. Oleh karena itu, pendekatan ini tidak hanya berkontribusi secara implementatif, tetapi juga memperjelas posisi metodologis antara pemodelan prediktif perilaku lawan dan optimisasi strategi agen.

2.0.3 Bagaimana efektivitas strategi pemodelan lawan dievaluasi dalam *Repeated Games*?

Praktik evaluasi secara implisit mendefinisikan apa yang dianggap sebagai keberhasilan dalam interaksi multi-agent yang adaptif, baik dalam bentuk hasil kerja sama, ketahanan terhadap eksploitasi, stabilitas perilaku, maupun akurasi prediksi. Tabel 2.2 merangkum lingkungan evaluasi dan metrik yang digunakan dalam penelitian-penelitian terdahulu, dengan tujuan mengidentifikasi pola evaluasi yang berulang serta aspek-aspek yang relatif terabaikan.

Sebagaimana terlihat pada Tabel 2.2, mayoritas studi mengevaluasi efektivitas pemodelan lawan melalui metrik kinerja agregat jangka panjang, seperti payoff rata-rata, tingkat kerja sama, stabilitas, serta konvergensi menuju equilibrium. Evaluasi semacam ini menilai keberhasilan berdasarkan hasil akhir interaksi, tanpa secara eksplisit mengkaji bagaimana kualitas prediksi perilaku lawan pada berbagai horizon mempengaruhi proses pengambilan keputusan strategis.

Selain itu, sebagian besar pendekatan yang melibatkan komponen prediktif melaporkan kinerja berdasarkan galat satu langkah (*one-step prediction error*). Meskipun metrik ini relevan untuk mengukur konsistensi lokal model terhadap data historis, ia tidak secara langsung mencerminkan kebutuhan perencanaan dalam *repeated games*. Dalam konteks permainan berulang seperti IPD, keputusan pada suatu langkah mempengaruhi respons lawan pada langkah-langkah berikutnya, sehingga pengambilan keputusan bersifat intrinsik multi-langkah.

Ketergantungan pada objektif prediksi satu langkah berpotensi menimbulkan ketidaksesuaian antara objektif statistik dan objektif strategis. Model yang dioptimalkan untuk meminimalkan galat satu langkah belum tentu menghasilkan estimasi lintasan perilaku lawan yang stabil ketika digunakan untuk perencanaan lintas-horizon. Dalam skema *recursive forecasting*, kesalahan prediksi awal dapat terpropa-

Tabel 2.2 Lingkungan evaluasi dan metrik dalam penelitian

Ref.	Lingkungan Evaluasi	Metrik
Qiao et al. 2024	Self-play simetris	MSE selama pelatihan offline; akurasi memori laten
Zhu et al. 2025	Jaringan scale-free dengan strategi zero-determinant	Frekuensi kerja sama (C) dan eksploitasi (E)
Lv et al. 2023	Opponent adaptif (dirata-ratakan pada beberapa opponent)	Nilai reward
Gómez et al. 2025	Simulator teamwork-game khusus	Produktivitas tim agregat; konvergensi ke Nash equilibrium; kontribusi individu
Di et al. 2023	Simulator evolutionary game	Tingkat kerja sama; fraksi kooperator
Perera et al. 2025	Repeated matrix games dengan populasi sintetis	Payoff rata-rata; robustness; generalisasi
Li et al. 2025	Repeated zero-sum games	Galat prediksi; payoff kumulatif
Freire et al. 2023	Repeated matrix games	Efektivitas; stabilitas; akurasi prediksi
Hu et al. 2023	Simulasi repeated matrix game	Payoff rata-rata; kecepatan konvergensi
Elhamer et al. 2020	Simulasi continuous-space	Tingkat kerja sama; stabilitas klaster
Wang et al. 2019	Lingkungan SPD 2D khusus	Reward rata-rata; kesejahteraan sosial
Jin et al. 2025	Benchmark MARL	Return ternormalisasi; konvergensi
De Weerd et al. 2022	Simulasi Colored Trails	Skor agen; kesejahteraan sosial

Tabel 2.3 Ringkasan Penelitian Terkait

Ref	Nama Model	Temuan Utama
Qiao et al. 2024	Online Opponent Modeling (O2M)	O2M mampu beradaptasi lebih baik dan memperoleh rata-rata reward lebih tinggi dibandingkan baseline.
Zhu et al. 2025	Zero Determinant Strategy under Evolutionary Dynamic	Proporsi akhir kerja sama melebihi strategi Extort, menunjukkan keunggulan dinamika evolusioner.
Lv et al. 2023	Hierarchical Gifting DQN	Mendeteksi perubahan strategi lawan secara real-time dan dinamis menyesuaikan insentif kerja sama.
Gómez et al. 2025	Teamwork Game + MA-MAB	Mereproduksi pola mirip manusia (social loafing, compensation).
Di et al. 2023	Environment-Strategy Coupling Model	Kopling antara umpan balik lingkungan dan dinamika strategi secara signifikan meningkatkan stabilitas kerja sama kelompok.
Perera et al. 2025	Ensemble-Training Cooperative Agent	Robust dan memiliki generalisasi lebih baik namun biaya komputasi lebih tinggi dan potensi estimasi reward intrinsik sub-optimal.
Li et al. 2025	LSTM-Strategy	RNN mampu mengaproksimasi dinamika no-regret yang halus secara akurat serta memungkinkan eksploitasi yang menguntungkan pada tingkat non-stasioneritas rendah.
Freire et al. 2023	Internal Model	Konvergensi lebih cepat dan stabil dibanding TD-learning standar; performa menurun ketika perilaku lawan bergantung pada aksi agen sendiri (misalnya Tit-for-Tat).
Hu et al. 2023	Symmetric Learning Awareness (SLA)	Keseimbangan yang lebih stabil dan menghindari perilaku siklik pada metode gradien standar; pemodelan eksplisit meningkatkan konvergensi.
Elhamer et al. 2020	Extended Social Particle Swarm (SPS) Model	Ukuran populasi dan laju pembaruan informasi membentuk pola kerja sama dinamis dan beragam.
Wang et al. 2019	Deep Multiagent Reinforcement Learning (untuk SPD)	Mencapai kerja sama mutual; adaptif terhadap perubahan strategi lawan.
Jin et al. 2025	Suggestion Sharing (SS)	Meningkatkan kerja sama dibanding value sharing dan policy sharing.
De Weerd et al. 2022	Higher-order Theory of Mind (ToM k , $k \geq 2$)	ToM tingkat tinggi berpengaruh signifikan; <i>diminishing returns</i> setelah ToM-3.

gasi dan mempengaruhi estimasi payoff kumulatif secara non-linear. Namun demikian, literatur yang ada jarang menguji secara eksplisit bagaimana kualitas prediksi multi-langkah berhubungan dengan performa strategis agen.

Lebih lanjut, belum banyak studi yang secara sistematis membandingkan implikasi penggunaan prediksi satu langkah, *recursive multi-step forecasting*, dan *direct multi-step forecasting* terhadap payoff strategis. Analisis mengenai keberadaan horizon prediksi optimal (k^*) yang memberikan trade-off terbaik antara stabilitas prediksi dan manfaat strategis juga masih terbatas.

Berdasarkan sintesis tersebut, terdapat celah penelitian yang signifikan, yaitu belum adanya analisis sistematis mengenai ketidaksesuaian antara objektif prediksi satu langkah dan kebutuhan perencanaan strategis multi-langkah dalam *repeated games*. Secara khusus, hubungan antara akurasi prediksi lintas-horizon, propagasi kesalahan dalam skema rekursif, dan dampaknya terhadap payoff strategis belum dievaluasi secara terintegrasi dan terkontrol.

Penelitian ini berangkat dari celah tersebut dengan memfokuskan analisis pada evaluasi kinerja prediksi multi-langkah serta implikasinya terhadap pengambilan keputusan strategis dalam IPD, tanpa memosisikan arsitektur model sebagai kontribusi utama, melainkan sebagai instrumen untuk mengisolasi efek horizon forecasting.

BAB III

LANDASAN TEORI

3.1 Dilema Sosial

Dilema sosial merupakan situasi di mana keputusan rasional secara individual menghasilkan luaran yang tidak optimal secara kolektif (Axelrod dan Hamilton 1981). Secara formal, kondisi ini dapat dinyatakan sebagai:

$$\sum_{i=1}^n u_i(a_i, a_{-i}) < \sum_{i=1}^n u_i(a'_i, a'_{-i})$$

di mana n adalah jumlah pemain, u_i adalah fungsi utilitas pemain i , a_i adalah aksi rasional individu dan a'_i adalah profil aksi yang memaksimalkan kesejahteraan kolektif.

Formulasi ini menjelaskan adanya konflik antara rasionalitas individu dan optimalitas sosial. Namun, ekspresi agregat tersebut belum menyediakan struktur analitis yang cukup untuk memodelkan interaksi strategis antar agen secara eksplisit.

3.2 Game Theory

teori permainan memberikan kerangka formal yang memodelkan pemain, strategi, dan payoff secara terstruktur (Bonanno 2024), dalam bentuk normal didefinisikan sebagai:

$$G = (N, A, U)$$

dengan N himpunan pemain, $A = A_1 \times A_2$ himpunan profil strategi atau *Action space*, dan $U = (u_1, u_2)$ fungsi payoff atau *utility*.

Nash Equilibrium adalah profil strategi a^* yang memenuhi:

$$u_i(a_i^*, a_{-i}^*) \geq u_i(a_i, a_{-i}^*) \quad \forall a_i \in A_i$$

Menunjukkan pilihan aksi selain a_i^* tidak dapat memberikan keuntungan lebih besar dari strategi keseimbangan. Kerangka ini memungkinkan analisis rasionalitas strategis dalam interaksi statik. Namun, model bentuk normal bersifat satu tahap dan mengasumsikan struktur payoff tetap.

3.3 Prisoner's Dilemma

Prisoner's Dilemma merepresentasikan konflik rasionalitas individu dan kolektif secara eksplisit (Axelrod dan Hamilton 1981). Aksi yang dapat dipilih adalah *Cooperate* (C) atau *Defect* (D). Struktur payoff Prisoner's Dilemma diberikan oleh:

	C	D
C	(R, R)	(S, T)
D	(T, S)	(P, P)

Tabel 3.1 Payoff Matrix Prisoner's Dilemma

Dengan R (Reward) adalah payoff jika kedua pemain bekerja sama, T (Temptation) adalah payoff bagi pemain yang berkhianat sementara yang lain bekerja sama, S (Sucker's payoff) adalah payoff bagi pemain yang bekerja sama sementara yang lain berkhianat, dan P (Punishment) adalah payoff jika kedua pemain berkhianat. dengan ketidaksamaan:

$$T > R > P > S \quad \text{dan} \quad 2R > T + S.$$

Dalam permainan satu tahap, strategi dominan adalah defeksi (D), sehingga keseimbangan Nash berada pada (D, D) meskipun (C, C) lebih optimal secara kolektif. Namun, interaksi nyata jarang terjadi hanya satu kali.

3.4 Iterated Prisoner's Dilemma

Permainan PD diperluas menjadi bentuk berulang disebut Iterated Prisoner's Dilemma (IPD), permainan diulang selama T atau *Turn* tahap dengan payoff kumulatif atau terdiskonto. Dalam IPD, strategi dapat bergantung pada histori interaksi, memungkinkan untuk pembalasan dan kerja sama yang berkelanjutan. IPD relevan untuk mempelajari dinamika manusia seperti: pembentukan hubungan, konflik berkepanjangan, siklus saling membalas, dan pemulihan kepercayaan.

3.4.1 Finite Horizon

Pada formulasi finite horizon dengan panjang permainan tetap T , utilitas total pemain didefinisikan sebagai penjumlahan utilitas pada setiap ronde:

$$U_i = \sum_{t=1}^T u_i(a_i^t, a_{-i}^t) \quad (3.1)$$

Pada model ini, tidak digunakan faktor diskonto. Namun, secara teoretis, pendekatan ini cenderung menghasilkan strategi defeksi melalui mekanisme *backward induction* (Bonanno 2024).

3.4.2 Definisi Riwayat Interaksi pada mekanisme online

Dalam konteks iterated game dua pemain, riwayat hingga waktu t tidak hanya terdiri dari aksi satu pemain, tetapi pasangan aksi kedua pemain pada setiap putaran. Secara formal, riwayat didefinisikan sebagai:

$$h_t = ((a_i^1, a_{-i}^1), (a_i^2, a_{-i}^2), \dots, (a_i^t, a_{-i}^t))$$

dengan a_i^k menyatakan aksi pemain i pada waktu k , dan a_{-i}^k menyatakan aksi lawan pada waktu yang sama (Bonanno 2024).

Dalam pengaturan iteratif, riwayat tidak tersedia secara sekaligus, melainkan terbentuk secara *online*. Pada setiap putaran t , riwayat diperbarui secara inkremental sebagai:

$$h_t = (h_{t-1}, (a_i^t, a_{-i}^t))$$

dengan $h_0 = \emptyset$.

Formulasi ini menegaskan bahwa agen tidak memiliki akses terhadap trajectory interaksi di masa depan, dan hanya dapat menggunakan informasi yang telah terobservasi hingga waktu berjalan. Dengan kata lain, proses pengambilan keputusan berlangsung dalam kerangka kausal dan sekuensial (Bonanno 2024).

riwayat interaksi menyediakan rekaman lengkap atas realisasi aksi kedua pemain. *Namun*, riwayat hanya merepresentasikan keluaran observabel dari proses pengambilan keputusan lawan, bukan mekanisme generatif yang mendasarinya. Agen tidak memiliki akses langsung terhadap strategi internal, parameter keputusan, ataupun aturan adaptasi yang digunakan oleh lawan (Bonanno 2024).

Dengan demikian, meskipun seluruh pasangan aksi teramati secara bertahap, struktur strategi lawan tetap bersifat laten. Kondisi ini menyebabkan interaksi dalam IPD tidak memenuhi asumsi informasi lengkap sebagaimana pada analisis keseimbangan statik klasik (Bonanno 2024).

Oleh karena itu, permasalahan strategis dalam IPD dengan agen adaptif berada dalam kerangka permainan dengan informasi tidak lengkap, di mana agen harus melakukan inferensi terhadap strategi lawan secara bertahap seiring pertambahan riwayat (Bonanno 2024).

3.4.3 Informasi tidak lengkap dan Pembentukan kepercayaan

Dalam permainan dengan informasi tidak lengkap, ketidakpastian terhadap strategi lawan direpresentasikan melalui distribusi probabilitas atas kemungkinan tipe atau parameter strategi. Alih-alih mengasumsikan strategi tetap dan diketahui, agen memelihara suatu *belief state* yang diperbarui seiring bertambahnya histori interaksi.

Secara konseptual, belief state pada waktu t dapat dituliskan sebagai:

$$b_t = P(\theta \mid h_t)$$

dengan θ merepresentasikan representasi laten dari strategi lawan, dan h_t adalah histori interaksi hingga waktu t .

Formulasi ini menegaskan bahwa pengambilan keputusan dalam IPD adaptif bukan sekadar persoalan memilih aksi optimal terhadap strategi tetap, melainkan proses pembaruan belief secara sekuensial terhadap dinamika perilaku lawan. Dengan demikian, fokus analisis bergeser dari pencarian equilibrium statik menuju inferensi dinamis berbasis histori (Bonanno 2024).

3.5 Pemodelan Lawan

Pemodelan lawan atau *pemodelan lawan* memungkinkan untuk mempelajari perilaku ataupun strategi lawan (Shoham 2009).

Diberikan riwayat interaksi penuh:

$$h_t = ((a_i^1, a_{-i}^1), \dots, (a_i^t, a_{-i}^t)) \quad (3.2)$$

model parametrik f_θ mempelajari distribusi kondisional:


$$p_\theta(a_{t+1}^{-i} \mid h_t).$$

Pendekatan regresi linear sederhana mampu memodelkan hubungan statik, namun memiliki keterbatasan dalam menangkap dependensi temporal dan pola nonlinier (Hochreiter dan Schmidhuber 1997).

3.6 Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM) merupakan pengembangan dari Recurrent Neural Network (RNN) yang dirancang untuk menangkap dependensi jangka panjang melalui mekanisme memori eksplisit (Hochreiter dan Schmidhuber 1997). Dalam konteks *pemodelan lawan*, LSTM digunakan untuk membangun representasi laten terhadap strategi lawan berdasarkan histori interaksi.

Diberikan input x_t (observasi pada waktu t , misalnya aksi lawan), hidden state sebelumnya h_{t-1} (representasi laten sebelumnya), dan parameter bobot W , U , serta bias b , setiap komponen LSTM bekerja secara berurutan sebagai berikut.



Gambar 3.1 Diagram metodologi.

3.6.1 Forget Gate

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f) \quad (3.3)$$

3.6.2 Input Gate

Input $x_t \in \mathbb{R}^d$ merepresentasikan observasi saat ini, sedangkan $h_{t-1} \in \mathbb{R}^h$ adalah ringkasan historis interaksi sebelumnya. Namun, tidak semua informasi baru

relevan atau stabil untuk memperbarui belief terhadap strategi lawan. Oleh karena itu, input gate $i_t \in [0, 1]^h$ mengontrol seberapa besar setiap dimensi informasi baru akan diterima ke dalam memori, dengan $\sigma(\cdot)$ sebagai fungsi sigmoid dan W_i, U_i, b_i sebagai parameter yang dipelajari.

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i) \quad (3.4)$$

3.6.3 Candidate Cell State

Informasi mentah dari x_t tidak langsung disimpan karena dapat mengandung noise atau pola sementara yang belum representatif. Namun, model tetap membutuhkan representasi kandidat dari informasi baru tersebut. Oleh karena itu, $\tilde{c}_t \in [-1, 1]^h$ dibentuk melalui transformasi non-linear $\tanh(\cdot)$ sebagai kandidat memori baru, dengan parameter W_c, U_c, b_c .

$$\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c) \quad (3.5)$$

3.6.4 Cell State (Memori Jangka Panjang)

Cell state $c_t \in \mathbb{R}^h$ merupakan jalur utama propagasi informasi jangka panjang dalam LSTM yang berfungsi sebagai *latent belief representation* terhadap strategi lawan. Namun, memori ini harus mampu menjaga stabilitas sekaligus tetap adaptif terhadap informasi baru. Oleh karena itu, pembaruannya dirumuskan sebagai:

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \quad (3.6)$$

Operator $\odot$ menyatakan perkalian elemen-per-elemen. Komponen $f_t \odot c_{t-1}$ mempertahankan informasi lama yang masih relevan, sedangkan $i_t \odot \tilde{c}_t$ menambahkan informasi baru secara selektif. Struktur aditif ini penting karena menjaga stabilitas gradien dan memungkinkan pembelajaran dependensi jangka panjang.

3.6.5 Output Gate

Meskipun c_t menyimpan informasi lengkap, tidak seluruhnya relevan untuk prediksi saat ini. Namun, model perlu mengekstrak bagian informasi yang paling informatif untuk pengambilan keputusan. Oleh karena itu, output gate $o_t \in [0, 1]^h$

mengontrol seberapa besar informasi dari cell state akan diekspos ke hidden state, dengan parameter W_o, U_o, b_o .

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o) \quad (3.7)$$

3.6.6 Hidden State Update

Cell state c_t mengandung representasi lengkap jangka panjang, namun terlalu kaya untuk digunakan secara langsung. Oleh karena itu, hidden state $h_t \in \mathbb{R}^h$ dibentuk sebagai representasi laten terfilter yang lebih terfokus, yang kemudian digunakan untuk memprediksi aksi lawan atau sebagai input ke modul pengambilan keputusan.

$$h_t = o_t \odot \tanh(c_t) \quad (3.8)$$

Struktur ini memungkinkan model mempertahankan dependensi jangka panjang sekaligus tetap adaptif terhadap perubahan strategi lawan. Oleh karena itu, LSTM sangat sesuai untuk digunakan dalam permainan berulang seperti Iterated Prisoner's Dilemma, di mana perilaku lawan bergantung pada histori is'nteraksi. Namun, karena LSTM hanya menghasilkan prediksi satu langkah ke depan, model ini belum secara eksplisit mempertimbangkan konsekuensi jangka panjang, sehingga masih berpotensi menghasilkan kebijakan yang suboptimal.

3.7 Prediksi Multi-Langkah

Model LSTM menghasilkan distribusi prediktif satu langkah ke depan $p(a_{t+1}^{-i} | h_t)$. Namun, dalam permainan berulang, nilai suatu aksi tidak hanya ditentukan oleh respons lawan pada tahap berikutnya, melainkan oleh konsekuensi jangka panjang sepanjang lintasan interaksi.

3.7.1 Peramalan Rekursif dan Simulasi Monte Carlo (Horizon Tetap)

Untuk memperoleh estimasi lintasan masa depan sepanjang horizon tetap H , model perilaku lawan digunakan secara autoregresif. Pada setiap langkah ke- k , prediksi aksi lawan dihasilkan dari distribusi:

$$\hat{a}_{t+k}^{-i} \sim p_\theta(\cdot | \hat{h}_{t+k-1}), \quad k = 1, \dots, H$$

dengan $\hat{h}_{t+k-1}$ merupakan riwayat yang diperluas secara rekursif menggunakan aksi yang telah direalisasikan pada langkah-langkah sebelumnya.

Proses ini menghasilkan distribusi atas lintasan aksi sepanjang horizon terbatas:

$$\hat{\tau}_t^{(H)} = \{\hat{a}_{t+1}^{-i}, \hat{a}_{t+2}^{-i}, \dots, \hat{a}_{t+H}^{-i}\}$$

Karena jumlah kemungkinan lintasan tumbuh secara eksponensial terhadap H , ekspektasi payoff tidak dihitung secara analitik, melainkan diaproksimasi menggunakan simulasi Monte Carlo.

Untuk suatu aksi awal a_t , estimasi nilai diperoleh melalui M simulasi independen:

$$\hat{Q}_H(a_t) = \frac{1}{M} \sum_{m=1}^M \sum_{k=0}^{H-1} u_i^{(m)}(a_i^{t+k}, a_{-i}^{t+k}) \quad (3.9)$$

dengan:

- H : horizon prediksi tetap,
- M : jumlah rollout Monte Carlo,
- $u_i^{(m)}$: payoff agen pada simulasi ke- m .

Karena horizon bersifat terbatas, faktor diskonto tidak diperlukan, dan nilai aksi merepresentasikan akumulasi payoff sepanjang jendela prediksi tetap.

Dengan demikian, evaluasi aksi dilakukan melalui aproksimasi ekspektasi atas distribusi lintasan terbatas, yang sepenuhnya ditentukan oleh model belief dan horizon yang telah ditetapkan.

3.7.2 Dari Akurasi Prediksi ke Kinerja Strategis

Namun demikian, akurasi prediksi distribusi aksi lawan tidak secara langsung menjamin kinerja strategis yang optimal. Tujuan agen dalam permainan berulang bukan sekadar meminimalkan kesalahan prediksi, melainkan memaksimalkan payoff kumulatif.

Dalam formulasi permainan, misalkan i menyatakan agen yang dikontrol, dan $-i$ menyatakan himpunan seluruh lawan. Aksi yang diambil agen pada waktu t dinotasikan sebagai $a_t^i \in A_i$, sedangkan aksi lawan dinotasikan sebagai $a_t^{-i} \in A_{-i}$.

Fungsi utilitas $u_i(a_t^i, a_t^{-i})$ merepresentasikan payoff yang diterima agen i ketika ia memilih aksi a_t^i dan lawan memilih aksi a_t^{-i} . Dalam konteks *pemodelan lawan*, a_t^{-i} merupakan variabel yang tidak dapat dikontrol dan hanya dapat diperkirakan melalui belief yang dibangun model.

Cumulative Regret (Classical Regret) Untuk mengukur performa jangka panjang, digunakan metrik regret kumulatif (Nisan et al. 2008):

$$R_T = \max_{a_i \in A_i} \sum_{t=1}^T u_i(a_i, a_t^{-i}) - \sum_{t=1}^T u_i(a_t^i, a_t^{-i}) \quad (3.10)$$

Pada persamaan di atas, $\max_{a_i \in A_i}$ merepresentasikan aksi tetap terbaik (*best fixed action*) yang dipilih secara retrospektif setelah seluruh interaksi hingga horizon T diamati. Namun, aksi optimal ini tidak diketahui selama permainan berlangsung. Term pertama $\sum_{t=1}^T u_i(a_i, a_t^{-i})$ merepresentasikan total payoff yang akan diperoleh jika agen selalu memainkan aksi terbaik tersebut, sedangkan term kedua $\sum_{t=1}^T u_i(a_t^i, a_t^{-i})$ adalah payoff aktual dari aksi yang benar-benar diambil agen. Oleh karena itu, R_T mengukur kerugian akibat tidak mengetahui strategi optimal sejak awal.

Pada permainan berulang, optimalitas strategi tidak hanya ditentukan oleh kualitas aksi pada satu waktu, melainkan oleh konsistensi keputusan sepanjang interaksi (Bonanno 2024). Namun, regret kumulatif membandingkan performa agen terhadap satu aksi tetap terbaik (*best fixed action*), yang dipilih secara retrospektif.

Pendekatan ini bersifat terbatas, karena pembanding berupa aksi statis tidak mampu merepresentasikan strategi kondisional yang bergantung pada histori interaksi. Dalam permainan seperti Iterated Prisoner's Dilemma, strategi optimal sering kali berbentuk kebijakan adaptif, di mana aksi pada waktu tertentu bergantung pada perilaku lawan sebelumnya.

Akibatnya, aksi yang optimal secara per-langkah tidak selalu menghasilkan payoff kumulatif yang optimal, karena keputusan saat ini dapat mempengaruhi respons lawan di masa depan. Dengan demikian, evaluasi berbasis aksi tetap menjadi kurang representatif terhadap kualitas strategi dalam konteks permainan berulang. (Bonanno 2024)

Equilibrium Regret Oleh karena itu, digunakan konsep equilibrium regret, yang mengukur deviasi performa agen terhadap strategi ekuilibrium yang mempertimbangk-

an interaksi strategis antar agen.

Secara umum, equilibrium regret dapat didefinisikan sebagai selisih antara payoff yang diperoleh agen dengan payoff yang akan diperoleh jika agen mengikuti strategi ekuilibrium. (Bonanno 2024) Misalkan π_i^* adalah strategi ekuilibrium untuk agen i , dan π_i adalah strategi yang digunakan, maka equilibrium regret dapat dituliskan sebagai:

$$R_T^{eq} = \sum_{t=1}^T (u_i(a_t^*, a_t^{-i}) - u_i(a_t^i, a_t^{-i})) \quad (3.11)$$

di mana a_t^* merupakan aksi yang dihasilkan oleh strategi ekuilibrium π_i^* pada waktu t .

Meskipun equilibrium regret memberikan pembandingan yang lebih representatif dibandingkan aksi tetap, pendekatan ini tetap mengasumsikan keberadaan strategi ekuilibrium yang stabil sepanjang interaksi. Namun, dalam praktiknya, agen berinteraksi dengan lawan yang adaptif, di mana strategi lawan dapat berubah sebagai respons terhadap histori permainan dan tindakan agen itu sendiri. Dengan demikian, bahkan strategi ekuilibrium atau respons terbaik yang relevan dapat bergeser equilibrium dari waktu ke waktu.

Dynamic Regret (Fixed Horizon) Dalam lingkungan adaptif, aksi optimal dapat berubah seiring perubahan perilaku lawan. Oleh karena itu, digunakan dynamic regret yang membandingkan performa agen dengan aksi optimal yang dihitung ulang pada setiap waktu berdasarkan horizon tetap H .

Dynamic regret didefinisikan sebagai:

$$R_T^{dyn} = \sum_{t=1}^T (Q_H(a_t^* | h_t) - Q_H(a_t^i | h_t)) \quad (3.12)$$

dengan aksi optimal pada waktu t diberikan oleh:

$$a_t^* = \arg \max_{a_i \in A_i} Q_H(a_i | h_t)$$

di mana $Q_H(a_i | h_t)$ merupakan estimasi nilai aksi berdasarkan simulasi Monte Carlo sepanjang horizon tetap H .

Dengan formulasi ini, dynamic regret mengukur selisih performa agen terhadap keputusan optimal yang dihitung ulang pada setiap waktu, tanpa mengasumsikan

strategi pembandingan yang statis.

Metrik ini lebih sesuai untuk mengevaluasi kinerja dalam lingkungan non-stasioner, karena comparator diperbolehkan berubah secara temporal.

3.7.3 Pemisahan Pemodelan Lawan

Dalam konteks pemodelan lawan, terdapat dua komponen utama, yaitu model prediksi perilaku lawan dan aksi agen. Secara umum, kedua komponen ini dapat dirancang secara terintegrasi maupun terpisah.

Pendekatan terintegrasi mempelajari representasi lawan secara end-to-end bersama dengan policy, sehingga prediksi yang dihasilkan langsung digunakan dalam proses pengambilan keputusan. Pendekatan ini banyak digunakan dalam *reinforcement learning*, karena memungkinkan optimasi langsung terhadap tujuan akhir berupa reward kumulatif (Di et al. 2023)

Namun, keterkaitan yang erat antara prediksi dan policy menyulitkan interpretasi kualitas model lawan secara terpisah. Kesalahan prediksi dapat terkompensasi oleh policy, atau sebaliknya, sehingga evaluasi berbasis performa akhir tidak selalu mencerminkan akurasi representasi lawan.

Sebagai alternatif, pendekatan pemisahan pemodelan lawan memisahkan proses pembelajaran model lawan dari kebijakan agen. Dalam kerangka ini, model bertujuan untuk memperkirakan distribusi aksi lawan

$$p(a_t^{-i} \mid h_{<t})$$

berdasarkan riwayat interaksi $h_{<t-1}$, tanpa secara langsung dioptimalkan terhadap reward agen.

Pemisahan ini memungkinkan evaluasi model dilakukan secara independen (Di et al. 2023), misalnya melalui metrik probabilistik seperti *log-likelihood* atau *cross-entropy*. Namun, dalam skenario interaksi berulang, prediksi dilakukan secara berurutan sepanjang waktu, sehingga kesalahan prediksi pada satu langkah dapat mempengaruhi langkah berikutnya, fenomena yang dikenal sebagai *compounding error*.

Selain itu, dalam pengaturan *online*, prediksi distribusi aksi lawan tidak selalu dapat diverifikasi secara langsung pada setiap langkah, terutama ketika policy agen tidak secara eksplisit mengeksplorasi prediksi tersebut. Hal ini menyebabkan adanya kesenjangan antara evaluasi berbasis akurasi prediksi dan dampaknya terhadap

kinerja strategis agen.

3.7.4 professor forcing

Pada model sekuens autoregresif seperti RNN atau LSTM, prediksi pada waktu t bergantung pada output sebelumnya. Secara umum, dinamika sistem dituliskan sebagai:

$$h_t = f(h_{t-1}, y_{t-1}; \theta)$$

$$\hat{y}_t = g(h_t; \theta)$$

dengan h_t hidden state, y_{t-1} input autoregresif, $\hat{y}_t$ prediksi model, dan θ parameter yang dipelajari. Dalam skema *professor forcing*, input autoregresif selama pelatihan digantikan oleh ground-truth y_{t-1}^* :

$$h_t = f(h_{t-1}, y_{t-1}^*; \theta).$$

Fungsi kerugian didefinisikan sebagai:

$$\mathcal{L}(\theta) = \sum_{t=1}^T \ell(\hat{y}_t, y_t^*), \quad (3.13)$$

dengan $\ell(\cdot)$ fungsi loss yang sesuai.

professor forcing mempercepat konvergensi dan menghasilkan gradien yang lebih stabil, karena distribusi input selama pelatihan identik dengan distribusi data sebenarnya (Lamb et al. 2016).

Namun, pada fase inferensi rekursif sepanjang horizon H , model menggunakan prediksinya sendiri:

$$h_t = f(h_{t-1}, \hat{y}_{t-1}; \theta).$$

Perbedaan distribusi ini menimbulkan *exposure bias*, yang menjadi sumber utama *compounding error* dalam forecasting multi-langkah. Semakin panjang horizon H , semakin besar potensi akumulasi kesalahan.

3.7.5 Fungsi Objektif Negative Log-Likelihood

Untuk mengevaluasi kualitas prediksi sekuensial lawan dalam horizon multi-step, digunakan metrik *Negative Log-Likelihood* (NLL) sebagai proper scoring rule yang konsisten terhadap estimasi distribusi probabilistik.

Misalkan pada waktu t tersedia riwayat interaksi

$$h_t = \{(a_i^1, a_{-i}^1), \dots, (a_i^t, a_{-i}^t)\}.$$

Model pemodelan lawan menghasilkan distribusi probabilitas atas aksi lawan pada langkah berikutnya, yang dinotasikan sebagai:

$$P_\theta(a_{-i}^{t+1} \mid h_t)$$

dengan θ merepresentasikan parameter model (misalnya parameter LSTM).

Untuk prediksi multi-step sepanjang horizon H , model digunakan secara autoregresif, sehingga distribusi pada langkah ke- k bergantung pada riwayat yang telah diperluas hingga waktu tersebut. Secara umum, probabilitas gabungan untuk urutan aksi aktual lawan $a_{-i}^{t+1:t+H}$ diberikan oleh:

$$P_\theta(a_{-i}^{t+1:t+H} \mid h_t) = \prod_{k=1}^H P_\theta(a_{-i}^{t+k} \mid \hat{h}_{t+k-1}) \quad (3.14)$$

dengan:

- a_{-i}^{t+k} : aksi aktual lawan pada waktu $t + k$,
- $\hat{h}_{t+k-1}$: riwayat yang digunakan model pada langkah ke- k , yang terdiri dari riwayat asli h_t yang diperluas secara rekursif menggunakan observasi aktual hingga waktu $t + k - 1$,
- H : panjang horizon prediksi multi-step.

Negative Log-Likelihood untuk satu segmen horizon sepanjang H kemudian didefinisikan sebagai:

$$\mathcal{L}_{\text{NLL}}^{(H)} = - \sum_{k=1}^H \log P_\theta(a_{-i}^{t+k} \mid \hat{h}_{t+k-1}) \quad (3.15)$$

Nilai NLL yang lebih kecil menunjukkan bahwa model memberikan probabilitas yang lebih tinggi terhadap aksi aktual yang benar-benar terjadi. Karena NLL

merupakan proper scoring rule, metrik ini tidak hanya mengevaluasi ketepatan klasifikasi, tetapi juga kualitas kalibrasi probabilitas yang dihasilkan model.

Dalam konteks IPD dengan lawan adaptif, penggunaan NLL multi-step memungkinkan pengukuran efek *compounding error* akibat prediksi rekursif. Jika distribusi prediksi menjadi semakin bias pada horizon yang lebih panjang, maka akumulasi log-loss akan meningkat secara signifikan, mencerminkan degradasi kualitas belief seiring waktu.

3.7.6 Rank Order Centroid (ROC)

Metode *Rank Order Centroid* (ROC) merupakan teknik pembobotan dalam *multi-criteria decision making* (MCDM) yang digunakan ketika hanya informasi peringkat (ranking) kriteria yang tersedia, tanpa nilai bobot numerik eksplisit. Metode ini diperkenalkan oleh Barron dan Barrett sebagai pendekatan aproksimasi sederhana terhadap bobot yang diperoleh dari metode *swing weighting* atau metode pembobotan berbasis utilitas (Barron dan Barrett 1996).

Misalkan terdapat n kriteria yang telah diurutkan berdasarkan tingkat kepentingannya, dengan kriteria peringkat pertama dianggap paling penting. Bobot ROC untuk kriteria ke- i didefinisikan sebagai rata-rata dari kebalikan peringkat mulai dari posisi tersebut hingga peringkat terakhir, yaitu:

$$w_i = \frac{1}{n} \sum_{j=i}^n \frac{1}{j}, \quad \text{untuk } i = 1, 2, \dots, n. \quad (3.16)$$

Dengan demikian, bobot yang dihasilkan memenuhi sifat:

$$w_1 \geq w_2 \geq \dots \geq w_n, \quad \text{dan} \quad \sum_{i=1}^n w_i = 1.$$

Pendekatan ini mengasumsikan bahwa seluruh vektor bobot yang konsisten dengan urutan peringkat memiliki peluang yang sama, sehingga bobot ROC merepresentasikan nilai ekspektasi dari distribusi seragam atas seluruh kemungkinan bobot yang memenuhi urutan tersebut (Barron dan Barrett 1996).

Keunggulan utama metode ROC adalah kesederhanaannya dan kemampuannya menghasilkan estimasi bobot yang cukup representatif meskipun hanya tersedia informasi ordinal. Beberapa studi menunjukkan bahwa bobot ROC sering kali memberikan performa yang mendekati metode pembobotan yang lebih kompleks, khusus-

nya ketika informasi numerik detail sulit diperoleh (Stillwell et al. 1981).

Dalam konteks penelitian ini, metode ROC digunakan untuk memberikan pembobotan berbeda pada prediksi lintasan (trajectory) berdasarkan urutan waktu, di mana prediksi pada langkah awal diberikan bobot lebih besar dibandingkan langkah berikutnya.

BAB IV

ANALISIS DAN PERANCANGAN


4.1 Deskripsi Umum

Penelitian ini bertujuan mengembangkan algoritma pembelajaran *online* untuk skenario *Iterated Prisoner's Dilemma* (IPD) dengan lawan yang dapat bersifat adaptif maupun non-stasioner.

Fokus utama penelitian adalah pada pemodelan lawan yang sepenuhnya *terpisah* (*decoupled*) dari sinyal reward agen. Model prediktif dilatih untuk mengestimasi distribusi aksi lawan berdasarkan riwayat interaksi, tanpa menggunakan informasi reward sebagai sinyal pembelajaran.

Model prediksi tersebut kemudian digunakan sebagai komponen dalam simulasi *multi-step Monte Carlo rollout* untuk mengestimasi nilai aksi agen. Dengan demikian, proses pembentukan belief terhadap lawan dipisahkan secara eksplisit dari proses evaluasi utilitas agen.

Pendekatan ini memungkinkan analisis terhadap stabilitas prediksi multi-langkah serta dampaknya terhadap kualitas perencanaan aksi, tanpa mencampurkan bias utilitas ke dalam representasi model lawan.



Gambar 4.1 Diagram metodologi.

diagram

4.2 Formulasi Masalah

Penelitian ini mempertimbangkan skenario *Iterated Prisoner's Dilemma* (IPD) dengan horizon tetap T .

Pada setiap langkah waktu $t = 1, \dots, T$, agen dan lawan masing-masing memilih aksi:

$$a_t^{agent}, a_t^{opp} \in \{C, D\}.$$

Reward diperoleh berdasarkan matriks payoff standar IPD.

Lawan diasumsikan dapat bersifat adaptif maupun non-stasioner, namun algoritma internalnya tidak diketahui. Lawan dapat berupa strategi tetap, strategi reaktif, atau agen pembelajaran daring seperti Q-learning atau pendekatan berbasis estimasi frekuensi.

Agen tidak memiliki akses terhadap parameter internal, fungsi utilitas, maupun mekanisme pembelajaran lawan. Satu-satunya informasi yang tersedia adalah riwayat interaksi:

$$H_t = \{a_1^{agent}, a_1^{opp}, \dots, a_t^{agent}, a_t^{opp}\}.$$

Tujuan agen adalah memilih aksi yang memaksimalkan reward kumulatif selama horizon T , dengan memanfaatkan modul pemodelan lawan yang dilatih secara terpisah dari sinyal reward.

Model pemodelan lawan menghasilkan distribusi prediktif

$$p(a_{t+1}^{opp} \mid H_t),$$

yang kemudian digunakan dalam simulasi multi-langkah untuk mengestimasi nilai aksi kandidat agen.

4.3 Spesifikasi Lingkungan

Penelitian ini membangun model prediktif aksi lawan pada permainan berulang dan memanfaatkannya untuk estimasi nilai aksi melalui simulasi multi-langkah (*Monte Carlo rollout*). Pendekatan ini memisahkan secara eksplisit proses pemodelan lawan dari sinyal reward agen.

4.3.1 Setup Permainan

Permainan yang digunakan adalah *Iterated Prisoner's Dilemma* (IPD) dua pemain dengan dua aksi diskrit yang tersedia, yaitu C (Cooperate) dan D (Defect), di mana C menyatakan *Cooperate* dan D menyatakan *Defect*.

Matriks Payoff Struktur payoff mengikuti formulasi klasik Prisoner's Dilemma dengan Nilai numerik yang digunakan:

$$P = \begin{bmatrix} R & S \\ T & P \end{bmatrix} = \begin{bmatrix} 3 & 0 \\ 5 & 1 \end{bmatrix}$$

dengan:

- $T = 5$ (*Temptation*)
- $R = 3$ (*Reward*)
- $P = 1$ (*Punishment*)
- $S = 0$ (*Sucker*)

Pada setiap langkah t Reward ditentukan langsung berdasarkan matriks payoff P .

Horizon Permainan Permainan dijalankan dengan horizon tetap sepanjang $T = 100$ langkah per episode. Penggunaan horizon tetap bertujuan untuk mengisolasi analisis stabilitas prediksi multi-langkah tanpa pengaruh terminasi stokastik.

4.4 Desain Populasi Strategi Lawan

Desain populasi strategi lawan dalam penelitian ini bertujuan untuk membentuk lingkungan interaksi yang heterogen, sehingga model prediksi diuji pada spektrum perilaku yang representatif terhadap dinamika *Iterated Prisoner's Dilemma* (IPD). Landasan konseptual mengenai karakteristik masing-masing strategi telah dijelaskan pada Bab 3, sehingga pada bagian ini difokuskan pada rasionalisasi desain eksperimental dan konfigurasi populasi.

Populasi lawan terdiri atas enam tipe strategi sebagai berikut:

- *Tit-for-Tat* (TFT),

- *Grim Trigger*,
- *Win-Stay Lose-Shift* (WSLS),
- *Forgiving-Tit-for-Tat*,
- *Hedge*,
- *Online Mirror Descent* (OMD).

4.4.1 Tujuan Eksperimental dari Heterogenitas Populasi

Heterogenitas populasi dirancang untuk menguji tiga aspek utama model prediksi:

1. **Kemampuan identifikasi rezim perilaku**, khususnya pada strategi dengan titik perubahan (misalnya Grim Trigger).
2. **Kemampuan memodelkan dependensi temporal lebih dari satu langkah**, terutama pada strategi yang menghasilkan pola siklik.
3. **Kemampuan menangani dinamika adaptif non-deterministik**, seperti pada Hedge dan OMD.

Dengan komposisi ini, model tidak hanya diuji pada stabilitas jangka pendek (one-step prediction), tetapi juga pada konsistensi trajektori prediksi dalam horizon multi-langkah.

4.4.2 Proporsi dan Skema Sampling

Setiap strategi dalam populasi diberikan proporsi yang seimbang pada tahap generasi data untuk menghindari bias distribusi kelas. Dalam setiap simulasi, lawan dipilih secara acak dari himpunan strategi dengan probabilitas seragam. Pendekatan ini memastikan bahwa performa model tidak dipengaruhi oleh dominasi strategi tertentu dalam dataset pelatihan maupun pengujian.

Jika diperlukan, eksperimen tambahan dapat dilakukan dengan distribusi tidak seimbang untuk menguji robustnes model terhadap pergeseran distribusi populasi (distribution shift).

4.4.3 Implikasi terhadap Evaluasi Multi-Step Forecasting

Desain populasi ini memungkinkan evaluasi eksplisit terhadap:

4.4.4 Kategorisasi Perilaku Strategi

Untuk memastikan keberagaman dinamika trajektori, strategi-strategi tersebut diklasifikasikan ke dalam tiga kategori perilaku:

- akumulasi error pada prediksi trajektori,
- sensitivitas model terhadap perubahan fase strategi,
- degradasi performa pada strategi adaptif dibanding deterministik.

Dengan demikian, populasi strategi lawan tidak hanya berfungsi sebagai sumber data interaksi, tetapi sebagai instrumen eksperimental untuk menguji hipotesis utama penelitian mengenai misalignment antara objektif prediksi satu langkah dan kebutuhan perencanaan strategis multi-langkah.

4.5 Prosedur dan Simulasi Generasi Data

Data penelitian diperoleh melalui simulasi Iterated Prisoner's Dilemma (IPD) menggunakan populasi strategi lawan yang telah didefinisikan pada bagian sebelumnya. Prosedur ini bertujuan untuk menghasilkan trajektori interaksi temporal yang dapat digunakan sebagai dasar pembentukan dataset prediksi multi-langkah.

4.5.1 Konfigurasi Episode

Setiap simulasi dijalankan dalam bentuk episode dengan panjang horizon tetap sebesar $T = 100$ langkah waktu. Pada setiap langkah t , agent dan lawan secara simultan memilih aksi $a_t \in \{C, D\}$. Satu episode menghasilkan sekuens interaksi:

$$\{(a_1^{agent}, a_1^{opp}), (a_2^{agent}, a_2^{opp}), \dots, (a_T^{agent}, a_T^{opp})\}.$$

Untuk setiap tipe strategi lawan, simulasi dilakukan dalam beberapa ronde independen guna memperoleh variasi trajektori dan memastikan stabilitas distribusi perilaku yang diamati. Jumlah ronde per strategi ditetapkan konstan agar distribusi data antar strategi tetap seimbang.

4.5.2 Mekanisme Trembling Hand

Untuk menghindari trajektori deterministik yang sepenuhnya dapat diprediksi, diterapkan mekanisme *trembling hand* dengan probabilitas $\epsilon = 0.05$. Pada setiap langkah waktu, baik agent maupun lawan memiliki peluang sebesar 5% untuk secara acak membalik aksi yang dipilih.

Secara formal, jika aksi asli adalah a_t , maka aksi aktual yang dieksekusi $\tilde{a}_t$ didefinisikan sebagai:

$$\tilde{a}_t = \begin{cases} a_t, & \text{dengan probabilitas } 1 - \epsilon, \\ \text{flip}(a_t), & \text{dengan probabilitas } \epsilon. \end{cases}$$

Penambahan noise ini memiliki dua fungsi utama:

1. Menghindari konvergensi deterministik sempurna pada strategi berbasis memori seperti TFT atau Grim Trigger.
2. Menguji robustnes model terhadap deviasi lokal yang dapat menyebabkan propagasi error pada prediksi multi-langkah.

4.5.3 Struktur Penyimpanan Data

Untuk setiap episode, seluruh pasangan aksi agent dan lawan pada setiap langkah waktu disimpan sebagai satu trajektori lengkap. Dataset akhir terdiri atas kumpulan trajektori:

$$\mathcal{D} = \{\tau^{(1)}, \tau^{(2)}, \dots, \tau^{(N)}\},$$

dengan setiap trajektori $\tau^{(i)}$ berupa urutan pasangan aksi sepanjang 100 langkah waktu.

Struktur data ini memungkinkan pembentukan sampel pelatihan dalam bentuk:

- Prediksi satu langkah ke depan,
- Prediksi multi-langkah dengan horizon k ,
- Prediksi trajektori penuh berbasis conditioning pada histori parsial.

4.5.4 Implikasi terhadap Multi-Step Forecasting

Karena data dihasilkan melalui interaksi berulang dalam horizon panjang dengan adanya noise, trajektori yang terbentuk mencerminkan kombinasi antara:

- dinamika deterministik strategi,
- transisi rezim akibat hukuman atau adaptasi,
- deviasi stokastik akibat trembling hand.

Kombinasi ini penting untuk mengevaluasi fenomena akumulasi error pada prediksi multi-langkah serta menguji apakah model yang dioptimalkan untuk objektif satu langkah mampu mempertahankan konsistensi trajektori dalam horizon yang lebih panjang.

4.6 Representasi dan Persiapan Dataset

Bagian ini menjelaskan bagaimana trajektori hasil simulasi dikonversi menjadi format yang dapat digunakan untuk pelatihan model prediksi.

4.6.1 Representasi Dasar Aksi

Pada setiap langkah waktu t , interaksi direpresentasikan sebagai vektor dua dimensi:

$$x_t = \begin{bmatrix} a_t^{agent} \\ a_t^{opp} \end{bmatrix}, \quad a_t^{agent}, a_t^{opp} \in \{C, D\}.$$

Untuk kebutuhan komputasional, aksi dikodekan dalam bentuk numerik biner, misalnya:

$$C = 0, \quad D = 1.$$

Satu episode sepanjang $T = 100$ langkah direpresentasikan sebagai matriks:

$$X = [x_1, x_2, \dots, x_T]^\top \in \mathbb{R}^{T \times 2}.$$

Dengan demikian, setiap trajektori merupakan deret waktu dua kanal (two-channel time series) yang memuat histori aksi kedua pemain.

4.6.2 Augmentasi Simetri Peran

Untuk meningkatkan keberagaman distribusi interaksi dan mengurangi bias peran (role bias), dilakukan augmentasi data melalui pertukaran dimensi:

$$x'_t = \begin{bmatrix} a_t^{opp} \\ a_t^{agent} \end{bmatrix}.$$

Artinya, setiap trajektori asli τ menghasilkan satu trajektori tambahan τ' dengan peran agent dan lawan dipertukarkan.

Augmentasi ini berasumsi bahwa struktur permainan bersifat simetris terhadap pertukaran pemain. Secara eksperimental, langkah ini bertujuan untuk:

- meningkatkan ukuran dataset,
- mendorong model mempelajari pola interaksi, bukan identitas tetap pemain,
- meningkatkan generalisasi terhadap variasi distribusi lawan.

4.6.3 Pembentukan Sampel Prediksi

Dari setiap trajektori penuh, dibentuk pasangan input-target sesuai skenario pelatihan:

- Untuk prediksi satu langkah:

$$(x_1, \dots, x_t) \rightarrow a_{t+1}^{opp}.$$

- Untuk prediksi multi-langkah horizon k :

$$(x_1, \dots, x_t) \rightarrow (a_{t+1}^{opp}, \dots, a_{t+k}^{opp}).$$

Dengan pendekatan ini, dataset akhir terdiri dari sekumpulan subsekuens histori dengan target trajektori lawan pada horizon tertentu.

4.6.4 Pengacakan dan Pembagian Data

Seluruh sampel yang terbentuk kemudian diacak secara acak (random shuffle) untuk menghilangkan korelasi urutan antar episode. Setelah proses pengacakan, dataset dibagi menjadi:

- 70% data pelatihan (training set),
- 15% data validasi (validation set).
- 15% data test (test set)

Pembagian dilakukan pada level trajektori (bukan pada level langkah waktu) untuk mencegah kebocoran informasi temporal antar subset. Dengan demikian, tidak terdapat fragmen dari satu episode yang muncul sekaligus pada data pelatihan dan validasi.

4.6.5 Implikasi terhadap Evaluasi Model

Representasi dua kanal dan augmentasi simetri memungkinkan model menangkap dependensi silang antar aksi pemain. Sementara itu, pemisahan berbasis trajektori memastikan evaluasi dilakukan pada distribusi interaksi yang benar-benar tidak terlihat selama pelatihan, sehingga mengurangi risiko overfitting berbasis memorisasi pola spesifik episode.

4.7 Perancangan Model Prediksi Lawan

Model prediksi lawan dibangun menggunakan arsitektur Long Short-Term Memory (LSTM) sebagai encoder temporal untuk menangkap dependensi historis dalam interaksi IPD. Arsitektur terdiri atas:

- Satu lapisan LSTM dengan *hidden size* 64,
- Lapisan linear sebagai proyeksi ke ruang aksi lawan,
- Fungsi softmax untuk menghasilkan distribusi probabilitas atas aksi $\{C, D\}$.

Diberikan histori hingga waktu t :

$$h_t = \text{LSTM}(x_1, \dots, x_t), \quad \hat{y}_{t+1} = \text{softmax}(Wh_t + b),$$

dengan $\hat{y}_{t+1}$ distribusi prediksi aksi lawan.

4.7.1 Model Satu Langkah

Model satu langkah dioptimalkan untuk memprediksi aksi lawan pada waktu $t + 1$ berdasarkan histori hingga waktu t .

Fungsi objektif yang digunakan adalah *cross-entropy loss* satu langkah:

$$\mathcal{L}_{1-step} = - \sum_{t=1}^{T-1} y_{t+1} \log \hat{y}_{t+1}.$$

Optimisasi ini mendorong model memaksimalkan akurasi prediksi lokal tanpa mempertimbangkan konsistensi trajektori jangka panjang.

4.7.2 Model Multi Langkah

Berbeda dengan model satu langkah, model multi langkah dirancang untuk mempelajari prediksi trajektori lawan sepanjang horizon k secara eksplisit.

Pada skenario ini, pelatihan dilakukan menggunakan *teacher forcing*. Artinya, pada setiap langkah dalam horizon, input yang diberikan ke LSTM tetap menggunakan aksi aktual (ground-truth), bukan hasil prediksi model.

Untuk setiap histori awal hingga waktu t , model menghasilkan distribusi:

$$(\hat{y}_{t+1}, \hat{y}_{t+2}, \dots, \hat{y}_{t+k}),$$

dengan input rekursif:

$$x_{t+i} = \begin{bmatrix} a_{t+i}^{agent,oracle} \\ a_{t+i}^{opp,groundtruth} \end{bmatrix}.$$

Oracle pada konteks ini merepresentasikan agent yang diketahui secara deterministik dalam simulasi. Oracle digunakan untuk menghasilkan aksi agent yang konsisten terhadap trajektori ground-truth lawan selama proses pelatihan.

Fungsi loss multi langkah didefinisikan sebagai akumulasi cross-entropy sepanjang horizon:

$$\mathcal{L}_{multi-step} = - \sum_{i=1}^k y_{t+i} \log \hat{y}_{t+i}.$$

Dengan formulasi ini, model secara eksplisit dioptimalkan untuk mempertahankan konsistensi prediksi sepanjang beberapa langkah, bukan hanya pada langkah

berikutnya.

4.7.3 Perbedaan Konseptual Kedua Model

Perbedaan utama antara kedua pendekatan terletak pada:

- **Ruang optimisasi:** satu langkah bersifat lokal, sedangkan multi langkah bersifat trajektorial.
- **Distribusi error:** model multi langkah menerima sinyal kesalahan dari seluruh horizon k , sehingga lebih sensitif terhadap dinamika jangka menengah.
- **Tujuan pembelajaran:** model satu langkah meminimalkan error prediksi langsung, sedangkan model multi langkah meminimalkan deviasi trajektori.

4.7.4 Evaluasi Generalisasi

Untuk menguji robustnes dan generalisasi, kedua model dievaluasi pada strategi lawan yang tidak terlihat selama pelatihan. Evaluasi dilakukan pada:

- akurasi satu langkah,
- akurasi trajektori multi langkah,
- degradasi performa seiring bertambahnya horizon prediksi.

Pendekatan ini memungkinkan analisis empiris terhadap potensi misalignment antara objektif satu langkah dan kebutuhan prediksi trajektori dalam repeated games.

4.8 Protokol Pelatihan

Pelatihan model dilakukan dalam dua skema utama: (1) pelatihan satu langkah dan (2) pelatihan multi langkah. Kedua skema menggunakan arsitektur yang sama, namun berbeda dalam objektif optimisasi dan mekanisme pembentukan loss.

4.8.1 Pelatihan Satu Langkah

Pada tahap ini, model dioptimalkan untuk memprediksi aksi lawan pada waktu $t + 1$ berdasarkan histori hingga waktu t .

Fungsi objektif yang digunakan adalah *cross-entropy loss* satu langkah:

$$\mathcal{L}_{1-step} = -\frac{1}{T-1} \sum_{t=1}^{T-1} y_{t+1} \log \hat{y}_{t+1}.$$

Optimisasi dilakukan menggunakan algoritma Adam dengan parameter pembelajaran yang ditetapkan sebelumnya. Pelatihan berlangsung selama sejumlah epoch tertentu dengan *batch size* tetap, serta validasi dilakukan pada setiap epoch untuk memantau konvergensi dan mencegah overfitting.

Model yang dihasilkan merepresentasikan baseline prediksi lokal tanpa optimisasi eksplisit terhadap konsistensi trajektori.

4.8.2 Pelatihan Multi Langkah

Pada tahap ini, model dilatih untuk memprediksi trajektori aksi lawan sepanjang horizon k menggunakan mekanisme *teacher forcing*.

Untuk setiap histori hingga waktu t , model menghasilkan prediksi:

$$(\hat{y}_{t+1}, \hat{y}_{t+2}, \dots, \hat{y}_{t+k}).$$

Selama pelatihan, input pada setiap langkah dalam horizon menggunakan aksi ground-truth (teacher forcing). Namun, untuk membentuk trajektori interaksi dua arah, digunakan oracle agent untuk menghasilkan aksi respon terhadap aksi lawan pada setiap langkah. Dengan demikian, dinamika interaksi tetap konsisten terhadap kebijakan agent yang diasumsikan diketahui.

Fungsi Loss Multi Langkah Loss dasar didefinisikan sebagai akumulasi cross-entropy sepanjang horizon:

$$\mathcal{L}_{multi} = -\sum_{i=1}^k w_i y_{t+i} \log \hat{y}_{t+i},$$

dengan w_i merupakan bobot pada langkah ke- i .

Skema Pembobotan Rank Order Centroid (ROC) Untuk mengontrol kontribusi error pada tiap langkah, digunakan pembobotan berbasis Rank Order Centroid (ROC).

Bobot ROC untuk horizon k didefinisikan sebagai:

$$w_i = \frac{1}{k} \sum_{j=i}^k \frac{1}{j},$$

yang kemudian dinormalisasi sehingga:

$$\sum_{i=1}^k w_i = 1.$$

Dua varian pembobotan digunakan:

- **ROC Newest:** langkah terdekat ($i = 1$) diberi bobot terbesar.
- **ROC Latest:** langkah terjauh ($i = k$) diberi bobot terbesar (urutan dibalik).

Sebagai pembandingan, digunakan juga skema tanpa ROC, yaitu bobot seragam:

$$w_i = \frac{1}{k}.$$

Konfigurasi Eksperimen Model dilatih dengan kombinasi berikut:

- Teacher Forcing, $k = 5$, tanpa ROC
- Teacher Forcing, $k = 10$, tanpa ROC
- Teacher Forcing + ROC Newest, $k = 5$
- Teacher Forcing + ROC Newest, $k = 10$
- Teacher Forcing + ROC Latest, $k = 5$
- Teacher Forcing + ROC Latest, $k = 10$

Seluruh loss dinormalisasi terhadap jumlah langkah horizon agar dapat dibandingkan secara adil antar konfigurasi k .

Evaluasi Closed-Loop Meskipun pelatihan menggunakan teacher forcing, evaluasi dilakukan secara rekursif (*closed-loop rollout*). Pada tahap ini:

1. Model memprediksi aksi lawan pada langkah berikutnya.
2. Oracle agent menghasilkan aksi respon berdasarkan prediksi tersebut.

3. Pasangan aksi hasil prediksi dimasukkan kembali sebagai input.
4. Proses diulang hingga horizon k .

Loss trajektori kemudian dihitung terhadap ground-truth untuk menilai akumulasi error akibat propagasi prediksi sendiri.

4.9 Protokol Evaluasi

Evaluasi dilakukan dalam dua skema utama, yaitu evaluasi terpisah (*decoupled evaluation*) dan evaluasi terpasang (*coupled evaluation*). Kedua skema ini dirancang untuk mengukur perbedaan performa model pada prediksi lokal satu langkah dan pada dinamika interaksi trajektorial multi-langkah.

4.9.1 Evaluasi Terpisah (Decoupled)

Evaluasi terpisah dilakukan dengan mengukur kemampuan model dalam memprediksi aksi lawan satu langkah ke depan tanpa membentuk trajektori rekursif.

Pada skema ini, model hanya menghasilkan prediksi:

$$\hat{y}_{t+1}$$

berdasarkan histori hingga waktu t , dan evaluasi dilakukan terhadap ground-truth aksi lawan pada langkah berikutnya.

Metrik yang digunakan meliputi:

- **Confusion Matrix**, untuk menganalisis distribusi kesalahan klasifikasi antara aksi C dan D .
- **Negative Log-Likelihood (NLL)**:

$$\text{NLL} = -\frac{1}{N} \sum_i \log p_\theta(a_i^{opp}),$$

yang mengukur kualitas kalibrasi probabilistik model.

- **Cross-Entropy**, sebagai rata-rata loss klasifikasi satu langkah.

Evaluasi ini merepresentasikan kualitas prediksi lokal dan menjadi baseline terhadap performa trajektorial.

4.9.2 Evaluasi Terpasang (Coupled)

Evaluasi terpasang dilakukan menggunakan prediksi multi langkah secara rekursif (*closed-loop rollout*). Pada skema ini, model:

1. Memprediksi aksi lawan pada langkah berikutnya,
2. Oracle agent menghasilkan respon terhadap prediksi tersebut,
3. Hasil pasangan aksi dimasukkan kembali sebagai input,
4. Proses diulang hingga horizon k .

Dengan pendekatan ini, terbentuk trajektori prediksi sepanjang horizon k yang kemudian dibandingkan dengan trajektori ground-truth.

Metrik evaluasi meliputi:

- **Akurasi Multi Langkah:**

$$\text{Acc}_k = \frac{1}{k} \sum_{i=1}^k \mathbf{1}(\hat{a}_{t+i}^{opp} = a_{t+i}^{opp}),$$

yang mengukur konsistensi prediksi sepanjang horizon.

- **Dynamic Regret**, yaitu selisih antara reward kumulatif yang diperoleh agent berdasarkan trajektori prediksi dibandingkan dengan reward pada trajektori aktual:

$$\text{Regret}_k = R_k^{oracle} - R_k^{pred}.$$

- **Reward Kumulatif**, yaitu total payoff agent sepanjang horizon k berdasarkan interaksi dengan trajektori prediksi.

Metrik-metrik ini menangkap dampak kesalahan prediksi terhadap kualitas interaksi strategis dalam repeated game.

4.9.3 Validasi dan Pengujian

Perbandingan performa dilakukan pada:

- **Validation set**, untuk memilih konfigurasi terbaik berdasarkan performa trajektorial.

- **Test set**, untuk mengukur generalisasi akhir model terhadap distribusi yang tidak terlihat selama pelatihan.

Evaluasi dilakukan baik pada skenario strategi yang telah terlihat selama pelatihan maupun pada strategi yang sepenuhnya baru, guna menguji kemampuan generalisasi terhadap dinamika interaksi yang tidak dikenal sebelumnya.

4.10 Analisis Eksperimen

Analisis eksperimen difokuskan pada pengujian hipotesis utama penelitian, yaitu adanya potensi misalignment antara objektif prediksi satu langkah dan kebutuhan konsistensi trajektori dalam repeated games.

Analisis dilakukan terhadap tiga aspek utama:

1. Akumulasi error pada prediksi multi-langkah,
2. Sensitivitas model terhadap perubahan fase strategi,
3. Degradasi performa pada strategi adaptif dibandingkan strategi deterministik.

4.10.1 Akumulasi Error Multi-Langkah

Aspek pertama menganalisis bagaimana error berkembang seiring bertambahnya horizon prediksi k .

Evaluasi dilakukan dengan membandingkan:

- NLL dan Cross-Entropy pada evaluasi terpisah (satu langkah),
- Akurasi multi-langkah,
- Dynamic regret,
- Reward kumulatif rata-rata.

Akumulasi error dianalisis dengan mengamati:

$$\Delta_k = \text{Acc}_1 - \text{Acc}_k,$$

serta peningkatan regret seiring bertambahnya k .

Jika model dengan performa terbaik pada NLL satu langkah menunjukkan degradasi signifikan pada regret atau reward kumulatif, maka hal tersebut mendukung hipotesis adanya misalignment antara objektif lokal dan performa trajektorial.

4.10.2 Sensitivitas terhadap Perubahan Fase Strategi

Strategi dengan perubahan rezim (misalnya strategi dengan mekanisme hukuman permanen atau semi-permanen) dianalisis secara khusus untuk mengukur:

- Waktu deteksi perubahan fase,
- Lonjakan error pasca transisi,
- Dampak kesalahan awal terhadap trajektori jangka menengah.

Analisis ini bertujuan untuk mengidentifikasi apakah model mampu menangkap dinamika non-stasioner dan apakah pembobotan ROC mempengaruhi stabilitas prediksi pada fase transisi.

4.10.3 Strategi Deterministik vs Adaptif

Strategi deterministik dan strategi adaptif dianalisis secara terpisah untuk mengukur robustnes model terhadap dinamika yang berbeda.

Perbandingan dilakukan berdasarkan:

- Confusion matrix per kategori strategi,
- Rata-rata NLL,
- Dynamic regret,
- Average payoff.

Hipotesis yang diuji adalah bahwa strategi adaptif menghasilkan degradasi performa yang lebih besar pada skema one-step dibandingkan model multi-step berbobot, khususnya pada horizon lebih panjang.

4.10.4 Pelaporan Hasil

Hasil eksperimen disajikan dalam bentuk tabel komparatif yang memuat:

- Confusion matrix untuk evaluasi terpisah,
- Nilai rata-rata dan standar deviasi NLL,
- Dynamic regret pada horizon $k = 5$ dan $k = 10$,

- Average payoff agent pada evaluasi terpasang.

Selain tabel agregat, analisis per-strategi juga ditampilkan untuk mengidentifikasi pola kegagalan spesifik.

Interpretasi hasil difokuskan pada hubungan antara objektif pelatihan (one-step vs multi-step dengan variasi ROC) dan performa trajektorial aktual dalam interaksi repeated game.

BAB V

JADWAL PENELITIAN

5.1 Jadwal Penelitian

Penelitian ini direncanakan berlangsung selama dua bulan (8 minggu) dengan pembagian tahapan yang terstruktur sesuai dengan fokus utama penelitian, yaitu:

1. Pemodelan lawan yang sepenuhnya terpisah dari sinyal reward (decoupled opponent modelling)
2. Analisis stabilitas prediksi multi-langkah (multi-step forecasting)

Penyusunan jadwal dilakukan berdasarkan dependensi antar komponen sistem, dimulai dari pembangunan lingkungan deterministik, implementasi model prediktif, hingga evaluasi stabilitas dan analisis perencanaan berbasis rollout.

5.1.1 Tahapan Penelitian

Secara umum, tahapan penelitian dibagi menjadi sembilan fase utama sebagai berikut:

1. Perancangan dan Validasi Lingkungan IPD Deterministik

Tahap awal mencakup implementasi lingkungan *Iterated Prisoner's Dilemma* (IPD) dengan konfigurasi:

- Implementasi matriks payoff klasik
- Fixed horizon ($T = 100$)
- Validasi konsistensi reward
- Verifikasi determinisme transisi permainan

Lingkungan dibuat sepenuhnya deterministik untuk mengisolasi analisis pada dinamika model prediktif, tanpa gangguan noise maupun terminasi stokastik.

2. Implementasi Tipe Lawan

Meliputi pembangunan berbagai tipe lawan untuk menguji kapasitas representasi model:

- Fixed mixed strategy
- Tit-for-Tat
- Win-Stay Lose-Shift
- Fictitious Play
- Q-Learning agent

Dilakukan validasi bahwa agen adaptif menunjukkan dinamika non-stasioner dalam episode.

3. Pengumpulan dan Validasi Dataset

Tahap ini mencakup:

- Simulasi 10.000 episode pelatihan
- Simulasi 2.000 episode validasi
- Simulasi 2.000 episode pengujian
- Verifikasi distribusi tipe lawan uniform
- Pemeriksaan pemisahan data pelatihan dan pengujian

Dataset dikumpulkan tanpa memasukkan sinyal reward sebagai target pemodelan, untuk menjaga prinsip decoupling.

4. Implementasi Model Decoupled LSTM

Meliputi:

- Implementasi arsitektur LSTM satu layer (hidden size 64)
- Implementasi linear layer + softmax
- Implementasi scheduled sampling
- Pemisahan eksplisit modul belief dari modul evaluasi reward

Tahap ini memastikan bahwa pembentukan belief tidak bergantung pada utilitas agen.

5. Pelatihan Model Prediktif

Meliputi:

- Pelatihan dengan loss cross-entropy one-step
- Teacher forcing dengan scheduled sampling
- Monitoring validation loss
- Penyimpanan model terbaik

6. Evaluasi Model Prediktif (One-step)

Evaluasi kapasitas lokal model menggunakan:

- Accuracy
- Cross-entropy loss
- Entropy prediktif

Tahap ini memverifikasi kapasitas representasi sebelum analisis multi-langkah dilakukan.

7. Evaluasi Stabilitas Multi-Langkah (Open-loop)

Merupakan tahap inti penelitian.

Meliputi:

- Prediksi rekursif hingga horizon $k = 10$
- Analisis pertumbuhan error terhadap horizon
- Analisis divergensi distribusi prediktif
- Analisis akumulasi error akibat self-conditioning

Tahap ini menguji apakah representasi laten stabil dalam prediksi jangka panjang.

8. Implementasi dan Evaluasi Rollout Planning

Meliputi:

- Implementasi estimator nilai aksi $\hat{Q}$
- Integrasi prediksi multi-step dalam Monte Carlo rollout
- Analisis sensitivitas terhadap horizon k
- Analisis stabilitas estimasi nilai terhadap jumlah simulasi n

Fokus utama adalah mengevaluasi dampak kualitas forecasting terhadap kualitas perencanaan.

9. Evaluasi Closed-loop dan Studi Ablasi

Tahap akhir meliputi:

- Simulasi episode penuh
- Evaluasi reward rata-rata
- Perbandingan dengan baseline greedy one-step
- Ablasi tanpa scheduled sampling
- Ablasi horizon $k = 1$

Tahap ini mengukur kontribusi nyata multi-step forecasting terhadap performa agen.

5.1.2 Rencana Waktu Pelaksanaan

Rencana waktu pelaksanaan penelitian selama enam bulan ditunjukkan pada Tabel berikut.

Tabel 5.1 Rencana Jadwal Penelitian (2 Bulan / 8 Minggu)

Kegiatan	M1	M2	M3	M4	M5	M6	M7	M8
Spesifikasi lingkungan IPD	✓	✓						
Desain Populasi Strategi Lawan	✓	✓						
Prosedur simulasi dan generasi data		✓	✓					
Representasi dan persiapan dataset			✓	✓				
Perancangan model prediksi (arsitektur)			✓	✓				
Implementasi protokol pelatihan satu langkah				✓	✓			
Implementasi pelatihan multi langkah (k=5,10 + ROC)					✓	✓		
Evaluasi terpisah (Confusion Matrix, NLL, CE)						✓		
Evaluasi terpasang (Multi-step, Regret, Reward)						✓	✓	
Analisis eksperimen dan komparasi model							✓	✓
Penulisan dan revisi laporan	✓	✓	✓	✓	✓	✓	✓	✓

5.1.3 Dependensi dan Risiko

Beberapa dependensi penting dalam penelitian ini:

- Implementasi rollout planning bergantung pada stabilitas model prediktif pada evaluasi open-loop.
- Evaluasi closed-loop tidak dapat dilakukan sebelum estimator nilai $\hat{Q}$ tervalidasi.
- Studi ablasi dilakukan setelah konfigurasi utama sistem stabil.

Risiko utama penelitian meliputi:

- Akumulasi error prediksi pada horizon panjang
- Kompleksitas komputasi akibat $\mathcal{O}(N \cdot n \cdot k \cdot M)$
- Ketidakstabilan model pada lawan non-stasioner

Strategi mitigasi meliputi pengujian bertahap (offline $\rightarrow$ open-loop $\rightarrow$ closed-loop), monitoring konvergensi estimator, serta pembatasan parameter eksperimen untuk menjaga efisiensi komputasi.

BAB VI

KESIMPULAN DAN SARAN

Penelitian ini mengkaji potensi ketidaksesuaian antara formulasi prediksi satu-langkah dalam *opponent modelling* dan kebutuhan perencanaan strategis multi-langkah dalam permainan berulang seperti *Iterated Prisoner's Dilemma*. Melalui implementasi modul prediksi yang difokuskan pada *k-step forecasting*, penelitian ini mengevaluasi bagaimana horizon prediksi memengaruhi akurasi estimasi distribusi aksi lawan serta dinamika kesalahan prediksi antar-langkah.

Hasil eksperimen menunjukkan bahwa perluasan horizon prediksi memberikan representasi yang lebih informatif terhadap pola strategi lawan yang bergantung pada beberapa langkah interaksi, meskipun tetap terdapat trade-off dalam bentuk peningkatan kompleksitas dan potensi propagasi kesalahan. Temuan ini mengindikasikan bahwa pemilihan objektif pembelajaran dalam *opponent modelling* perlu mempertimbangkan keselarasan dengan horizon perencanaan strategis yang digunakan agen.

Secara keseluruhan, penelitian ini memberikan dasar eksperimental untuk memahami peran horizon prediksi dalam interaksi strategis berulang, tanpa melakukan asumsi terhadap struktur internal atau parametrik dari algoritma lawan.

DAFTAR PUSTAKA

- Axelrod, R. dan Hamilton, W. D. (1981), *The Evolution of Cooperation*,
- Barron, F. H. dan Barrett, B. E. (1996), Decision quality using ranked attribute weights, *Management Science* 42.11, pp. 1515–1523.
- Bonanno, G., 2024, *Game theory: volume 1: basic concepts*, Kindle Direct Publishing, Place of publication not identified.
- De Weerd, H., Verbrugge, R., dan Verheij, B. (Oct. 2022), Higher-order theory of mind is especially useful in unpredictable negotiations, *Autonomous Agents and Multi-Agent Systems* 36.2, p. 30.
- Di, C., Zhou, Q., Shen, J., Wang, J., Zhou, R., dan Wang, T. (2023), The coupling effect between the environment and strategies drives the emergence of group cooperation, *Chaos, Solitons & Fractals* 176, p. 114138.
- Elhamer, Z., Suzuki, R., dan Arita, T. (2020), The effects of population size and information update rates on the emergent patterns of cooperative clusters in a large-scale social particle swarm model, *Artificial Life and Robotics* 25.1, Type: Article, pp. 149–158.
- Freire, I. T., Arsiwalla, X. D., Puigbò, J. Y., dan Verschure, P. (2023), Modeling Theory of Mind in Dyadic Games Using Adaptive Feedback Control, *Information (Switzerland)* 14.8, Type: Article.
- Gómez, A. L. d. A., Sierra, C., dan Sabater-Mir, J. (2025), Grounded predictions of teamwork as a one-shot game: A multiagent multi-armed bandits approach, *Artificial Intelligence* 341, p. 104307.
- Hernandez-Leal, P., Kartal, B., dan Taylor, M. E. (Nov. 2019), A Survey and Critique of Multiagent Deep Reinforcement Learning, *Autonomous Agents and Multi-Agent Systems* 33.6, pp. 750–797.
- Hochreiter, S. dan Schmidhuber, J. (Nov. 1, 1997), Long Short-Term Memory, *Neural Computation* 9.8, pp. 1735–1780.
- Hu, Y., Han, C., Li, H., dan Guo, T. (2023), Modeling opponent learning in multiagent repeated games, *Applied Intelligence* 53.13, Type: Article, pp. 17194–17210.

- Jin, Y., Wei, S., dan Montana, G. (Aug. 2025), Achieving collective welfare in multi-agent reinforcement learning via suggestion sharing, *Machine Learning* 114.8, p. 190.
- Lamb, A. M., Goyal, A., Zhang, Y., Zhang, S., Courville, A. C., dan Bengio, Y. (2016), Professor Forcing: A New Algorithm for Training Recurrent Networks, *Advances in Neural Information Processing Systems*.
- Li, K., Huang, W., Li, C., dan Deng, X. (2025), Exploiting a No-Regret Opponent in Repeated Zero-Sum Games, *Journal of Shanghai Jiaotong University (Science)* 30.2, Type: Article, pp. 385–398.
- Lv, M., Liu, J., Guo, B., Ding, Y., Zhang, Y., dan Yu, Z. (Sept. 2023), Inducing Coordination in Multi-Agent Repeated Game through Hierarchical Gifting Policies, *2023 IEEE 20th International Conference on Mobile Ad Hoc and Smart Systems (MASS)*, 2023 IEEE 20th International Conference on Mobile Ad Hoc and Smart Systems (MASS), ISSN: 2155-6814, pp. 279–287.
- Nashed, S. B. dan Zilberstein, S. (2022), A Survey on Opponent Modeling in Adversarial Domains,
- Nisan, N., Roughgarden, T., Tardos, É., dan Vazirani, V. V., eds. (2008), *Algorithmic game theory*, Repr., [Nachdr.], Cambridge: Cambridge Univ. Press, 754 pp.
- Perera, I., Nijs, F. de, dan Garcia, J. (2025), Learning to cooperate against ensembles of diverse opponents, *Neural Computing and Applications* 37.23, Type: Article, pp. 18835–18849.
- Qiao, X., Han, C., dan Guo, T. (Dec. 2024), O2M: Online Opponent Modeling in Online General-Sum Matrix Games, *2024 4th International Conference on Artificial Intelligence, Robotics, and Communication (ICAIRC)*, 2024 4th International Conference on Artificial Intelligence, Robotics, and Communication (ICAIRC), pp. 358–361.
- Shoham, Y. (2009), Multiagent Systems: Algorithmic, Game-Theoretic, and Logical Foundations,
- Stillwell, W. G., Seaver, D. A., dan Edwards, W. (1981), Preference modeling with ordinal data, *Organizational Behavior and Human Performance* 28.1, pp. 62–81.

- Wang, W., Wang, Y., Hao, J., dan Taylor, M. E. (2019), Achieving cooperation through deep multiagent reinforcement learning in sequential prisoner's dilemmas, *ACM International Conference Proceeding Series*, Type: Conference paper.
- Zhu, L., Zhu, Y., dan Xia, C. (May 2025), Evolutionary Dynamics of Cooperation and Extortion on Networks With Fitness-Dependent Rules, *2025 Joint International Conference on Automation-Intelligence-Safety (ICAIS) & International Symposium on Autonomous Systems (ISAS)*, 2025 Joint International Conference on Automation-Intelligence-Safety (ICAIS) & International Symposium on Autonomous Systems (ISAS), ISSN: 2996-3850, pp. 1–6.

LAMPIRAN