


USULAN PENELITIAN TUGAS AKHIR S1

**PEMODELAN LAWAN BERBASIS FORECASTING MULTI-LANGKAH
YANG TERPISAH DARI OPTIMISASI REWARD PADA ITERATED
PRISONER'S DILEMMA**

***MULTI-STEP FORECASTING-BASED OPPONENT MODELLING
DECOUPLED FROM REWARD OPTIMIZATION IN THE ITERATED
PRISONER'S DILEMMA***



Faqih Mahardika
21/482551/PA/21039

**PROGRAM STUDI ILMU KOMPUTER
DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA**

2026

DAFTAR ISI

HALAMAN SAMPUL	i
DAFTAR ISI	ii
DAFTAR TABEL	iv
DAFTAR GAMBAR	v
INTISARI	vi
ABSTRACT	vii
I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Batasan Penelitian	3
1.4 Tujuan Penelitian	3
1.5 Manfaat Penelitian	4
1.6 Sistematika Penelitian	4
II TINJAUAN PUSTAKA	5
2.1 Pendekatan metodologis dalam pemodelan lawan untuk <i>Repeated Games</i>	6
2.2 Efektivitas strategi pemodelan lawan dievaluasi dalam <i>Repeated Games</i>	7
2.3 Celah Penelitian	10
III LANDASAN TEORI	13
3.1 Game Theory	13
3.1.1 Dilema Sosial	13
3.1.2 Prisoner's Dilemma	13
3.2 Pemodelan Lawan	14
3.3 Long Short-Term Memory (LSTM)	14
3.3.1 Forget Gate	16
3.3.2 Input Gate	17
3.3.3 Candidate Cell State	17

3.3.4	Cell State (Memori Jangka Panjang)	17
3.3.5	Output Gate	18
3.4	Prediksi Multi-Langkah	18
3.4.1	Peramalan Rekursif	19
3.5	Metriks Loss dan Evaluasi	19
3.5.1	Cross-Entropy	19
3.5.2	Negative Log-Likelihood	20
3.5.3	Confusion Matrix	21
3.5.4	Rank Order Centroid (ROC)	22
IV	ANALISIS DAN PERANCANGAN	24
4.1	Deskripsi Umum	24
4.2	Formulasi Masalah	24
4.3	Rancangan Algoritma Metode	25
4.3.1	Gambaran Umum	25
4.3.2	Spesifikasi Lingkungan Simulasi IPD	26
4.3.3	Desain Populasi Strategi Lawan	27
4.3.4	Prosedur dan Simulasi Generasi Data	27
4.3.5	Representasi dan Persiapan Dataset	28
4.3.6	Perancangan Model Prediksi Lawan	29
4.3.7	Protokol Pelatihan	31
4.3.8	Protokol Validasi	33
4.3.9	Protokol Evaluasi	35
4.3.10	Analisis Eksperimen	36
V	JADWAL PENELITIAN	37
5.1	Jadwal Penelitian	37
	DAFTAR PUSTAKA	38
	LAMPIRAN	41

DAFTAR TABEL

2.1	Lingkungan evaluasi dan metrik dalam penelitian	9
2.2	Ringkasan Penelitian Terkait	11
3.1	Payoff Matrix Prisoner's Dilemma	13
5.1	Rencana Jadwal Penelitian (2 Bulan / 8 Minggu)	37

DAFTAR GAMBAR

3.1	Finite Automata untuk strategi IPD Reiter 2014	15
3.2	Diagram LSTM.	16
4.1	Diagram metodologi.	24
4.2	Rancangan Algoritma Metode.	26

INTISARI

Pemodelan Lawan Berbasis Forecasting Multi-Langkah yang Terpisah dari Optimisasi Reward pada Iterated Prisoner's Dilemma

Oleh

Faqih Mahardika

21/482551/PA/21039

Pendekatan pemodelan lawan dalam permainan berulang umumnya diformulasikan sebagai prediksi satu-langkah terhadap aksi lawan, meskipun interaksi strategis berlangsung dalam horizon yang panjang dan bersifat sekuensial. Kondisi ini berpotensi menimbulkan ketidaksesuaian antara objektif pembelajaran model lawan dan kebutuhan perencanaan multi-langkah agen.

Penelitian ini mengkaji peran horizon prediksi dalam konteks *Iterated Prisoner's Dilemma* dengan mengimplementasikan modul pemodelan lawan berbasis *h-step forecasting* yang dilatih menggunakan kesalahan prediksi distribusi aksi teramati. Analisis difokuskan pada akurasi prediksi multi-langkah serta implikasinya terhadap interaksi strategis jangka pendek.

Hasil eksperimen diharapkan menunjukkan bahwa perluasan horizon prediksi dapat memberikan representasi yang lebih kaya terhadap pola strategi lawan yang bergantung pada trajectory interaksi. Diharapkan ini menyoroti pentingnya mempertimbangkan keselarasan antara objektif prediksi dan horizon perencanaan dalam perancangan sistem pemodelan lawan untuk permainan berulang.

ABSTRACT

Multi-Step Forecasting-Based Opponent Modelling Decoupled from Reward Optimization in the Iterated Prisoner's Dilemma

By

Faqih Mahardika

21/482551/PA/21039

Opponent modelling in repeated games is commonly formulated as a one-step prediction problem, despite the fact that strategic interactions unfold over long and sequential horizons. This formulation may introduce a mismatch between the learning objective of the opponent model and the multi-step planning requirements of the agent.

This study investigates the role of prediction horizon in the context of the Iterated Prisoner's Dilemma by implementing a k -step forecasting module trained using prediction loss over observed action distributions. The analysis focuses on multi-step prediction accuracy and its implications for short-term strategic interaction.

Experimental results hypothetically indicate that extending the prediction horizon can provide a more informative representation of opponent strategies that depend on interaction trajectories, although it introduces trade-offs in terms of learning stability and model complexity. These findings will highlight the importance of aligning prediction objectives with planning horizons in the design of opponent modelling frameworks for repeated strategic settings.

BAB I

PENDAHULUAN

1.1 Latar Belakang

Interaksi strategis antar individu merupakan komponen penting dalam berbagai proses pengambilan keputusan kolektif, terutama pada sistem sosial, ekonomi, dan kebijakan publik. Dalam banyak situasi, hasil yang diperoleh oleh suatu pihak tidak hanya ditentukan oleh keputusan yang diambil sendiri, tetapi juga oleh keputusan pihak lain yang berinteraksi dalam sistem yang sama. Kerangka *game theory* telah lama digunakan untuk menganalisis fenomena tersebut dan memberikan pemahaman formal mengenai bagaimana keputusan rasional individu dapat menghasilkan dinamika kolektif tertentu.

Beberapa fenomena kebijakan publik menunjukkan bahwa hasil dari interaksi strategis sering kali tidak bersifat intuitif. Contohnya adalah *tragedy of the commons*, yaitu situasi di mana individu secara rasional mengeksploitasi sumber daya bersama sehingga pada akhirnya merugikan seluruh kelompok (Hardin 1968). Fenomena lain adalah *Braess paradox*, di mana penambahan infrastruktur jalan justru dapat memperburuk kemacetan karena setiap pengguna memilih rute yang secara individual paling menguntungkan (Roughgarden 2005). Contoh-contoh tersebut menunjukkan bahwa keputusan rasional pada tingkat individu dapat menghasilkan hasil kolektif yang tidak optimal apabila interaksi strategis antar pihak tidak diperhitungkan secara tepat.

Dalam konteks komputasional, permasalahan interaksi strategis juga muncul pada bidang *multi-agent reinforcement learning* (MARL), di mana beberapa agen belajar secara simultan dalam lingkungan yang sama. Berbeda dengan pembelajaran penguatan pada agen tunggal, dalam lingkungan multi-agen setiap agen tidak hanya beradaptasi terhadap lingkungan statis, tetapi juga terhadap agen lain yang turut belajar dan mengubah strateginya. Interaksi ini membentuk dinamika pembelajaran yang bersifat non-stasioner dan berlangsung dalam mekanisme *closed-loop*, di mana keputusan yang diambil oleh suatu agen memengaruhi perilaku agen lain yang kemudian kembali memengaruhi keputusan agen tersebut pada langkah berikutnya (Hernandez-Leal et al. 2019).

Salah satu kerangka klasik yang sering digunakan untuk mempelajari dinamika interaksi strategis berulang adalah *Iterated Prisoner's Dilemma* (IPD) (Axelrod

dan Hamilton 1981). Dalam permainan ini, dua agen berinteraksi secara berulang dengan memilih antara aksi kooperatif atau defektif pada setiap putaran. Berbeda dengan permainan satu langkah, strategi dalam IPD tidak hanya ditentukan oleh aksi saat ini, tetapi juga oleh pola respons terhadap sejarah interaksi sebelumnya. Strategi seperti *Tit-for-Tat* dan berbagai variasinya menunjukkan bahwa perilaku kooperatif dapat muncul melalui mekanisme respons timbal balik yang berlangsung dalam beberapa langkah interaksi.

Dalam literatur pemodelan lawan (*opponent modeling*), pendekatan yang umum digunakan adalah prediksi aksi lawan satu langkah ke depan (*one-step prediction*). Model dilatih untuk meminimalkan kesalahan prediksi terhadap aksi lawan pada langkah berikutnya. Pendekatan ini selaras dengan formulasi standar dalam *supervised learning*, di mana model dioptimalkan untuk memprediksi target pada langkah selanjutnya berdasarkan observasi historis (Nashed dan Zilberstein 2022). Namun dalam interaksi yang bersifat *closed-loop*, prediksi yang dihasilkan model tidak hanya berfungsi sebagai estimasi pasif terhadap perilaku lawan, tetapi juga memengaruhi keputusan agen yang menggunakan prediksi tersebut untuk menentukan tindakannya.

Akibatnya, keputusan yang diambil berdasarkan prediksi tersebut dapat memengaruhi respons lawan pada langkah berikutnya dan membentuk trajektori interaksi secara keseluruhan. Dalam konteks permainan berulang, keputusan optimal sering kali bergantung pada konsekuensi strategis yang terjadi dalam beberapa langkah ke depan. Strategi tertentu mungkin tampak tidak optimal secara satu langkah, tetapi menghasilkan keuntungan strategis apabila dilihat dalam beberapa langkah interaksi.

Selain dalam konteks teori permainan klasik, kemampuan untuk memodelkan dan memprediksi strategi lawan juga memiliki implikasi praktis dalam berbagai sistem interaktif modern. Contohnya meliputi permainan strategis berbasis komputer, sistem negosiasi otomatis, serta simulasi ekonomi komputasional di mana agen perlu mengantisipasi respons pihak lain dalam beberapa langkah ke depan (Albrecht et al. 2024). Dalam konteks tersebut, representasi perilaku lawan yang mampu menangkap pola respons jangka pendek menjadi penting untuk mendukung proses perencanaan keputusan yang lebih adaptif.

Berdasarkan kondisi tersebut, muncul kebutuhan untuk menganalisis hubungan antara horizon prediksi dan kualitas pengambilan keputusan dalam permainan berulang. Secara khusus, penting untuk mengevaluasi apakah prediksi beberapa langkah jangka pendek (*h-step forecasting*) dapat memberikan representasi strategi lawan yang lebih sesuai dengan kebutuhan perencanaan dibandingkan pendekatan prediksi

satu langkah yang umum digunakan dalam literatur.

1.2 Rumusan Masalah

Pendekatan pemodelan lawan dalam permainan berulang umumnya diformulasikan sebagai prediksi satu langkah (*one-step prediction*) yang dioptimalkan berdasarkan kesalahan prediksi jangka pendek. Formulasi ini berfokus pada akurasi prediksi lokal tanpa secara eksplisit mempertimbangkan kebutuhan perencanaan strategis dalam horizon beberapa langkah interaksi.

Ketidaksesuaian antara objektif prediksi satu langkah dan kebutuhan perencanaan strategis tersebut menimbulkan potensi bahwa model lawan tidak merepresentasikan dinamika strategi secara memadai, sehingga interaksi yang dihasilkan berpotensi berkembang menuju ekuilibrium yang suboptimal.

1.3 Batasan Penelitian

Agar ruang lingkup penelitian tetap terfokus dan implementasi eksperimental dapat dikendalikan, penelitian ini dibatasi pada beberapa aspek berikut:

1. Lingkungan permainan yang digunakan adalah *Iterated Prisoner's Dilemma* (IPD) klasik dengan struktur *payoff* standar dan horizon permainan yang tetap.
2. Lawan yang dimodelkan dibatasi pada strategi deterministik yang dapat direpresentasikan sebagai *finite state machine*.
3. Penelitian tidak merancang mekanisme eksplorasi strategi baru maupun proses pembelajaran kebijakan agen, melainkan berfokus pada pemodelan dan prediksi perilaku lawan.
4. Interaksi antar agen dianalisis dalam skenario *closed-loop*, di mana keputusan agen dan lawan saling memengaruhi sepanjang trajektori permainan.

1.4 Tujuan Penelitian

Penelitian ini bertujuan untuk mengembangkan pendekatan peramalan trajektori aksi lawan dalam interaksi *closed-loop* pada permainan berulang melalui pemodelan lawan, serta menganalisis peran horizon prediksi dalam merepresentasikan dinamika strategi pada lingkungan *Iterated Prisoner's Dilemma*.

1.5 Manfaat Penelitian

Manfaat yang diharapkan dari penelitian ini adalah sebagai berikut:

1. Memberikan pemahaman eksperimental mengenai peran horizon prediksi dalam pemodelan lawan pada interaksi strategis berulang.
2. Menyediakan pendekatan peramalan trajektori aksi lawan dalam skenario interaksi *closed-loop* pada lingkungan *Iterated Prisoner's Dilemma*.
3. Menyediakan kerangka simulasi yang dapat digunakan untuk mengevaluasi hubungan antara kualitas prediksi trajektori dan dinamika interaksi dalam permainan berulang.

1.6 Sistematika Penelitian

Sistematika penulisan penelitian ini disusun dalam beberapa bab untuk memudahkan pemahaman terhadap alur penelitian yang dilakukan. Bab I merupakan pendahuluan yang memuat latar belakang penelitian, rumusan masalah, batasan penelitian, tujuan penelitian, manfaat penelitian, serta sistematika penulisan. Bab II berisi tinjauan pustaka yang mengkaji berbagai literatur terkait topik penelitian, khususnya mengenai pemodelan lawan, *Iterated Prisoner's Dilemma*, serta pendekatan pembelajaran dalam lingkungan interaksi berulang.

Bab III memuat landasan teori yang digunakan dalam penelitian, meliputi formulasi masalah secara formal, definisi konsep yang digunakan seperti *belief* dan *forecasting loss*, serta gambaran umum arsitektur pendekatan yang digunakan. Bab IV menjelaskan metode penelitian yang meliputi desain eksperimen, algoritma yang digunakan dalam pemodelan dan prediksi, serta prosedur evaluasi yang diterapkan untuk menilai kinerja model. Bab V memaparkan jadwal pelaksanaan penelitian dalam bentuk *Gantt chart*.

BAB II

TINJAUAN PUSTAKA

Bagian ini mensintesis temuan utama dari studi yang ditinjau dengan tujuan mengidentifikasi pola asumsi perilaku lawan serta implikasinya terhadap desain metodologis pemodelan lawan dalam *repeated games*. Sintesis difokuskan pada dimensi perilaku yang dapat diamati dari riwayat interaksi, alih-alih pada asumsi internal seperti struktur optimisasi reward atau arsitektur pembelajaran yang digunakan.

Pendekatan ini penting karena dalam banyak karya terdahulu, pemodelan perilaku lawan sering kali tidak dipisahkan secara konseptual dari proses optimisasi kebijakan agen. Akibatnya, representasi perilaku lawan terenkapsulasi di dalam parameter kebijakan atau fungsi nilai, sehingga sulit untuk mengevaluasi kualitas prediksi perilaku secara independen dari reward yang dicapai. Untuk mengidentifikasi celah tersebut secara sistematis, tinjauan ini mengabstraksikan asumsi perilaku lawan pada tingkat eksternal yang dapat diinferensi dari *interaction traces*.

Tabel 2.2 merangkum berbagai pendekatan dalam *opponent modelling* dan pembelajaran multi-agen pada interaksi strategis berulang. Pendekatan berbasis pemodelan eksplisit terhadap lawan ditunjukkan oleh Online Opponent Modeling (O2M) yang dilaporkan mampu beradaptasi lebih baik dan memperoleh reward rata-rata lebih tinggi dibandingkan baseline (Qiao et al. 2024). Dalam konteks dinamika evolusioner, strategi Zero Determinant menunjukkan proporsi kerja sama akhir yang lebih tinggi dibandingkan strategi Extort, mengindikasikan peran signifikan dinamika populasi dalam membentuk hasil kolektif (L. Zhu et al. 2025).

Pendekatan berbasis pembelajaran mendalam juga menunjukkan kemampuan adaptif terhadap dinamika lawan. Hierarchical Gifting DQN mampu mendeteksi perubahan strategi secara real-time dan menyesuaikan insentif kerja sama secara dinamis (Lv et al. 2023). Model berbasis LSTM dilaporkan dapat mengaproksimasi dinamika no-regret secara akurat dan mengeksploitasi lawan secara menguntungkan pada tingkat non-stasioneritas rendah (Li et al. 2025). Selain itu, pendekatan Deep Multiagent Reinforcement Learning pada Social Prisoner's Dilemma mampu mencapai kerja sama mutual dan beradaptasi terhadap perubahan strategi lawan (Wang et al. 2019).

Beberapa studi menekankan pentingnya struktur interaksi dan kopling dinamika. Environment-Strategy Coupling Model menunjukkan bahwa kopling antara

umpan balik lingkungan dan dinamika strategi meningkatkan stabilitas kerja sama kelompok (Di et al. 2023), sementara Extended Social Particle Swarm Model memperlihatkan bahwa ukuran populasi dan laju pembaruan informasi memengaruhi pola kerja sama yang muncul (Elhamer et al. 2020). Pendekatan Teamwork Game dengan MA-MAB bahkan mampu mereproduksi pola perilaku mirip manusia seperti *social loafing* dan *compensation* (Gómez et al. 2025).

Dalam konteks pemodelan internal dan kesadaran pembelajaran, Internal Model dilaporkan mencapai konvergensi lebih cepat dibanding TD-learning standar, meskipun performanya menurun ketika perilaku lawan bergantung langsung pada aksi agen (Freire et al. 2023). Symmetric Learning Awareness (SLA) meningkatkan stabilitas keseimbangan dan mengurangi siklikitas pada metode gradien standar melalui pemodelan eksplisit terhadap proses pembelajaran lawan (Hu et al. 2023). Pendekatan Higher-order Theory of Mind (ToM k) menunjukkan bahwa peningkatan level ToM memberikan pengaruh signifikan hingga tingkat tertentu, dengan *diminishing returns* setelah ToM-3 (De Weerd et al. 2022). Sementara itu, mekanisme Suggestion Sharing meningkatkan kerja sama dibandingkan skema berbagi nilai atau kebijakan (Jin et al. 2025), dan pendekatan Ensemble-Training Cooperative Agent menunjukkan peningkatan robustnes dan generalisasi meskipun dengan biaya komputasi yang lebih tinggi (Perera et al. 2025).

Secara keseluruhan, literatur menunjukkan keberagaman pendekatan dalam memodelkan dan merespons dinamika perilaku lawan, baik melalui pembelajaran eksplisit, mekanisme kopling lingkungan, maupun adaptasi berbasis populasi.

2.1 Pendekatan metodologis dalam pemodelan lawan untuk *Repeated Games*

Pendekatan-pendekatan dalam pemodelan lawan dapat dibedakan berdasarkan apakah adaptasi terhadap lawan ditangani secara eksplisit atau implisit. Paradigma pemodelan lawan yang eksplisit, seperti *gradient-based opponent shaping* Qiao et al. 2024; Hu et al. 2023; Wang et al. 2019, *recursive belief reasoning* Freire et al. 2023; De Weerd et al. 2022, serta identifikasi sistem Li et al. 2025 secara langsung membangun representasi internal perilaku lawan untuk memprediksi atau memengaruhi respons lawan di masa depan. Sebaliknya, pendekatan implisit, termasuk *reactive reinforcement learning* Lv et al. 2023, *population-based training* Perera et al. 2025, dinamika evolusioner L. Zhu et al. 2025; Di et al. 2023; Elhamer et al. 2020, dan *bandit-based learning-in-games* Gómez et al. 2025, beradaptasi terhadap lawan tan-

pa mempertahankan model perilaku lawan yang terpisah.

Meskipun demikian, baik pendekatan eksplisit maupun implisit pada umumnya merumuskan dan mengevaluasi adaptasi terhadap lawan hanya pada tingkat respons satu langkah (*one-step interaction*), tanpa melakukan pemodelan atau evaluasi eksplisit terhadap konsekuensi perilaku lawan dalam horizon multi-langkah.

Kebanyakan Pendekatan yang memperlakukan perilaku lawan sebagai proses sekuensial yang dapat dipelajari, serta dievaluasi berdasarkan kualitas prediksi terhadap lintasan aksi di masa depan, bukan semata-mata berdasarkan payoff agregat jangka panjang. Pendekatan semacam ini secara alami menekankan pentingnya *forecasting* multi-langkah dalam menghadapi dinamika interaksi berulang, terutama ketika keputusan pada fase awal interaksi memiliki implikasi strategis terhadap lintasan berikutnya.

Pendekatan berbasis model sekuensial memori seperti *Long Short-Term Memory* (LSTM) menawarkan alternatif metodologis yang berbeda. LSTM dapat dipandang sebagai pendekatan yang memodelkan perilaku lawan sebagai proses dinamis berbasis riwayat interaksi. Model LSTM dilatih untuk meminimalkan kesalahan prediksi perilaku lawan tanpa melibatkan sinyal reward agen. Dengan demikian, kualitas model lawan dapat dievaluasi secara independen menggunakan metrik prediksi sekuensial, sebelum diintegrasikan ke dalam proses pengambilan keputusan.

Struktur rekuren pada LSTM memungkinkan forecast multi-langkah (*multi-step forecasting*) terhadap aksi lawan memanfaatkan skema prediksi rekursif atau *rolling horizon*. Kemampuan ini relevan dalam *repeated games*, di mana keputusan optimal agen sering kali bergantung pada ekspektasi terhadap respons lawan tidak hanya pada langkah berikutnya, tetapi juga pada beberapa langkah interaksi selanjutnya. Dengan menyediakan estimasi lintasan perilaku lawan pada horizon terbatas, agen dapat melakukan evaluasi strategi secara lebih prospektif dibandingkan pendekatan satu-langkah.

2.2 Efektivitas strategi pemodelan lawan dievaluasi dalam *Repeated Games*

Praktik evaluasi secara implisit mendefinisikan apa yang dianggap sebagai keberhasilan dalam interaksi multi-agent yang adaptif, baik dalam bentuk hasil kerja sama, ketahanan terhadap eksploitasi, stabilitas perilaku, maupun akurasi prediksi. Tabel 2.1 merangkum lingkungan evaluasi dan metrik yang digunakan dalam penelitian-penelitian terdahulu, dengan tujuan mengidentifikasi pola evaluasi yang berulang ser-

ta aspek-aspek yang relatif terabaikan.

Berbagai penelitian terdahulu mengevaluasi pendekatan pemodelan lawan dalam lingkungan eksperimen dan metrik evaluasi yang beragam. Evaluasi dalam pengaturan *self-play* simetris dilakukan dengan menilai kesalahan prediksi selama pelatihan *offline*, seperti *mean squared error* (MSE), serta kualitas representasi memori laten (Qiao et al. 2024). Dalam konteks dinamika evolusioner pada jaringan *scale-free* dengan strategi *zero-determinant*, kinerja model dianalisis melalui frekuensi kerja sama dan tingkat eksploitasi antar agen (L. Zhu et al. 2025). Pendekatan *reactive reinforcement learning* dalam interaksi berulang juga dievaluasi terhadap lawan adaptif dengan menggunakan rata-rata nilai *reward* sebagai indikator utama performa (Lv et al. 2023).

Beberapa penelitian lain menggunakan lingkungan simulasi yang lebih spesifik untuk menilai dinamika koordinasi antar agen. Dalam simulator *teamwork-game*, performa dievaluasi melalui produktivitas tim agregat, konvergensi menuju *Nash equilibrium*, serta kontribusi individu dalam tim (Gómez et al. 2025). Pada studi dinamika evolusioner dalam permainan berulang dan ruang strategi kontinu, evaluasi sering dilakukan melalui metrik seperti tingkat kerja sama, fraksi kooperator dalam populasi, serta stabilitas kluster strategi (Di et al. 2023; Elhamer et al. 2020). Pendekatan berbasis populasi pada *repeated matrix games* juga dianalisis menggunakan populasi sintesis dengan fokus pada payoff rata-rata, *robustness*, dan kemampuan generalisasi terhadap berbagai tipe lawan (Perera et al. 2025).

Galat prediksi perilaku lawan dan payoff kumulatif yang diperoleh agen dalam Permainan *repeated zero-sum* sering digunakan sebagai indikator evaluasi (Li et al. 2025). Studi lain pada *repeated matrix games* menilai efektivitas model melalui indikator seperti akurasi prediksi, payoff rata-rata, stabilitas strategi, serta kecepatan konvergensi selama interaksi berulang (Freire et al. 2023; Hu et al. 2023). Selain itu, beberapa penelitian mengembangkan lingkungan eksperimen khusus, seperti lingkungan SPD dua dimensi dengan metrik reward rata-rata dan kesejahteraan sosial (Wang et al. 2019), serta benchmark MARL dengan indikator return ternormalisasi dan konvergensi pembelajaran (Jin et al. 2025). Simulasi negosiasi berbasis permainan *Colored Trails* juga digunakan untuk mengevaluasi performa agen melalui skor individu dan kesejahteraan sosial kolektif (De Weerd et al. 2022).

Secara keseluruhan, variasi lingkungan eksperimen dan metrik evaluasi tersebut menunjukkan bahwa sebagian besar penelitian menilai performa pemodelan lawan melalui indikator seperti payoff, konvergensi strategi, atau tingkat kerja sama.

Namun demikian, pengukuran eksplisit terhadap kualitas peramalan trajektori perilaku lawan dalam horizon multi-langkah masih relatif terbatas dalam literatur yang ada.

Tabel 2.1 Lingkungan evaluasi dan metrik dalam penelitian

Referensi	Lingkungan Evaluasi	Metrik
Qiao et al. 2024	Self-play simetris	MSE selama pelatihan offline; akurasi memori laten
L. Zhu et al. 2025	Jaringan scale-free dengan strategi zero-determinant	Frekuensi kerja sama (C) dan eksploitasi (E)
Lv et al. 2023	Opponent adaptif (dirata-ratakan pada beberapa opponent)	Nilai reward
Gómez et al. 2025	Simulator teamwork-game khusus	Produktivitas tim agregat; konvergensi ke Nash equilibrium; kontribusi individu
Di et al. 2023	Simulator evolutionary game	Tingkat kerja sama; fraksi kooperator
Perera et al. 2025	Repeated matrix games dengan populasi sintetis	Payoff rata-rata; robustness; generalisasi
Li et al. 2025	Repeated zero-sum games	Galat prediksi; payoff kumulatif
Freire et al. 2023	Repeated matrix games	Efektivitas; stabilitas; akurasi prediksi
Hu et al. 2023	Simulasi repeated matrix game	Payoff rata-rata; kecepatan konvergensi
Elhamer et al. 2020	Simulasi continuous-space	Tingkat kerja sama; stabilitas klaster
Wang et al. 2019	Lingkungan SPD 2D khusus	Reward rata-rata; kesejahteraan sosial
Jin et al. 2025	Benchmark MARL	Return ternormalisasi; konvergensi
De Weerd et al. 2022	Simulasi Colored Trails	Skor agen; kesejahteraan sosial

Sebagaimana terlihat pada Tabel 2.1, mayoritas studi mengevaluasi efektivitas pemodelan lawan melalui metrik kinerja agregat jangka panjang, seperti payoff rata-rata,

tingkat kerja sama, stabilitas, serta konvergensi menuju equilibrium. Evaluasi semacam ini menilai keberhasilan berdasarkan hasil akhir interaksi, tanpa secara eksplisit mengkaji bagaimana kualitas prediksi perilaku lawan pada berbagai horizon mempengaruhi proses pengambilan keputusan strategis.

Sebagian besar pendekatan yang melibatkan komponen prediktif melaporkan kinerja berdasarkan galat satu langkah (*one-step prediction error*). Meskipun metrik ini relevan untuk mengukur konsistensi lokal model terhadap data historis, ia tidak secara langsung mencerminkan kebutuhan perencanaan dalam *repeated games*. Permainan berulang seperti IPD, keputusan pada suatu langkah mempengaruhi respons lawan pada langkah-langkah berikutnya, sehingga pengambilan keputusan bersifat intrinsik multi-langkah.

Ketergantungan pada objektif prediksi satu langkah berpotensi menimbulkan ketidaksesuaian antara objektif statistik dan objektif strategis. Model yang dioptimalkan untuk meminimalkan galat satu langkah belum tentu menghasilkan estimasi lintasan perilaku lawan yang stabil ketika digunakan untuk perencanaan lintas-horizon. Dalam skema *recursive forecasting*, kesalahan prediksi awal dapat terpropagasi dan mempengaruhi estimasi payoff kumulatif secara non-linear. Namun demikian, literatur yang ada jarang menguji secara eksplisit bagaimana kualitas prediksi multi-langkah berhubungan dengan performa strategis agen.

2.3 Celah Penelitian

Belum banyak studi yang secara sistematis membandingkan implikasi penggunaan prediksi satu langkah, *recursive multi-step forecasting*, dan *direct multi-step forecasting* terhadap payoff strategis. Analisis mengenai keberadaan horizon prediksi optimal (h^*) yang memberikan trade-off terbaik antara stabilitas prediksi dan manfaat strategis juga masih terbatas.

Berdasarkan sintesis tersebut, terdapat celah penelitian yang signifikan, yaitu belum adanya analisis sistematis mengenai ketidaksesuaian antara objektif prediksi satu langkah dan kebutuhan perencanaan strategis multi-langkah dalam *repeated games*. Secara khusus, hubungan antara akurasi prediksi lintas-horizon, propagasi kesalahan dalam skema rekursif, dan dampaknya terhadap payoff strategis belum dievaluasi secara terintegrasi dan terkontrol.

Penelitian ini berangkat dari celah tersebut dengan memfokuskan analisis pada evaluasi kinerja prediksi multi-langkah serta implikasinya terhadap pengambilan

Tabel 2.2 Ringkasan Penelitian Terkait

Ref	Nama Model	Temuan Utama
Qiao et al. 2024	Online Opponent Modeling (O2M)	O2M mampu beradaptasi lebih baik dan memperoleh rata-rata reward lebih tinggi dibandingkan baseline.
L. Zhu et al. 2025	Zero Determinant Strategy under Evolutionary Dynamic	Proporsi akhir kerja sama melebihi strategi Extort, menunjukkan keunggulan dinamika evolusioner.
Lv et al. 2023	Hierarchical Gifting DQN	Mendeteksi perubahan strategi lawan secara real-time dan dinamis menyesuaikan insentif kerja sama.
Gómez et al. 2025	Teamwork Game + MA-MAB	Mereproduksi pola mirip manusia (social loafing, compensation).
Di et al. 2023	Environment-Strategy Coupling Model	Kopling antara umpan balik lingkungan dan dinamika strategi secara signifikan meningkatkan stabilitas kerja sama kelompok.
Perera et al. 2025	Ensemble-Training Cooperative Agent	Robust dan memiliki generalisasi lebih baik namun biaya komputasi lebih tinggi dan potensi estimasi reward intrinsik sub-optimal.
Li et al. 2025	LSTM-Strategy	RNN mampu mengaproksimasi dinamika no-regret yang halus secara akurat serta memungkinkan eksploitasi yang menguntungkan pada tingkat non-stasioneritas rendah.
Freire et al. 2023	Internal Model	Konvergensi lebih cepat dan stabil dibanding TD-learning standar; performa menurun ketika perilaku lawan bergantung pada aksi agen sendiri (misalnya Tit-for-Tat).
Hu et al. 2023	Symmetric Learning Awareness (SLA)	Keseimbangan yang lebih stabil dan menghindari perilaku siklik pada metode gradien standar; pemodelan eksplisit meningkatkan konvergensi.
Elhamer et al. 2020	Extended Social Particle Swarm (SPS) Model	Ukuran populasi dan laju pembaruan informasi membentuk pola kerja sama dinamis dan beragam.
Wang et al. 2019	Deep Multiagent Reinforcement Learning (untuk SPD)	Mencapai kerja sama mutual; adaptif terhadap perubahan strategi lawan.
Jin et al. 2025	Suggestion Sharing (SS)	Meningkatkan kerja sama dibanding value sharing dan policy sharing.
De Weerd et al. 2022	Higher-order Theory of Mind (ToM k , $k \geq 2$)	ToM tingkat tinggi berpengaruh signifikan; <i>diminishing returns</i> setelah ToM-3.

keputusan strategis dalam IPD, tanpa memosisikan arsitektur model sebagai kontribusi utama, melainkan sebagai instrumen untuk mengisolasi efek horizon peramalan.

BAB III

LANDASAN TEORI

3.1 Game Theory

3.1.1 Dilema Sosial

Dilema sosial merupakan situasi di mana keputusan rasional secara individual menghasilkan luaran yang tidak optimal secara kolektif (Axelrod dan Hamilton 1981). Secara formal, kondisi ini dapat dinyatakan sebagai adanya konflik antara rasionalitas individu dan optimalitas sosial.

Teori permainan memberikan kerangka formal yang memodelkan pemain, strategi, dan payoff secara terstruktur (Bonanno 2024), dalam bentuk normal didefinisikan sebagai $G = (N, A, U)$ dengan N himpunan pemain, $A = A_1 \times A_2$ himpunan profil strategi atau *Action space*, dan $U = (u_1, u_2)$ fungsi payoff atau *utility*. Setiap pemain $i \in N$ memilih strategi $a_i \in A_i$ untuk memaksimalkan payoff $u_i(a_i, a_{-i})$, di mana a_{-i} adalah profil strategi lawan. Strategi yang dipilih oleh pemain lain mempengaruhi payoff yang diterima, sehingga interaksi ini bersifat strategis. Dalam konteks ini, konsep keseimbangan Nash menjadi penting untuk memahami hasil yang mungkin terjadi ketika setiap pemain bertindak secara rasional dengan mempertimbangkan strategi lawan. *Nash Equilibrium* adalah profil strategi a^* yang memenuhi $u_i(a_i^*, a_{-i}^*) \geq u_i(a_i, a_{-i}^*) \quad \forall a_i \in A_i$. Menunjukkan pilihan aksi selain a_i^* tidak dapat memberikan keuntungan lebih besar dari strategi keseimbangan. Kerangka ini memungkinkan analisis rasionalitas strategis dalam interaksi statik. Namun, model bentuk normal bersifat satu tahap dan mengasumsikan struktur payoff tetap.

3.1.2 Prisoner's Dilemma

Prisoner's Dilemma merepresentasikan konflik rasionalitas individu dan kolektif secara eksplisit (Axelrod dan Hamilton 1981). Aksi yang dapat dipilih adalah *Cooperate* (C) atau *Defect* (D). Struktur payoff Prisoner's Dilemma diberikan oleh:

Tabel 3.1 Payoff Matrix Prisoner's Dilemma

	C	D
C	(R, R)	(S, T)
D	(T, S)	(P, P)

Dengan R (Reward) adalah payoff jika kedua pemain bekerja sama, T (Temptation) adalah payoff bagi pemain yang berkhianat sementara yang lain bekerja sama, S (Sucker's payoff) adalah payoff bagi pemain yang bekerja sama sementara yang lain berkhianat, dan P (Punishment) adalah payoff jika kedua pemain berkhianat. dengan ketidaksamaan $T > R > P > S$ dan $2R > T + S$ Dalam permainan satu tahap, strategi dominan adalah defeksi (D), sehingga keseimbangan Nash berada pada (D, D) meskipun (C, C) lebih optimal secara kolektif. Namun, interaksi nyata jarang terjadi hanya satu kali.

Prisoner's Dilemma Berulang Permainan PD diperluas menjadi bentuk berulang disebut Iterated Prisoner's Dilemma (IPD), permainan diulang selama T atau *Turn* tahap dengan payoff kumulatif atau terdiskonto. Dalam IPD, strategi dapat bergantung pada histori interaksi, memungkinkan untuk pembalasan dan kerja sama yang berkelanjutan. IPD relevan untuk mempelajari dinamika manusia seperti pembentukan hubungan, konflik berkepanjangan, siklus saling membalas, dan pemulihan kepercayaan.

Beberapa strategi terkenal dalam IPD meliputi *Tit-for-Tat*: Mulai dengan bekerja sama, kemudian meniru aksi lawan pada langkah sebelumnya. *Cooperator*: Selalu bekerja sama. *Defector*: Selalu berkhianat. *Random*: Memilih secara acak antara bekerja sama dan berkhianat. beberapa algoritma tersebut dapat dipahami melalui gambar 3.1 finite state machine.


3.2 Pemodelan Lawan

Pemodelan lawan memungkinkan untuk mempelajari perilaku ataupun strategi lawan (Shoham 2009). Diberikan riwayat interaksi penuh $h_t = ((a_i^1, a_{-i}^1), \dots, (a_i^t, a_{-i}^t))$ model parametrik f_θ mempelajari distribusi kondisional $p_\theta(a_{t+1}^{-i} | h_t)$. Meskipun pendekatan regresi linear sederhana mampu memodelkan hubungan statik, namun memiliki keterbatasan dalam menangkap dependensi temporal dan pola nonlinier (Hochreiter dan Schmidhuber 1997).

3.3 Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM) merupakan pengembangan dari Recurrent Neural Network (RNN) yang dirancang untuk menangkap dependensi jangka panjang


Gambar 3.1 Finite Automata untuk strategi IPD Reiter 2014



melalui mekanisme memori eksplisit (Hochreiter dan Schmidhuber 1997). Dalam konteks pemodelan lawan, LSTM digunakan untuk membangun representasi laten terhadap strategi lawan berdasarkan histori interaksi.

Diberikan input x_t (observasi pada waktu t , misalnya aksi lawan), hidden state sebelumnya h_{t-1} (representasi laten sebelumnya), dan parameter bobot W , U , serta bias b , setiap komponen LSTM bekerja secara berurutan dengan ilustrasi gambar 3.2.

Gambar 3.2 Diagram LSTM.



3.3.1 Forget Gate

Forget gate mengontrol sejauh mana informasi pada state memori sebelumnya dipertahankan atau diabaikan pada waktu t (Hochreiter dan Schmidhuber 1997). Secara formal, nilai gerbang pelupaan f_t dihitung melalui fungsi aktivasi sigmoid terhadap kombinasi linear antara input saat ini x_t , hidden state sebelumnya h_{t-1} , serta bias b_f . Parameter W_f dan U_f masing-masing merepresentasikan matriks bobot yang memetakan input dan hidden state ke ruang gerbang. Karena fungsi sigmoid menghasilkan keluaran pada rentang $(0, 1)$, setiap elemen dalam f_t berperan sebagai koefisien penskalaan yang mengatur proporsi informasi dari cell state sebelumnya yang akan dipertahankan. Nilai yang mendekati 1 menunjukkan bahwa informasi tersebut dipertahankan hampir sepenuhnya, sedangkan nilai yang mendekati 0 menyebabkan

informasi tersebut dilupakan. Dengan demikian, forget gate memungkinkan model menyesuaikan horizon memori secara adaptif, sehingga dependensi temporal jangka panjang dapat dipertahankan atau dihapus sesuai kebutuhan dinamika data.

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f) \quad (3.1)$$

3.3.2 Input Gate

Input $x_t \in \mathbb{R}^d$ merepresentasikan observasi saat ini, sedangkan $h_{t-1} \in \mathbb{R}^h$ adalah ringkasan historis interaksi sebelumnya (Hochreiter dan Schmidhuber 1997). Namun, tidak semua informasi baru relevan atau stabil untuk memperbarui kepercayaan terhadap strategi lawan. Oleh karena itu, input gate $i_t \in [0, 1]^h$ mengontrol seberapa besar setiap dimensi informasi baru akan diterima ke dalam memori, dengan $\sigma(\cdot)$ sebagai fungsi sigmoid dan W_i, U_i, b_i sebagai parameter yang dipelajari.

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i) \quad (3.2)$$

3.3.3 Candidate Cell State

Informasi mentah dari x_t tidak langsung disimpan karena dapat mengandung noise atau pola sementara yang belum representatif (Hochreiter dan Schmidhuber 1997). Namun, model tetap membutuhkan representasi kandidat dari informasi baru tersebut. Oleh karena itu, $\tilde{c}_t \in [-1, 1]^h$ dibentuk melalui transformasi non-linear $\tanh(\cdot)$ sebagai kandidat memori baru, dengan parameter W_c, U_c, b_c .

$$\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c) \quad (3.3)$$

3.3.4 Cell State (Memori Jangka Panjang)

Cell state $c_t \in \mathbb{R}^h$ merupakan jalur utama propagasi informasi jangka panjang dalam LSTM (Hochreiter dan Schmidhuber 1997) yang berfungsi sebagai *latent kepercayaan representation* terhadap strategi lawan. Namun, memori ini harus mampu menjaga stabilitas sekaligus tetap adaptif terhadap informasi baru. Oleh karena itu, pembaruannya dirumuskan sebagai:

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \quad (3.4)$$

Operator $\odot$ menyatakan perkalian elemen-per-elemen. Komponen $f_t \odot c_{t-1}$ mempertahankan informasi lama yang masih relevan, sedangkan $i_t \odot \tilde{c}_t$ menambahkan informasi baru secara selektif. Struktur aditif ini penting karena menjaga stabilitas gradien dan memungkinkan pembelajaran dependensi jangka panjang.

3.3.5 Output Gate

Meskipun c_t menyimpan informasi lengkap, tidak seluruhnya relevan untuk prediksi saat ini. Namun, model perlu mengekstrak bagian informasi yang paling informatif untuk pengambilan keputusan (Hochreiter dan Schmidhuber 1997). Oleh karena itu, output gate $o_t \in [0, 1]^h$ mengontrol seberapa besar informasi dari cell state akan diekspos ke hidden state, dengan parameter W_o, U_o, b_o .

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o) \quad (3.5)$$

Pada persamaan di 3.5, $x_t \in \mathbb{R}^d$ menyatakan vektor input pada waktu t dengan dimensi fitur d , sedangkan $h_{t-1} \in \mathbb{R}^h$ adalah hidden state pada waktu sebelumnya dengan dimensi laten h . Matriks bobot $W_o \in \mathbb{R}^{h \times d}$ memetakan input ke ruang gerbang keluaran, dan $U_o \in \mathbb{R}^{h \times h}$ memetakan hidden state sebelumnya ke ruang yang sama. Vektor bias $b_o \in \mathbb{R}^h$ memungkinkan pergeseran affine dalam transformasi linear tersebut. Fungsi aktivasi sigmoid $\sigma(\cdot)$ diterapkan secara elemen-per-elemen sehingga menghasilkan $o_t \in (0, 1)^h$, yaitu vektor koefisien yang mengatur proporsi informasi dari cell state c_t yang akan diekspos ke hidden state saat ini. Dengan demikian, output gate berperan sebagai mekanisme penyaringan adaptif yang menentukan komponen representasi memori internal yang relevan untuk menghasilkan representasi laten h_t dan prediksi pada waktu t .

3.4 Prediksi Multi-Langkah

Model LSTM menghasilkan distribusi prediktif satu langkah ke depan $p(a_{t+1}^{-i} | h_t)$. Namun, dalam permainan berulang, nilai suatu aksi tidak hanya ditentukan oleh respons lawan pada tahap berikutnya, melainkan oleh konsekuensi jangka panjang sepanjang lintasan interaksi (Nashed dan Zilberstein 2022).

3.4.1 Peramalan Rekursif

Untuk memperoleh estimasi lintasan masa depan sepanjang horizon tetap H , model perilaku lawan digunakan secara autoregresif. Pada setiap langkah ke- h , prediksi aksi lawan dihasilkan dari distribusi $\hat{a}_{t+h}^{-i} \sim p_\theta(\cdot \mid \hat{H}_{t+h-1})$, $h = 1, \dots, H$ dengan t menyatakan waktu keputusan saat ini, sedangkan $H \in \mathbb{N}$ adalah horizon prediksi tetap yang menentukan panjang lintasan masa depan yang dipertimbangkan. Indeks h merepresentasikan langkah prediksi ke- h relatif terhadap waktu t . Simbol $\hat{a}_{t+h}^{-i}$ menyatakan aksi lawan yang diprediksi pada waktu $t + h$, dengan superskrip $-i$ menunjukkan pemain lawan terhadap agen i . Distribusi prediktif $p_\theta(\cdot \mid \hat{H}_{t+h-1})$ merupakan model parametrik dengan parameter θ yang mengaproksimasi probabilitas aksi lawan bersyarat pada riwayat yang tersedia. Notasi $\hat{H}_{t+h-1}$ menyatakan riwayat interaksi yang telah diperluas secara rekursif hingga waktu $t + h - 1$, termasuk aksi-aksi yang sebelumnya diprediksi atau direalisasikan selama proses rollout. Proses ini menghasilkan distribusi atas lintasan aksi sepanjang horizon terbatas $\hat{\tau}_t^{(H)} = \{\hat{a}_{t+1}^{-i}, \hat{a}_{t+2}^{-i}, \dots, \hat{a}_{t+H}^{-i}\}$. Lintasan prediksi sepanjang horizon H dinotasikan sebagai $\hat{\tau}_t^{(H)}$, yaitu himpunan berurutan dari aksi lawan yang diproyeksikan mulai dari $t + 1$ hingga $t + H$.

3.5 Metriks Loss dan Evaluasi

3.5.1 Cross-Entropy

Fungsi objektif cross-entropy digunakan untuk mengukur perbedaan antara distribusi prediksi model P_θ dan distribusi aktual dari aksi lawan P_{actual} pada setiap langkah prediksi (**goodfellow_deep_2016**). Cross-entropy didefinisikan sebagai persamaan 3.6.

$$\mathcal{L}_{\text{CE}} = - \sum_a P_{\text{actual}}(a) \log P_\theta(a \mid h_t) \quad (3.6)$$

dengan a merepresentasikan aksi lawan yang mungkin terjadi, $P_{\text{actual}}(a)$ adalah distribusi aktual (biasanya berupa distribusi one-hot yang menunjukkan aksi yang benar-benar terjadi), dan $P_\theta(a \mid h_t)$ adalah distribusi prediksi model berdasarkan riwayat interaksi h_t . Fungsi objektif ini memberikan penalti yang lebih besar ketika model memberikan probabilitas rendah terhadap aksi aktual, sehingga mendorong model untuk meningkatkan kepercayaan pada aksi yang benar-benar terjadi. Cross-entropy merupakan metrik yang umum digunakan dalam klasifikasi probabilistik karena si-

fatnya yang konsisten dan diferensiabel, memungkinkan optimisasi parameter model melalui algoritma seperti gradient descent.

3.5.2 Negative Log-Likelihood

Untuk mengevaluasi kualitas prediksi sekuensial lawan dalam horizon multi-step, digunakan metrik *Negative Log-Likelihood* (NLL) sebagai proper scoring rule yang konsisten terhadap estimasi distribusi probabilistik (D. Zhu et al. 2018). Misalkan pada waktu t tersedia riwayat interaksi $h_t = \{(a_i^1, a_{-i}^1), \dots, (a_i^t, a_{-i}^t)\}$. Model pemodelan lawan menghasilkan distribusi probabilitas atas aksi lawan pada langkah berikutnya, yang dinotasikan sebagai $P_\theta(a_{-i}^{t+1} | h_t)$ dengan θ merepresentasikan parameter model (misalnya parameter LSTM). Untuk prediksi multi-step sepanjang horizon H , model digunakan secara autoregresif, sehingga distribusi pada langkah ke- k bergantung pada riwayat yang telah diperluas hingga waktu tersebut. Secara umum, probabilitas gabungan untuk urutan aksi aktual lawan $a_{-i}^{t+1:t+H}$ diberikan oleh:

$$P_\theta(a_{-i}^{t+1:t+H} | h_t) = \prod_{k=1}^H P_\theta(a_{-i}^{t+k} | \hat{h}_{t+k-1}) \quad (3.7)$$

dengan a_{-i}^{t+k} sebagai aksi aktual lawan pada waktu $t+k$, $\hat{h}_{t+k-1}$ sebagai riwayat yang digunakan model pada langkah ke- k , yang terdiri dari riwayat asli h_t yang diperluas secara rekursif menggunakan observasi aktual hingga waktu $t+k-1$, H sebagai panjang horizon prediksi multi-step. Negative Log-Likelihood untuk satu segmen horizon sepanjang H kemudian didefinisikan sebagai persamaan 3.8.

$$\mathcal{L}_{\text{NLL}}^{(H)} = - \sum_{k=1}^H \log P_\theta(a_{-i}^{t+k} | \hat{h}_{t+k-1}) \quad (3.8)$$

Nilai NLL yang lebih kecil menunjukkan bahwa model memberikan probabilitas yang lebih tinggi terhadap aksi aktual yang benar-benar terjadi. Karena NLL merupakan *proper scoring rule*, metrik ini tidak hanya mengevaluasi ketepatan klasifikasi, tetapi juga kualitas kalibrasi probabilitas yang dihasilkan model.

Penggunaan NLL multi-step memungkinkan pengukuran efek *compounding error* akibat prediksi rekursif. Jika distribusi prediksi menjadi semakin bias pada horizon yang lebih panjang, maka akumulasi log-loss akan meningkat secara signifikan, mencerminkan degradasi kualitas kepercayaan seiring waktu.

3.5.3 Confusion Matrix

Untuk menganalisis performa prediksi multi-step secara lebih granular, digunakan matriks kebingungan (*confusion matrix*) yang diperluas untuk setiap langkah prediksi dalam horizon H . Matriks ini memberikan informasi mengenai frekuensi prediksi benar dan salah untuk setiap kelas aksi lawan pada setiap langkah prediksi ke- k . Dengan demikian, evaluasi tidak hanya melihat akurasi agregat model, tetapi juga memungkinkan analisis terhadap jenis kesalahan prediksi yang terjadi pada setiap langkah horizon.

Dalam konteks klasifikasi biner pada permainan *Iterated Prisoner's Dilemma*, aksi lawan direpresentasikan sebagai dua kelas, yaitu kerja sama (C) dan defeksi (D). Berdasarkan hasil prediksi model dan aksi aktual lawan, setiap prediksi dapat dikategorikan menjadi empat kemungkinan, yaitu *true positive* (TP), *true negative* (TN), *false positive* (FP), dan *false negative* (FN). Nilai-nilai ini kemudian digunakan untuk menghitung beberapa metrik evaluasi klasifikasi.

Accuracy Accuracy mengukur proporsi prediksi yang benar terhadap seluruh prediksi yang dilakukan. Metrik ini memberikan gambaran umum mengenai tingkat ketepatan model dalam memprediksi aksi lawan.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.9)$$

Precision Precision mengukur proporsi prediksi positif yang benar terhadap seluruh prediksi yang diklasifikasikan sebagai positif oleh model. Dalam konteks ini, precision menunjukkan seberapa sering prediksi suatu aksi (misalnya kerja sama) benar ketika model memprediksi aksi tersebut.

$$Precision = \frac{TP}{TP + FP} \quad (3.10)$$

Recall Recall mengukur kemampuan model dalam mengidentifikasi seluruh kejadian positif yang sebenarnya. Metrik ini menunjukkan seberapa besar proporsi aksi positif yang berhasil diprediksi dengan benar oleh model.

$$Recall = \frac{TP}{TP + FN} \quad (3.11)$$

F1-Score F1-Score merupakan rata-rata harmonik dari precision dan recall. Metrik ini digunakan untuk memberikan keseimbangan antara kedua ukuran tersebut, terutama ketika distribusi kelas tidak seimbang.

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (3.12)$$

Dalam penelitian ini, metrik-metrik tersebut dihitung untuk setiap langkah prediksi ke- h dalam panjang permainan T , sehingga memungkinkan analisis terhadap perubahan performa model seiring dengan bertambahnya jarak prediksi.

3.5.4 Rank Order Centroid (ROC)

Metode *Rank Order Centroid* (ROC) merupakan teknik pembobotan dalam *multi-criteria decision making* (MCDM) yang digunakan ketika hanya informasi peringkat (ranking) kriteria yang tersedia, tanpa nilai bobot numerik eksplisit. Metode ini diperkenalkan oleh Barron dan Barrett sebagai pendekatan aproksimasi sederhana terhadap bobot yang diperoleh dari metode *swing weighting* atau metode pembobotan berbasis utilitas (Barron dan Barrett 1996). Misalkan terdapat n kriteria yang telah diurutkan berdasarkan tingkat kepentingannya, dengan kriteria peringkat pertama dianggap paling penting. Bobot ROC untuk kriteria ke- i didefinisikan sebagai rata-rata dari kebalikan peringkat mulai dari posisi tersebut hingga peringkat terakhir, yaitu:

$$w_i = \frac{1}{n} \sum_{j=i}^n \frac{1}{j}, \quad \text{untuk } i = 1, 2, \dots, n. \quad (3.13)$$

Dengan demikian, bobot yang dihasilkan memenuhi sifat $w_1 \geq w_2 \geq \dots \geq w_n$, dan $\sum_{i=1}^n w_i = 1$. Pendekatan ini mengasumsikan bahwa seluruh vektor bobot yang konsisten dengan urutan peringkat memiliki peluang yang sama, sehingga bobot ROC merepresentasikan nilai ekspektasi dari distribusi seragam atas seluruh kemungkinan bobot yang memenuhi urutan tersebut (Barron dan Barrett 1996). Keunggulan utama metode ROC adalah kesederhanaannya dan kemampuannya menghasilkan estimasi bobot yang cukup representatif meskipun hanya tersedia informasi ordinal. Beberapa studi menunjukkan bahwa bobot ROC sering kali memberikan performa yang mendekati metode pembobotan yang lebih kompleks, khususnya ketika informasi numerik detail sulit diperoleh (Stillwell et al. 1981). Dalam konteks penelitian ini, metode ROC digunakan untuk memberikan pembobotan berbeda pada prediksi lintasan (trajektori) berdasarkan urutan waktu, di mana prediksi pada langkah

awal diberikan bobot lebih besar dibandingkan langkah berikutnya dan sebaliknya.

BAB IV


ANALISIS DAN PERANCANGAN

4.1 Deskripsi Umum

Penelitian ini bertujuan mengembangkan algoritma pembelajaran *online* untuk skenario *Iterated Prisoner's Dilemma* (IPD) dengan lawan yang dapat bersifat adaptif maupun non-stasioner.

Fokus utama penelitian adalah pada pemodelan lawan multi-langkah rekursif. Model prediktif dilatih untuk mengestimasi distribusi aksi lawan berdasarkan riwayat interaksi, tanpa menggunakan informasi reward sebagai sinyal pembelajaran.

Model prediksi tersebut kemudian digunakan sebagai komponen dalam simulasi *multi-step Monte Carlo rollout* untuk mengestimasi nilai aksi agen.



Gambar 4.1 Diagram metodologi.

4.2 Formulasi Masalah

Penelitian ini mempertimbangkan skenario *Iterated Prisoner's Dilemma* (IPD) dengan horizon tetap T .

Pada setiap langkah waktu $t = 1, \dots, T$, agen dan lawan masing-masing memilih aksi $a_t^{agent}, a_t^{opp} \in \{C, D\}$. Reward diperoleh berdasarkan matriks payoff standar IPD. Reward diperoleh berdasarkan matriks payoff standar IPD. Lawan diasumsikan dapat bersifat adaptif maupun non-stasioner, namun algoritma internalnya tidak diketahui. Lawan dapat berupa strategi tetap, strategi reaktif, atau strategi adaptif. Agen tidak memiliki akses terhadap parameter internal, fungsi utilitas, maupun mekanisme pembelajaran lawan. Satu-satunya informasi yang tersedia adalah riwayat interaksi $H_t = \{a_1^{agent}, a_1^{opp}, \dots, a_t^{agent}, a_t^{opp}\}$. Tujuan agen adalah memilih aksi yang

memaksimalkan reward kumulatif selama panjang permainan T , dengan memanfaatkan modul pemodelan lawan yang dilatih secara terpisah dari sinyal reward.

Model pemodelan lawan menghasilkan distribusi prediktif $p(a_{t+1}^{opp} | H_t)$ yang kemudian digunakan dalam simulasi multi-langkah untuk mengestimasi nilai aksi kandidat agen.

4.3 Rancangan Algoritma Metode

4.3.1 Gambaran Umum

Algoritma yang digunakan dalam penelitian ini menggunakan LSTM untuk memprediksi aksi lawan dalam horizon multi-langkah diperlihatkan pada gambar 4.2. Metode dimulai dengan Spesifikasi lingkungan simulasi dengan konfigurasi permainan, antarmuka permainan serta representasi riwayat yang digunakan. Selanjutnya, dilakukan desain populasi strategi lawan yang mencakup berbagai tipe strategi untuk memastikan keberagaman dinamika interaksi. Prosedur simulasi generasi data kemudian dijalankan untuk menghasilkan trajektori interaksi antara agen dan lawan berdasarkan konfigurasi yang telah ditetapkan. Trajektori yang dihasilkan kemudian diproses dalam tahap representasi dan persiapan dataset.

Setelah persiapan data selesai dilakukan perancangan model prediksi lawan menggunakan arsitektur LSTM untuk menangkap dependensi temporal dalam interaksi dilakukan pembentukan komponen LSTM seperti forget gate, input gate, dan output gate. Kemudian Model akan dikembangkan lebih lanjut agar dapat melakukan prediksi multi-langkah menggunakan konsep Monte Carlo Simulation secara recursive.


Selanjutnya model dilatih menggunakan protokol pelatihan yang mencakup pelatihan satu langkah dan pelatihan multi-langkah untuk pelatihan satu langkah akan menggunakan fungsi objektif cross entropy loss satu langkah, sedangkan untuk pelatihan multi-langkah akan menggunakan fungsi objektif Negative-log-likelihood yang merupakan akumulasi cross-entropy sepanjang horizon dengan pembobotan Rank Order Centroid (ROC) di mana langkah terdekat diberi bobot lebih besar dibanding langkah yang lebih jauh dan sebaliknya.

Setelah model dilatih, dilakukan validasi model dengan melakukan hyperparameter tuning untuk memilih konfigurasi terbaik berdasarkan performa trajektorial dengan fungsi objektif yang dimaksimalkan adalah *confusion matrix*.

Setelah model terbaik dipilih, dilakukan pengujian model pada test set untuk

mengukur generalisasi akhir model terhadap distribusi yang tidak terlihat selama pelatihan. Pengujian dilakukan baik pada skenario strategi yang telah terlihat selama pelatihan maupun pada strategi yang sepenuhnya baru, guna menguji kemampuan generalisasi terhadap dinamika interaksi yang tidak dikenal sebelumnya dengan *confusion matrix* sebagai metrik evaluasi.

Kemudian dilakukan interpretasi dan Analisis dari data pengujian yang didapatkan melalui pembelajaran ablasi. Analisis eksperimen difokuskan pada pengujian hipotesis utama penelitian, yaitu adanya potensi misalignment antara objektif prediksi satu langkah dan kebutuhan konsistensi trajektori dalam repeated games.



Gambar 4.2 Rancangan Algoritma Metode.

4.3.2 Spesifikasi Lingkungan Simulasi IPD

Penelitian ini membangun model prediktif aksi lawan pada permainan berulang dan memanfaatkannya untuk estimasi nilai aksi melalui simulasi multi-langkah (*Monte Carlo rollout*).

Konfigurasi Permainan Permainan yang digunakan adalah *Iterated Prisoner's Dilemma* (IPD) dua pemain dengan dua aksi diskrit yang tersedia, yaitu *C* (Cooperate)

dan D (Defect), Struktur payoff mengikuti formulasi klasik Prisoner's Dilemma dengan Nilai numerik yang digunakan sesuai pada 3.1.2 Permainan dijalankan dengan horizon tetap sepanjang $T = 100$ langkah per episode. Penggunaan horizon tetap bertujuan untuk mengisolasi analisis stabilitas prediksi multi-langkah tanpa pengaruh terminasi stokastik. Kemudian diberikan Trembling Hand dengan probabilitas $\epsilon = 0.05$ untuk menghindari trajektori deterministik yang sepenuhnya dapat diprediksi, serta untuk menguji robustnes model terhadap deviasi lokal yang dapat menyebabkan propagasi error pada prediksi multi-langkah.

4.3.3 Desain Populasi Strategi Lawan

Desain populasi strategi lawan dalam penelitian ini bertujuan untuk membentuk lingkungan interaksi yang heterogen, sehingga model prediksi diuji pada spektrum perilaku yang representatif terhadap dinamika Iterated Prisoner's Dilemma (IPD). Landasan konseptual mengenai karakteristik masing-masing strategi telah dijelaskan pada sub-bab 3.1.2, sehingga pada bagian ini difokuskan pada rasionalisasi desain eksperimental dan konfigurasi populasi.

Populasi lawan terdiri atas seluruh strategi pada sub-bab 3.1.2 yang mencakup strategi deterministik berbasis memori (misalnya TFT, Grim Trigger), strategi adaptif berbasis pembelajaran daring (misalnya Hedge, OMD), serta strategi dengan pola siklik (misalnya Cycle). Keberagaman ini dirancang untuk menguji kemampuan model dalam menangkap berbagai dinamika interaksi, termasuk transisi rezim perilaku, pola siklik, dan adaptasi terhadap perubahan strategi lawan.

Setiap strategi dalam populasi diberikan proporsi yang seimbang pada tahap generasi data untuk menghindari bias distribusi kelas. Dalam setiap simulasi, lawan dipilih secara acak dari himpunan strategi dengan probabilitas seragam. Pendekatan ini memastikan bahwa performa model tidak dipengaruhi oleh dominasi strategi tertentu dalam dataset pelatihan maupun pengujian.

4.3.4 Prosedur dan Simulasi Generasi Data

Data penelitian diperoleh melalui simulasi Iterated Prisoner's Dilemma (IPD) menggunakan populasi strategi lawan yang telah didefinisikan pada bagian sebelumnya pada 4.3.3. Prosedur ini bertujuan untuk menghasilkan trajektori interaksi temporal yang dapat digunakan sebagai dasar pembentukan dataset prediksi multi-langkah.

Setiap simulasi dijalankan dalam bentuk episode dengan panjang horizon te-

tap sebesar $T = 100$ langkah waktu. Pada setiap langkah t , agent dan lawan secara simultan memilih aksi $a_t \in \{C, D\}$. Satu episode menghasilkan sekuens interaksi: Setiap interaksi permainan direpresentasikan sebagai sebuah trajektori yang memuat identitas strategi lawan serta sekuens aksi kedua pemain. Misalkan $\mathcal{S}$ adalah himpunan strategi lawan yang digunakan dalam eksperimen. Untuk setiap strategi $s \in \mathcal{S}$, dilakukan simulasi sebanyak R ronde independen.

Keseluruhan dataset didefinisikan dengan himpunan trajektori sebanyak $N = |\mathcal{S}| \times R$ yang mencakup seluruh kombinasi strategi dan ronde simulasi. Untuk setiap tipe strategi lawan, jumlah ronde R ditetapkan konstan guna menjaga keseimbangan distribusi data antar strategi serta memastikan stabilitas variasi trajektori yang diamati.

Untuk menghindari trajektori deterministik yang sepenuhnya dapat diprediksi, diterapkan mekanisme *trembling hand* dengan probabilitas $\epsilon = 0.05$. Pada setiap langkah waktu, baik agent maupun lawan memiliki peluang sebesar 5% untuk secara acak membalik aksi yang dipilih.

Secara formal, jika aksi asli adalah a_t , maka aksi aktual yang dieksekusi $\tilde{a}_t$ didefinisikan sebagai aksi sebaliknya. Penambahan noise ini memiliki dua fungsi utama:

1. Menghindari konvergensi deterministik sempurna pada strategi berbasis memori seperti TFT atau Grim Trigger.
2. Menguji robustnes model terhadap deviasi lokal yang dapat menyebabkan propagasi error pada prediksi multi-langkah.

4.3.5 Representasi dan Persiapan Dataset

Bagian ini menjelaskan bagaimana trajektori hasil simulasi dikonversi menjadi format yang dapat digunakan untuk pelatihan model prediksi.

Representasi Dasar Aksi dan Strategi Lawan Setiap episode interaksi tidak hanya menyimpan histori aksi, tetapi juga identitas strategi lawan dalam bentuk enumerasi diskret.

Misalkan:

$$s^{opp} \in \mathcal{S}_{opp}$$

adalah label strategi lawan, dengan

$$\mathcal{S}_{opp} = \{S_1, S_2, \dots, S_K\}.$$

Pada setiap langkah waktu t , interaksi direpresentasikan sebagai vektor dua dimensi yang memuat aksi agent dan aksi lawan. Untuk kebutuhan komputasional, aksi dikodekan dalam bentuk numerik biner, $C = 0$, $D = 1$. Dengan demikian, setiap trajektori merupakan deret waktu dua kanal (*two-channel time series*) yang memuat histori aksi kedua pemain.

Pengacakan dan Pembagian Data Seluruh sampel yang terbentuk kemudian dia-cak secara acak (*random shuffle*) untuk menghilangkan korelasi urutan antar episode. Setelah proses pengacakan, dataset dibagi menjadi:

1. 70% data pelatihan (*training set*),
2. 15% data validasi (*validation set*),
3. 15% data uji (*test set*).

Pembagian dilakukan pada level trajektori (bukan pada level langkah waktu) untuk mencegah kebocoran informasi temporal antar subset. Dengan demikian, tidak terdapat fragmen dari satu episode yang muncul sekaligus pada data pelatihan dan validasi.

Implikasi terhadap Evaluasi Model Representasi dua kanal, padding awal, dan augmentasi simetri memungkinkan model menangkap dependensi silang antar aksi pemain sejak fase awal permainan.

Pemisahan berbasis trajektori memastikan evaluasi dilakukan pada distribusi interaksi yang benar-benar tidak terlihat selama pelatihan, sehingga mengurangi risiko overfitting berbasis memorisasi pola spesifik episode.

4.3.6 Perancangan Model Prediksi Lawan

Model prediksi lawan dibangun menggunakan arsitektur Long Short-Term Memory (LSTM) sebagai encoder temporal untuk menangkap dependensi historis dalam interaksi IPD. Arsitektur terdiri atas:

1. Satu lapisan LSTM dengan *hidden size* 64,
2. Lapisan linear sebagai proyeksi ke ruang aksi lawan,
3. Fungsi softmax untuk menghasilkan distribusi probabilitas atas aksi $\{C, D\}$.

Model Satu Langkah Model satu langkah dioptimalkan untuk memprediksi aksi lawan pada waktu $t + 1$ berdasarkan histori hingga waktu t .

Fungsi objektif yang digunakan adalah *cross-entropy loss* satu langkah yang didefinisikan pada persamaan 3.6. Optimisasi ini mendorong model memaksimalkan akurasi prediksi lokal tanpa mempertimbangkan konsistensi trajektori jangka panjang.

Model Multi Langkah Berbeda dengan model satu langkah, model multi langkah dirancang untuk mempelajari prediksi trajektori lawan sepanjang horizon k secara eksplisit.

Pada skenario ini, pelatihan dilakukan menggunakan *teacher forcing*. Artinya, pada setiap langkah dalam horizon, input yang diberikan ke LSTM tetap menggunakan aksi aktual (ground-truth), bukan hasil prediksi model.

Untuk setiap histori awal hingga waktu t , model menghasilkan distribusi:

$$(\hat{y}_{t+1}, \hat{y}_{t+2}, \dots, \hat{y}_{t+k}),$$

di mana $\hat{y}_{t+i}$ adalah distribusi prediksi untuk aksi lawan pada langkah ke- i setelah waktu t . dengan input rekursif riwayat interaksi yang diperbarui dengan aksi hasil prediksi pada langkah sebelumnya. Pada konteks ini digunakan agen sesungguhnya secara deterministik dalam simulasi untuk menghasilkan aksi agent yang konsisten terhadap trajektori ground-truth lawan selama proses pelatihan.

Fungsi loss multi langkah didefinisikan sebagai akumulasi cross-entropy sepanjang horizon:

$$\mathcal{L}_{multi-step} = - \sum_{i=1}^k y_{t+i} \log \hat{y}_{t+i}.$$

Dengan formulasi ini, model secara eksplisit dioptimalkan untuk mempertahankan konsistensi prediksi sepanjang beberapa langkah, bukan hanya pada langkah berikutnya.

4.3.7 Protokol Pelatihan

Pelatihan model dilakukan dalam dua skema utama: (1) pelatihan satu langkah dan (2) pelatihan multi langkah. Kedua skema menggunakan arsitektur yang sama, namun berbeda dalam objektif optimisasi dan mekanisme pembentukan loss.

Pelatihan Satu Langkah Pada tahap ini, model dioptimalkan untuk memprediksi aksi lawan pada waktu $t + 1$ berdasarkan histori hingga waktu t .

Fungsi objektif yang digunakan adalah *cross-entropy loss* satu langkah yang didefinisikan pada

Optimisasi dilakukan menggunakan algoritma Adam dengan parameter pembelajaran yang ditetapkan sebelumnya. Pelatihan berlangsung selama sejumlah epoch tertentu dengan *batch size* tetap, serta validasi dilakukan pada setiap epoch untuk memantau konvergensi dan mencegah overfitting.

Model yang dihasilkan merepresentasikan baseline prediksi lokal tanpa optimisasi eksplisit terhadap konsistensi trajektori.

Pelatihan Multi Langkah Pada tahap ini, model dilatih untuk memprediksi trajektori aksi lawan sepanjang horizon k menggunakan mekanisme *teacher forcing*. Selama pelatihan, input pada setiap langkah dalam horizon menggunakan aksi ground-truth (teacher forcing). Namun, untuk membentuk trajektori interaksi dua arah, digunakan agent untuk menghasilkan aksi respon terhadap aksi lawan pada setiap langkah. Dengan demikian, dinamika interaksi tetap konsisten terhadap kebijakan agent yang diasumsikan diketahui.

Fungsi Loss Multi Langkah Loss dasar didefinisikan sebagai akumulasi cross-entropy sepanjang horizon

Skema Pembobotan Rank Order Centroid (ROC) Untuk mengontrol kontribusi error pada tiap langkah, digunakan pembobotan berbasis Rank Order Centroid (ROC) pada sub-bab 3.5.4

Bobot ROC untuk horizon k didefinisikan sebagai:

$$w_i = \frac{1}{k} \sum_{j=i}^k \frac{1}{j},$$

yang kemudian dinormalisasi sehingga:

$$\sum_{i=1}^k w_i = 1.$$

tiga varian pembobotan digunakan:

1. **ROC terbaru:** langkah terdekat ($i = 1$) diberi bobot terbesar.
2. **ROC terlama:** langkah terjauh ($i = k$) diberi bobot terbesar (urutan dibalik).
3. **ROC seragam:** semua langkah diberi bobot yang sama.

Konfigurasi Eksperimen Model dilatih dengan kombinasi berbeda.

1. seragam, $k = 10$,
2. ROC terbaru, $k = 10$
3. ROC terlama, $k = 10$

Seluruh loss dinormalisasi terhadap jumlah langkah horizon agar dapat dibandingkan secara adil antar konfigurasi k .

Evaluasi Closed-Loop Meskipun pelatihan menggunakan teacher forcing, evaluasi dilakukan secara rekursif (*closed-loop rollout*). Pada tahap ini:

1. Model memprediksi aksi lawan pada langkah berikutnya.
2. Agent menghasilkan aksi respon berdasarkan prediksi tersebut.
3. Pasangan aksi hasil prediksi dimasukkan kembali sebagai input.
4. Proses diulang hingga horizon h .

Loss trajektori kemudian dihitung terhadap ground-truth untuk menilai akumulasi error akibat propagasi prediksi sendiri. Pendekatan ini memungkinkan analisis empiris terhadap potensi misalignment antara objektif satu langkah dan kebutuhan prediksi trajektori dalam repeated games.

4.3.8 Protokol Validasi

Validasi dilakukan untuk memilih konfigurasi hiperparameter terbaik berdasarkan performa prediksi trajektorial pada data yang tidak digunakan selama pelatihan. Evaluasi dilakukan pada *validation set* dengan tetap mempertahankan pemisahan berbasis trajektori, sehingga tidak terdapat fragmen episode yang muncul pada data pelatihan. Fokus evaluasi adalah konsistensi prediksi multi-langkah terhadap aksi lawan. Untuk setiap horizon h , dihitung dengan Akurasi kumulatif sepanjang horizon.

Misalkan target horizon adalah h , maka akurasi kumulatif didefinisikan sebagai:

$$Acc_{cum} = \frac{1}{h} \sum_{i=1}^h Acc_i,$$

dengan Acc_i adalah akurasi pada langkah prediksi ke- i . Karena jumlah kombinasi hiperparameter yang diuji cukup besar, proses tuning dilakukan secara hierarkis dalam empat tahap utama:

1. Tuning Stabilitas Optimisasi,
2. Tuning Temporal Modelling,
3. Tuning Kapasitas Model,
4. Tuning Fungsi Loss.

Pada setiap tahap, parameter lain dikunci pada nilai terbaik hasil tahap sebelumnya.

Konfigurasi Dasar Konfigurasi awal (baseline) yang digunakan sebelum tuning adalah sebagai berikut:

1. Steps (horizon) = 10,
2. Window size (*lag*) = 10,
3. Hidden units = 64,
4. Jumlah hidden layer = 1,
5. Dropout = 0.0,

6. Pembobotan ROC = seragam,

7. Epoch = 25.

Pada setiap tahap tuning, hanya parameter yang sedang diuji yang divariasikan, sementara parameter lain dipertahankan pada konfigurasi terbaik sementara.

Tahap 1: Tuning Stabilitas Optimisasi Tahap ini bertujuan memastikan proses pelatihan konvergen secara stabil dan tidak mengalami divergensi gradien.

Parameter yang diuji:

1. Learning Rate $\in \{0.001, 0.0005, 0.0001\}$,
2. Batch Size $\in \{16, 32, 64, 128\}$.

Kriteria pemilihan didasarkan pada stabilitas kurva loss serta akurasi validasi tertinggi.

Tahap 2: Tuning Temporal Modelling Tahap ini mengevaluasi kemampuan model dalam menangkap dependensi temporal.

Parameter yang diuji:

1. Window size (k) $\in \{5, 10, 15\}$,
2. Steps (horizon prediksi) $\in \{1, 5, 10\}$.

Evaluasi difokuskan pada degradasi akurasi sepanjang horizon serta kestabilan prediksi multi-langkah.

Tahap 3: Tuning Kapasitas Model Tahap ini menguji kapasitas representasional model terhadap kompleksitas pola interaksi.

Parameter yang diuji:

1. Hidden units $\in \{32, 64, 128\}$,
2. Jumlah layer $\in \{1, 2\}$,
3. Dropout $\in \{0.0, 0.1, 0.5\}$.

Pemilihan konfigurasi mempertimbangkan trade-off antara performa validasi dan indikasi overfitting.

Tahap 4: Tuning Fungsi Loss dan Skema Pembobotan Tahap terakhir mengevaluasi pengaruh mekanisme pembelajaran sekuensial terhadap kualitas prediksi trajektorial.

Parameter yang diuji:

1. Skema Pembobotan ROC:

- (a) seragam,
- (b) Bobot lebih besar pada langkah awal,
- (c) Bobot lebih besar pada langkah akhir.

Jika h adalah horizon prediksi, maka fungsi loss berbobot didefinisikan sebagai:

$$\mathcal{L} = \sum_{i=1}^h w_i \cdot \mathcal{L}_i, \quad \text{dengan} \quad \sum_{i=1}^h w_i = 1. \quad (4.1)$$

Skema bobot awal menekankan akurasi pada fase pembukaan trajektori, sedangkan skema bobot akhir menekankan stabilitas prediksi jangka panjang. Konfigurasi akhir dipilih berdasarkan performa validasi terbaik sebelum dievaluasi secara final pada *test set*.

4.3.9 Protokol Evaluasi

Evaluasi dilakukan menggunakan prediksi multi langkah secara rekursif (*closed-loop rollout*). Pada skema ini, model: Memprediksi aksi lawan pada langkah berikutnya, kemudian agent menghasilkan respon terhadap prediksi tersebut, kemudian Hasil pasangan aksi dimasukkan kembali sebagai input, kemudian Proses diulang hingga horizon h . Dengan pendekatan ini terbentuk trajektori prediksi sepanjang horizon h yang kemudian dibandingkan dengan trajektori ground-truth.

Metrik evaluasi Akurasi Multi Langkah:

$$\text{Acc}_k = \frac{1}{k} \sum_{i=1}^k \mathbf{1}(\hat{a}_{t+i}^{\text{opp}} = a_{t+i}^{\text{opp}}),$$

Mengukur konsistensi prediksi sepanjang horizon. Metrik-metrik ini menangkap dampak kesalahan prediksi terhadap kualitas interaksi strategis dalam repeated game.

4.3.10 Analisis Eksperimen

Analisis eksperimen difokuskan pada pengujian hipotesis utama penelitian, yaitu adanya potensi misalignment antara objektif prediksi satu langkah dan kebutuhan konsistensi trajektori dalam repeated games.

Sensitivitas terhadap Perubahan Fase Strategi Strategi dengan perubahan rezim (misalnya strategi dengan mekanisme hukuman permanen atau semi-permanen) dianalisis secara khusus untuk mengukur:

- Waktu deteksi perubahan fase,
- Lonjakan error pasca transisi,
- Dampak kesalahan awal terhadap trajektori jangka menengah.

Analisis ini bertujuan untuk mengidentifikasi apakah model mampu menangkap dinamika non-stasioner dan apakah pembobotan ROC mempengaruhi stabilitas prediksi pada fase transisi.

Pelaporan Hasil Hasil eksperimen disajikan dalam bentuk tabel komparatif yang memuat:

- Confusion matrix untuk evaluasi terpisah,
- Nilai rata-rata dan standar deviasi NLL,
- Dynamic regret pada horizon $k = 5$ dan $k = 10$,
- Average payoff agent pada evaluasi terpasang.

Selain tabel agregat, analisis per-strategi juga ditampilkan untuk mengidentifikasi pola kegagalan spesifik.

Interpretasi hasil difokuskan pada hubungan antara objektif pelatihan (one-step vs multi-step dengan variasi ROC) dan performa trajektorial aktual dalam interaksi repeated game.

BAB V

JADWAL PENELITIAN

5.1 Jadwal Penelitian

Penelitian ini direncanakan berlangsung selama dua bulan (8 minggu) dengan pembagian tahapan yang terstruktur. Penyusunan jadwal dilakukan berdasarkan dependensi antar komponen sistem, dimulai dari pembangunan lingkungan deterministik, implementasi model prediktif, hingga evaluasi stabilitas dan analisis perencanaan berbasis rollout. Jadwal rinci disajikan dalam bentuk *Gantt chart* pada Tabel 5.1.

Tabel 5.1 Rencana Jadwal Penelitian (2 Bulan / 8 Minggu)

Kegiatan	M1	M2	M3	M4	M5	M6	M7	M8
Spesifikasi lingkungan IPD	✓	✓						
Desain Populasi Strategi Lawan		✓						
Prosedur simulasi dan generasi data		✓	✓					
Representasi dan persiapan dataset			✓					
Perancangan model prediksi (arsitektur)			✓	✓				
Implementasi protokol pelatihan				✓	✓			
Validasi (Confusion Matrix, NLL, CE)						✓		
Evaluasi (Confusion Matrix, NLL, CE)						✓		
Analisis eksperimen dan komparasi model							✓	✓
Penulisan dan revisi laporan	✓	✓	✓	✓	✓	✓	✓	✓

DAFTAR PUSTAKA

- Albrecht, S. V. et al., 2024, *Autonomous Agents and Multiagent Systems*, MIT Press.
- Axelrod, R. dan Hamilton, W. D. (1981), The Evolution of Cooperation,
- Barron, F. H. dan Barrett, B. E. (1996), Decision quality using ranked attribute weights, *Management Science* 42.11, pp. 1515–1523.
- Bonanno, G., 2024, *Game theory: volume 1: basic concepts*, Kindle Direct Publishing, Place of publication not identified.
- De Weerd, H., Verbrugge, R., dan Verheij, B. (Oct. 2022), Higher-order theory of mind is especially useful in unpredictable negotiations, *Autonomous Agents and Multi-Agent Systems* 36.2, p. 30.
- Di, C., Zhou, Q., Shen, J., Wang, J., Zhou, R., dan Wang, T. (2023), The coupling effect between the environment and strategies drives the emergence of group cooperation, *Chaos, Solitons & Fractals* 176, p. 114138.
- Elhamer, Z., Suzuki, R., dan Arita, T. (2020), The effects of population size and information update rates on the emergent patterns of cooperative clusters in a large-scale social particle swarm model, *Artificial Life and Robotics* 25.1, Type: Article, pp. 149–158.
- Freire, I. T., Arsiwalla, X. D., Puigbò, J. Y., dan Verschure, P. (2023), Modeling Theory of Mind in Dyadic Games Using Adaptive Feedback Control, *Information (Switzerland)* 14.8, Type: Article.
- Gómez, A. L. d. A., Sierra, C., dan Sabater-Mir, J. (2025), Grounded predictions of teamwork as a one-shot game: A multiagent multi-armed bandits approach, *Artificial Intelligence* 341, p. 104307.
- Hardin, G. (1968), The tragedy of the commons, *Science* 162.3859, pp. 1243–1248.
- Hernandez-Leal, P., Kartal, B., dan Taylor, M. E. (Nov. 2019), A Survey and Critique of Multiagent Deep Reinforcement Learning, *Autonomous Agents and Multi-Agent Systems* 33.6, pp. 750–797.
- Hochreiter, S. dan Schmidhuber, J. (Nov. 1, 1997), Long Short-Term Memory, *Neural Computation* 9.8, pp. 1735–1780.

- Hu, Y., Han, C., Li, H., dan Guo, T. (2023), Modeling opponent learning in multiagent repeated games, *Applied Intelligence* 53.13, Type: Article, pp. 17194–17210.
- Jin, Y., Wei, S., dan Montana, G. (Aug. 2025), Achieving collective welfare in multi-agent reinforcement learning via suggestion sharing, *Machine Learning* 114.8, p. 190.
- Li, K., Huang, W., Li, C., dan Deng, X. (2025), Exploiting a No-Regret Opponent in Repeated Zero-Sum Games, *Journal of Shanghai Jiaotong University (Science)* 30.2, Type: Article, pp. 385–398.
- Lv, M., Liu, J., Guo, B., Ding, Y., Zhang, Y., dan Yu, Z. (Sept. 2023), Inducing Coordination in Multi-Agent Repeated Game through Hierarchical Gifting Policies, *2023 IEEE 20th International Conference on Mobile Ad Hoc and Smart Systems (MASS)*, 2023 IEEE 20th International Conference on Mobile Ad Hoc and Smart Systems (MASS), ISSN: 2155-6814, pp. 279–287.
- Nashed, S. B. dan Zilberstein, S. (2022), A Survey on Opponent Modeling in Adversarial Domains,
- Perera, I., Nijs, F. de, dan Garcia, J. (2025), Learning to cooperate against ensembles of diverse opponents, *Neural Computing and Applications* 37.23, Type: Article, pp. 18835–18849.
- Qiao, X., Han, C., dan Guo, T. (Dec. 2024), O2M: Online Opponent Modeling in Online General-Sum Matrix Games, *2024 4th International Conference on Artificial Intelligence, Robotics, and Communication (ICAIRC)*, 2024 4th International Conference on Artificial Intelligence, Robotics, and Communication (ICAIRC), pp. 358–361.
- Reiter, J. (2014), *Deterministic Strategies in the Prisoner's Dilemma*, https://www.researchgate.net/figure/Deterministic-strategies-in-the-Prisoners-Dilemma-Each-automaton-defines-a-different_fig1_259354712, Figure published on ResearchGate. Accessed: 3 March 2026.
- Roughgarden, T., 2005, *Selfish Routing and the Price of Anarchy*, MIT Press.
- Shoham, Y. (2009), *Multiagent Systems: Algorithmic, Game-Theoretic, and Logical Foundations*,

- Stillwell, W. G., Seaver, D. A., dan Edwards, W. (1981), Preference modeling with ordinal data, *Organizational Behavior and Human Performance* 28.1, pp. 62–81.
- Wang, W., Wang, Y., Hao, J., dan Taylor, M. E. (2019), Achieving cooperation through deep multiagent reinforcement learning in sequential prisoner’s dilemmas, *ACM International Conference Proceeding Series*, Type: Conference paper.
- Zhu, D., Yao, H., Jiang, B., dan Yu, P. (Apr. 27, 2018), *Negative Log Likelihood Ratio Loss for Deep Neural Network Classification*.
- Zhu, L., Zhu, Y., dan Xia, C. (May 2025), Evolutionary Dynamics of Cooperation and Extortion on Networks With Fitness-Dependent Rules, *2025 Joint International Conference on Automation-Intelligence-Safety (ICAIS) & International Symposium on Autonomous Systems (ISAS)*, 2025 Joint International Conference on Automation-Intelligence-Safety (ICAIS) & International Symposium on Autonomous Systems (ISAS), ISSN: 2996-3850, pp. 1–6.

LAMPIRAN