


def 6666

USULAN PENELITIAN TUGAS AKHIR S1

**PEMODELAN LAWAN BERBASIS FORECASTING MULTI-LANGKAH
YANG TERPISAH DARI OPTIMISASI REWARD PADA ITERATED
PRISONER'S DILEMMA**

***MULTI-STEP FORECASTING-BASED OPPONENT MODELLING
DECOUPLED FROM REWARD OPTIMIZATION IN THE ITERATED
PRISONER'S DILEMMA***



Faqih Mahardika
21/482551/PA/21039

**PROGRAM STUDI ILMU KOMPUTER
DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA**

2026

DAFTAR ISI

HALAMAN SAMPUL	i
DAFTAR ISI	ii
DAFTAR TABEL	iii
DAFTAR GAMBAR	iv
I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Batasan Penelitian	2
1.4 Tujuan Penelitian	3
1.5 Manfaat Penelitian	3
1.6 Sistematika Penelitian	4
II TINJAUAN PUSTAKA	5
2.1 Asumsi Perilaku Lawan dalam pemodelan lawan untuk <i>Repeated Games</i>	6
2.2 Pendekatan metodologis dalam pemodelan lawan untuk <i>Repeated Games</i>	9
2.3 Bagaimana efektivitas strategi pemodelan lawan dievaluasi dalam <i>Repeated Games</i> ?	11
III LANDASAN TEORI	16
3.1 Dilema Sosial	16
3.2 Game Theory	16
3.3 Prisoner's Dilemma	17
3.4 Prisoner's Dilemma Berulang	17
3.4.1 Horizon Terbatas	19
3.4.2 Definisi Riwayat Interaksi pada mekanisme online	19
3.4.3 Informasi tidak lengkap dan Pembentukan kepercayaan	20
3.5 Pemodelan Lawan	20
3.6 Long Short-Term Memory (LSTM)	21

3.6.1	Forget Gate	22
3.6.2	Input Gate	22
3.6.3	Candidate Cell State	22
3.6.4	Cell State (Memori Jangka Panjang)	23
3.6.5	Output Gate	23
3.6.6	Hidden State Update	24
3.7	Prediksi Multi-Langkah	24
3.7.1	Peramalan Rekursif dan Simulasi Monte Carlo (Horizon Tetap)	24
3.7.2	Teacher Forcing	26
3.7.3	Fungsi Objektif Negative Log-Likelihood	27
3.7.4	Rank Order Centroid (ROC)	28
IV	ANALISIS DAN PERANCANGAN	30
4.1	Deskripsi Umum	30
4.2	Formulasi Masalah	30
4.3	Rancangan Algoritma Metode	31
4.3.1	Gambaran Umum	31
4.3.2	Spesifikasi Lingkungan Simulasi IPD	32
4.3.3	Desain Populasi Strategi Lawan	34
4.3.4	Prosedur dan Simulasi Generasi Data	35
4.3.5	Representasi dan Persiapan Dataset	37
4.3.6	Perancangan Model Prediksi Lawan	40
4.3.7	Protokol Pelatihan	42
4.3.8	Protokol Pelatihan	44
4.3.9	Protokol Validasi	47
4.3.10	Protokol Evaluasi	50
4.3.11	Analisis Eksperimen	51
V	JADWAL PENELITIAN	53
5.1	Jadwal Penelitian	53
5.1.1	Rencana Waktu Pelaksanaan	53
5.1.2	Dependensi dan Risiko	54
VI	KESIMPULAN DAN SARAN	56
	DAFTAR PUSTAKA	57

LAMPIRAN

DAFTAR TABEL

2.1	Asumsi perilaku lawan berdasarkan dependensi perilaku yang dapat diamati.	8
2.2	Klasifikasi Pendekatan Pemodelan Lawan	10
2.3	Lingkungan evaluasi dan metrik dalam penelitian	13
2.4	Ringkasan Penelitian Terkait	14
3.1	Payoff Matrix Prisoner's Dilemma	17
5.1	Rencana Jadwal Penelitian (2 Bulan / 8 Minggu)	54

DAFTAR GAMBAR

3.1	Finite Automata untuk strategi IPD.	18
3.2	Diagram LSTM.	21
4.1	Diagram metodologi.	30
4.2	Rancangan Algoritma Metode.	33
4.3	Trust oleh Ncase 2017.	34

Pendekatan *opponent modelling* dalam permainan berulang umumnya diformulasikan sebagai prediksi satu-langkah terhadap aksi lawan, meskipun interaksi strategis berlangsung dalam horizon yang panjang dan bersifat sekuensial. Kondisi ini berpotensi menimbulkan ketidaksesuaian antara objektif pembelajaran model lawan dan kebutuhan perencanaan multi-langkah agen.

Penelitian ini mengkaji peran horizon prediksi dalam konteks *Iterated Prisoner's Dilemma* dengan mengimplementasikan modul pemodelan lawan berbasis *k-step forecasting* yang dilatih menggunakan kesalahan prediksi distribusi aksi teramati. Analisis difokuskan pada akurasi prediksi multi-langkah, dinamika propagasi kesalahan, serta implikasinya terhadap interaksi strategis jangka pendek.

Hasil eksperimen diharapkan menunjukkan bahwa perluasan horizon prediksi dapat memberikan representasi yang lebih kaya terhadap pola strategi lawan yang bergantung pada trajectory interaksi, meskipun disertai trade-off dalam stabilitas dan kompleksitas pembelajaran. Diharapkan ini menyoroti pentingnya mempertimbangan keselarasan antara objektif prediksi dan horizon perencanaan dalam perancangan sistem *opponent modelling* untuk permainan berulang.

Opponent modelling in repeated games is commonly formulated as a one-step prediction problem, despite the fact that strategic interactions unfold over long and sequential horizons. This formulation may introduce a mismatch between the learning objective of the opponent model and the multi-step planning requirements of the agent.

This study investigates the role of prediction horizon in the context of the Iterated Prisoner’s Dilemma by implementing a k -step forecasting module trained using prediction loss over observed action distributions. The analysis focuses on multi-step prediction accuracy, error propagation across steps, and its implications for short-term strategic interaction.

Experimental results hypothetically indicate that extending the prediction horizon can provide a more informative representation of opponent strategies that depend on interaction trajectories, although it introduces trade-offs in terms of learning stability and model complexity. These findings will highlight the importance of aligning prediction objectives with planning horizons in the design of opponent modelling frameworks for repeated strategic settings.

BAB I

PENDAHULUAN

1.1 Latar Belakang

Interaksi strategis berulang merupakan permasalahan fundamental dalam lingkungan sosial ataupun *multi-agent reinforcement learning* (MARL)(Hernandez-Leal et al. 2019). Dalam lingkungan multi-agen, setiap agen tidak hanya beradaptasi terhadap lingkungan, tetapi juga terhadap agen lain yang turut belajar. Kondisi ini menjadikan dinamika pembelajaran bersifat non-stasioner dan sangat bergantung pada pola interaksi historis.

Iterated Prisoner's Dilemma (IPD) (Axelrod dan Hamilton 1981) merupakan kerangka klasik untuk menganalisis dinamika tersebut. Dalam IPD, strategi tidak hanya ditentukan oleh aksi pada satu langkah, tetapi oleh pola respons yang berkembang sepanjang beberapa putaran. Banyak strategi deterministik maupun adaptif seperti *Tit-for-Tat* dan variasinya memperlihatkan struktur perilaku yang baru terlihat dalam rentang beberapa langkah interaksi.

Dalam literatur *opponent modelling*, pendekatan yang umum digunakan adalah prediksi satu langkah ke depan (*one-step prediction*) (Nashed dan Zilberstein 2022). Model dilatih untuk meminimalkan kesalahan prediksi terhadap aksi lawan pada langkah berikutnya. Meskipun pendekatan ini konsisten dengan formulasi supervised learning standar, terdapat potensi ketidaksesuaian antara objektif pelatihan satu-langkah dan kebutuhan pengambilan keputusan dalam permainan berulang.

Dalam repeated games, keputusan agen pada waktu t tidak hanya bergantung pada distribusi aksi lawan pada waktu $t + 1$, tetapi juga pada konsekuensi strategis dalam beberapa langkah berikutnya (Nashed dan Zilberstein 2022). Strategi tertentu mungkin tidak optimal secara satu-langkah, namun menguntungkan secara multi-langkah. Dengan demikian, akurasi prediksi satu-langkah tidak selalu berbanding lurus dengan kualitas perencanaan strategis.

Berdasarkan kondisi tersebut, terdapat kebutuhan untuk secara sistematis menganalisis hubungan antara horizon prediksi dan kualitas pengambilan keputusan dalam IPD. Secara khusus, penting untuk mengevaluasi apakah prediksi multi-langkah jangka pendek (k -step forecasting) memberikan representasi strategi lawan yang lebih selaras dengan kebutuhan perencanaan dibandingkan prediksi satu-langkah.

1.2 Rumusan Masalah

Dalam permainan berulang seperti *Iterated Prisoner's Dilemma*, interaksi antar-agen secara konseptual dipandang memiliki horizon yang panjang dan keputusan bersifat saling bergantung antar-langkah. Namun, dalam praktik *opponent modelling*, prediksi perilaku lawan sering diformulasikan sebagai prediksi satu-langkah (*one-step prediction*) yang dioptimalkan berdasarkan kesalahan prediksi jangka pendek.

Perbedaan antara horizon interaksi yang bersifat sekuensial dan objektif pembelajaran yang miopik tersebut menunjukkan adanya potensi ketidaksesuaian antara tujuan perencanaan strategis dan mekanisme pembelajaran model lawan. Kondisi ini dapat membatasi representasi pola strategi yang bergantung pada beberapa langkah interaksi serta memengaruhi dinamika adaptasi yang terbentuk selama permainan berlangsung.

1.3 Batasan Penelitian

Agar ruang lingkup penelitian tetap terfokus dan implementasi eksperimental terkendali, penelitian ini dibatasi pada:

1. Lingkungan *Iterated Prisoner's Dilemma* (IPD) dengan struktur payoff standar dan interaksi berulang dalam horizon tetap.
2. Lawan adaptif yang algoritmanya tidak diketahui oleh agen, namun dibatasi pada kelas pembelajaran daring seperti *Hedge*, *Online Mirror Descent*.
3. Analisis difokuskan pada prediksi trajectory aksi lawan dalam horizon terbatas (*k*-step forecasting), tanpa membahas konvergensi jangka panjang atau sifat asimtotik strategi.
4. Penelitian tidak melakukan inferensi terhadap struktur algoritma internal lawan, melainkan memodelkan distribusi aksi berdasarkan observasi historis.
5. Evaluasi difokuskan pada hubungan antara akurasi prediksi multi-langkah, propagasi kesalahan, dan perolehan payoff strategis, tanpa merancang algoritma eksplorasi baru.
6. Aktor yang digunakan dalam model adalah agen dengan strategi *TFT-belief*, di mana pembaruan keputusan dilakukan berdasarkan prediksi perilaku lawan.

tanpa optimisasi eksplisit terhadap fungsi reward. Konfigurasi ini diterapkan baik pada tahap pelatihan maupun evaluasi.

1.4 Tujuan Penelitian

Penelitian ini bertujuan untuk:

1. Menganalisis kesesuaian antara objektif prediksi satu-langkah (*one-step prediction*) dan kebutuhan perencanaan strategis multi-langkah dalam permainan berulang seperti IPD.
2. Mengembangkan dan mengimplementasikan mekanisme prediksi trajectory aksi lawan dalam horizon terbatas (*k*-step forecasting).
3. Mengevaluasi pengaruh panjang horizon prediksi (*k*) terhadap akurasi prediksi, propagasi kesalahan, dan perolehan payoff strategis.
4. Membandingkan pendekatan recursive forecasting dan direct multi-step forecasting dalam konteks stabilitas prediksi dan dampaknya terhadap performa agen.

1.5 Manfaat Penelitian

Manfaat dan kontribusi yang diharapkan dari penelitian ini adalah sebagai berikut:

1. Memberikan analisis konseptual dan empiris mengenai perbedaan antara objektif prediksi satu-langkah (*one-step prediction*) dan prediksi multi-langkah (*multi-step trajectory forecasting*) dalam konteks interaksi strategis berulang.
2. Menyediakan evaluasi sistematis mengenai pengaruh horizon prediksi (*k*) terhadap degradasi akurasi dalam skema open-loop forecasting, termasuk analisis propagasi error sepanjang trajectory.
3. Mengembangkan kerangka evaluasi berbasis likelihood yang memungkinkan perbandingan performa model secara lebih robust dalam lingkungan dengan stochasticity.

4. Menyediakan dasar eksperimental untuk memahami sejauh mana kualitas prediksi trajectory mencerminkan konsistensi dan stabilitas pola perilaku agen dalam repeated games, tanpa mengasumsikan optimalitas strategis.

1.6 Sistematika Penelitian

1. Bab 1: Pendahuluan: Latar belakang, rumusan masalah, batasan, tujuan, manfaat, dan sistematika penelitian.
2. Bab 2: Tinjauan Pustaka: Kajian literatur terkait opponent modelling, IPD, dan pendekatan pembelajaran daring.
3. Bab 3: Kerangka Teoritis: Formulasi masalah, definisi formal belief dan forecasting loss, serta arsitektur umum.
4. Bab 4: Metode Penelitian: Desain eksperimen, algoritma, dan prosedur evaluasi.
5. Bab 5: Jadwal Penelitian: gant chart, depedensi, dan risiko.
6. Bab 6: Kesimpulan dan Saran.

BAB II

TINJAUAN PUSTAKA

Bagian ini mensintesis temuan utama dari studi yang ditinjau dengan tujuan mengidentifikasi pola asumsi perilaku lawan serta implikasinya terhadap desain metodologis pemodelan lawan dalam *repeated games*. Sintesis difokuskan pada dimensi perilaku yang dapat diamati dari riwayat interaksi, alih-alih pada asumsi internal seperti struktur optimisasi reward atau arsitektur pembelajaran yang digunakan.

Pendekatan ini penting karena dalam banyak karya terdahulu, pemodelan perilaku lawan sering kali tidak dipisahkan secara konseptual dari proses optimisasi kebijakan agen. Akibatnya, representasi perilaku lawan terenkapsulasi di dalam parameter kebijakan atau fungsi nilai, sehingga sulit untuk mengevaluasi kualitas prediksi perilaku secara independen dari reward yang dicapai. Untuk mengidentifikasi celah tersebut secara sistematis, tinjauan ini mengabstraksikan asumsi perilaku lawan pada tingkat eksternal yang dapat diinferensi dari *interaction traces*.

Tabel ?? merangkum berbagai pendekatan dalam *opponent modelling* dan pembelajaran multi-agen pada interaksi strategis berulang. Pendekatan berbasis pemodelan eksplisit terhadap lawan ditunjukkan oleh Online Opponent Modeling (O2M) yang dilaporkan mampu beradaptasi lebih baik dan memperoleh reward rata-rata lebih tinggi dibandingkan baseline (Qiao et al. 2024). Dalam konteks dinamika evolusioner, strategi Zero Determinant menunjukkan proporsi kerja sama akhir yang lebih tinggi dibandingkan strategi Extort, mengindikasikan peran signifikan dinamika populasi dalam membentuk hasil kolektif (L. Zhu et al. 2025).

Pendekatan berbasis pembelajaran mendalam juga menunjukkan kemampuan adaptif terhadap dinamika lawan. Hierarchical Gifting DQN mampu mendeteksi perubahan strategi secara real-time dan menyesuaikan insentif kerja sama secara dinamis (Lv et al. 2023). Model berbasis LSTM dilaporkan dapat mengaproksimasi dinamika no-regret secara akurat dan mengeksploitasi lawan secara menguntungkan pada tingkat non-stasioneritas rendah (Li et al. 2025). Selain itu, pendekatan Deep Multiagent Reinforcement Learning pada Social Prisoner's Dilemma mampu mencapai kerja sama mutual dan beradaptasi terhadap perubahan strategi lawan (Wang et al. 2019).

Beberapa studi menekankan pentingnya struktur interaksi dan kopling dinamika. Environment-Strategy Coupling Model menunjukkan bahwa kopling antara

umpan balik lingkungan dan dinamika strategi meningkatkan stabilitas kerja sama kelompok (Di et al. 2023), sementara Extended Social Particle Swarm Model memperlihatkan bahwa ukuran populasi dan laju pembaruan informasi memengaruhi pola kerja sama yang muncul (Elhamer et al. 2020). Pendekatan Teamwork Game dengan MA-MAB bahkan mampu mereproduksi pola perilaku mirip manusia seperti *social loafing* dan *compensation* (Gómez et al. 2025).

Dalam konteks pemodelan internal dan kesadaran pembelajaran, Internal Model dilaporkan mencapai konvergensi lebih cepat dibanding TD-learning standar, meskipun performanya menurun ketika perilaku lawan bergantung langsung pada aksi agen (Freire et al. 2023). Symmetric Learning Awareness (SLA) meningkatkan stabilitas keseimbangan dan mengurangi siklikitas pada metode gradien standar melalui pemodelan eksplisit terhadap proses pembelajaran lawan (Hu et al. 2023). Pendekatan Higher-order Theory of Mind (ToM k) menunjukkan bahwa peningkatan level ToM memberikan pengaruh signifikan hingga tingkat tertentu, dengan *diminishing returns* setelah ToM-3 (De Weerd et al. 2022). Sementara itu, mekanisme Suggestion Sharing meningkatkan kerja sama dibandingkan skema berbagi nilai atau kebijakan (Jin et al. 2025), dan pendekatan Ensemble-Training Cooperative Agent menunjukkan peningkatan robustnes dan generalisasi meskipun dengan biaya komputasi yang lebih tinggi (Perera et al. 2025).

Secara keseluruhan, literatur menunjukkan keberagaman pendekatan dalam memodelkan dan merespons dinamika perilaku lawan, baik melalui pembelajaran eksplisit, mekanisme kopling lingkungan, maupun adaptasi berbasis populasi. Namun demikian, fokus evaluasi dalam studi-studi tersebut umumnya diarahkan pada peningkatan reward, stabilitas kerja sama, atau konvergensi, sehingga membuka ruang analisis lebih lanjut mengenai hubungan antara kualitas prediksi perilaku lawan dan implikasinya terhadap perencanaan strategis lintas-horizon.

2.1 Asumsi Perilaku Lawan dalam pemodelan lawan untuk *Repeated Games*

Untuk mengoperasionalkan asumsi perilaku lawan secara konsisten pada pengaturan permainan yang beragam, tinjauan ini mengkarakterisasi perilaku berdasarkan dependensi yang dapat diamati dari riwayat interaksi. Secara khusus, aksi lawan dianalisis berdasarkan apakah ia:

1. Bervariasi lintas kondisi lingkungan dalam permainan yang sama,

2. Dimediasi oleh dinamika tingkat populasi,
3. Merespons secara langsung aksi agen,
4. Menunjukkan divergensi aksi pada riwayat interaksi terkini yang ekuivalen.

Kriteria-kriteria ini sepenuhnya berbasis observasi eksternal dan tidak mengasumsikan akses terhadap model internal, mekanisme pembelajaran, maupun fungsi objektif lawan. Dengan demikian, kategorisasi ini bukan taksonomi formal algoritma, melainkan kerangka analitis untuk memungkinkan perbandingan lintas paradigma pembelajaran.

Dalam studi yang tidak menyatakan asumsi perilaku secara eksplisit, klasifikasi diturunkan secara konservatif dari desain eksperimen dan dinamika interaksi yang dilaporkan. Hasil kategorisasi dirangkum pada Tabel 2.1.

Distribusi asumsi dependensi perilaku lawan dalam literatur menunjukkan variasi tingkat kompleksitas interaksi yang dimodelkan. Studi pada Jin et al. 2025 berfokus pada respons langsung terhadap aksi agen tanpa mempertimbangkan efek populasi maupun variasi lintas lingkungan. Pendekatan pada Gómez et al. 2025 menempatkan perilaku dalam konteks populasi, namun tanpa asumsi respons langsung terhadap agen atau divergensi pada riwayat yang ekuivalen. Sementara itu, Elhamer et al. 2020 menggabungkan dinamika populasi dan respons agen, tetapi tidak secara eksplisit memasukkan asumsi divergensi perilaku pada riwayat identik.

Sebaliknya, sejumlah studi secara eksplisit mengasumsikan adanya respons agen sekaligus potensi divergensi perilaku. Pendekatan pada Qiao et al. 2024, Lv et al. 2023, Li et al. 2025, Freire et al. 2023, Hu et al. 2023, Wang et al. 2019, dan De Weerd et al. 2022 memodelkan lawan yang secara langsung merespons aksi agen serta memungkinkan terjadinya divergensi aksi meskipun riwayat interaksi terkini setara. Studi pada Perera et al. 2025 memperluas asumsi ini dengan memasukkan dimensi populasi, sehingga perilaku lawan dipengaruhi baik oleh interaksi agen maupun struktur populasi, serta tetap memungkinkan divergensi. Pada tingkat kompleksitas yang lebih tinggi, L. Zhu et al. 2025 dan Di et al. 2023 mempertimbangkan variasi lintas lingkungan sekaligus dinamika populasi, dengan potensi divergensi perilaku yang muncul dari interaksi struktural dan evolusioner.

Sejumlah pola konsisten muncul dari Tabel 2.1. Mayoritas studi terkini mengasumsikan lawan yang responsif terhadap aksi agen serta menunjukkan divergensi perilaku pada riwayat interaksi yang setara. Hal ini mencerminkan pergeseran fokus

Tabel 2.1 Asumsi perilaku lawan berdasarkan dependensi perilaku yang dapat diamati.

Referensi	Lingkungan	Populasi	Agen	divergensi
Jin et al. 2025	—	—	✓	—
Gómez et al. 2025	—	✓	—	—
Elhamer et al. 2020	—	✓	✓	—
Qiao et al. 2024	—	—	✓	✓
Lv et al. 2023	—	—	✓	✓
Li et al. 2025	—	—	✓	✓
Freire et al. 2023	—	—	✓	✓
Hu et al. 2023	—	—	✓	✓
Wang et al. 2019	—	—	✓	✓
De Weerd et al. 2022	—	—	✓	✓
Perera et al. 2025	—	✓	✓	✓
L. Zhu et al. 2025	✓	✓	—	✓
Di et al. 2023	✓	✓	✓	✓

Catatan:

Lingkungan — perilaku bervariasi lintas lingkungan dalam permainan yang sama;

Populasi — perilaku dimediasi oleh interaksi tingkat populasi;

Agen — perilaku merespons secara langsung aksi agen;

Divergen — divergensi aksi terjadi pada riwayat interaksi terkini yang ekuivalen.

Tanda centang menunjukkan adanya dependensi.

riset dari optimisasi terhadap strategi lawan yang tetap menuju interaksi dengan lawan yang adaptif dan dinamis.

2.2 Pendekatan metodologis dalam pemodelan lawan untuk *Repeated Games*

Distribusi asumsi perilaku lawan pada Tabel 2.1 mencerminkan pergeseran metodologis yang lebih luas dalam riset pemodelan lawan, dari pengaturan dengan asumsi lawan yang tetap dan terkontrol menuju lawan yang adaptif, heterogen, dan berperilaku tidak stasioner. Namun, karakterisasi berbasis asumsi perilaku semata belum menjelaskan bagaimana kompleksitas tersebut dihadapi secara komputasional di sisi agen. Untuk itu, Tabel 2.2 mereorganisasi studi-studi terdahulu berdasarkan paradigma pemodelan dominan dan mekanisme pembelajaran yang digunakan oleh agen.

Pendekatan-pendekatan tersebut dapat dibedakan lebih lanjut berdasarkan apakah adaptasi terhadap lawan ditangani secara eksplisit atau implisit. Paradigma pemodelan lawan yang eksplisit—seperti *gradient-based opponent shaping* Qiao et al. 2024; Hu et al. 2023; Wang et al. 2019, *recursive belief reasoning* Freire et al. 2023; De Weerd et al. 2022, serta *system identification* Li et al. 2025—secara langsung membangun representasi internal perilaku lawan untuk memprediksi atau memengaruhi respons lawan di masa depan. Sebaliknya, pendekatan implisit, termasuk *reactive reinforcement learning* Lv et al. 2023, *population-based training* Perera et al. 2025, dinamika evolusioner L. Zhu et al. 2025; Di et al. 2023; Elhamer et al. 2020, dan *bandit-based learning-in-games* Gómez et al. 2025, beradaptasi terhadap lawan tanpa mempertahankan model perilaku lawan yang terpisah.

Meskipun demikian, baik pendekatan eksplisit maupun implisit pada umumnya merumuskan dan mengevaluasi adaptasi terhadap lawan hanya pada tingkat respons satu langkah (*one-step interaction*), tanpa melakukan pemodelan atau evaluasi eksplisit terhadap konsekuensi perilaku lawan dalam horizon multi-langkah.

Kebanyakan Pendekatan yang memperlakukan perilaku lawan sebagai proses sekuensial yang dapat dipelajari, serta dievaluasi berdasarkan kualitas prediksi terhadap lintasan aksi di masa depan, bukan semata-mata berdasarkan payoff agregat jangka panjang. Pendekatan semacam ini secara alami menekankan pentingnya *forecasting* multi-langkah dalam menghadapi dinamika interaksi berulang, terutama ketika keputusan pada fase awal interaksi memiliki implikasi strategis terhadap lintasan berikutnya.

Tabel 2.2 Klasifikasi Pendekatan Pemodelan Lawan

Ref	Kategori	Pendekatan	Model
Wang et al. 2019	Implisit	Bandit-based Learning	Multi-Armed Bandit
Gómez et al. 2025	Implisit	Bandit-based Learning	Multi-Armed Bandit (MA-MAB)
L. Zhu et al. 2025	Implisit	Dinamika Evolusioner	Strategi berbasis fitness
Elhamer et al. 2020	Implisit	Dinamika Evolusioner	Extended Social Particle Swarm (SPS)
Perera et al. 2025	Implisit	Population-based Training	MARL berbasis ensemble
Wang et al. 2019	Implisit	Reactive Reinforcement Learning	Deep RL (DQN)
Lv et al. 2023	Eksplisit	Gradient-based Opponent Shaping	Pembaruan sadar lawan
Hu et al. 2023	Eksplisit	Gradient-based Opponent Shaping	Symmetric Learning Awareness (SLA)
De Weerd et al. 2022	Eksplisit	Recursive Belief Reasoning	Higher-order Theory of Mind
Li et al. 2025	Eksplisit	System Identification	NARX / LSTM Strategy

Dalam konteks ini, pendekatan berbasis model sekuensial memori seperti *Long Short-Term Memory* (LSTM) menawarkan alternatif metodologis yang berbeda. LSTM dapat dipandang sebagai pendekatan yang memodelkan perilaku lawan sebagai proses dinamis berbasis riwayat interaksi. Aksi agen diperlakukan sebagai sinyal eksogen, sementara urutan aksi lawan dipelajari sebagai keluaran yang bergantung pada dependensi temporal jangka pendek maupun jangka panjang.

Model LSTM dilatih untuk meminimalkan kesalahan prediksi perilaku lawan tanpa melibatkan sinyal reward agen. Dengan demikian, kualitas model lawan dapat dievaluasi secara independen menggunakan metrik prediksi sekuensial, sebelum diintegrasikan ke dalam proses pengambilan keputusan.

Selain itu, struktur rekuren pada LSTM memungkinkan forecast multi-langkah (*multi-step forecasting*) terhadap aksi lawan memanfaatkan skema prediksi rekursif atau *rolling horizon*. Kemampuan ini relevan dalam *repeated games*, di mana keputusan optimal agen sering kali bergantung pada ekspektasi terhadap respons lawan tidak hanya pada langkah berikutnya, tetapi juga pada beberapa langkah interaksi

selanjutnya. Dengan menyediakan estimasi lintasan perilaku lawan pada horizon terbatas, agen dapat melakukan evaluasi strategi secara lebih prospektif dibandingkan pendekatan satu-langkah.

Literatur yang sepenuhnya memisahkan pembelajaran model lawan dari sinyal reward kebijakan masih relatif terbatas, khususnya dalam konteks *repeated games* dengan lawan adaptif dan tidak stasioner.

2.3 Bagaimana efektivitas strategi pemodelan lawan dievaluasi dalam *Repeated Games*?

Praktik evaluasi secara implisit mendefinisikan apa yang dianggap sebagai keberhasilan dalam interaksi multi-agent yang adaptif, baik dalam bentuk hasil kerja sama, ketahanan terhadap eksploitasi, stabilitas perilaku, maupun akurasi prediksi. Tabel 2.3 merangkum lingkungan evaluasi dan metrik yang digunakan dalam penelitian-penelitian terdahulu, dengan tujuan mengidentifikasi pola evaluasi yang berulang serta aspek-aspek yang relatif terabaikan.

Berbagai penelitian terdahulu mengevaluasi pendekatan pemodelan lawan dalam lingkungan dan metrik yang beragam. (Qiao et al. 2024) mengevaluasi metode mereka dalam pengaturan *self-play* simetris dengan fokus pada eror prediksi (MSE) selama pelatihan *offline* serta akurasi representasi memori laten. (L. Zhu et al. 2025) menggunakan jaringan *scale-free* dengan strategi *zero-determinant* dan menilai dinamika melalui frekuensi kerja sama dan eksploitasi. Pendekatan *reactive reinforcement learning* yang diajukan (Lv et al. 2023) dievaluasi terhadap lawan adaptif dengan metrik utama berupa nilai reward yang dirata-ratakan pada beberapa tipe lawan. (Gómez et al. 2025) menguji pendekatan mereka dalam simulator *teamwork-game* khusus, menggunakan produktivitas tim agregat, konvergensi menuju *Nash equilibrium*, serta kontribusi individu sebagai indikator kinerja.

Dalam konteks dinamika evolusioner (Di et al. 2023) dan (Elhamer et al. 2020) memanfaatkan simulator permainan evolusioner dan ruang kontinu, dengan metrik seperti tingkat kerja sama, fraksi kooperator, serta stabilitas klaster. (Perera et al. 2025) mengevaluasi pendekatan berbasis populasi dalam *repeated matrix games* menggunakan populasi sintesis, dengan fokus pada payoff rata-rata, robustness, dan generalisasi. (Li et al. 2025) pada *repeated zero-sum games* mengukur galat prediksi dan payoff kumulatif sebagai indikator efektivitas eksploitasi lawan. (Freire et al. 2023) dan (Hu et al. 2023) mengkaji *repeated matrix games* dengan menilai efektivitas,

stabilitas, akurasi prediksi, payoff rata-rata, serta kecepatan konvergensi.

Selain itu (Wang et al. 2019) mengembangkan lingkungan SPD dua dimensi khusus dan mengevaluasi reward rata-rata serta kesejahteraan sosial, sementara (Jin et al. 2025) memanfaatkan benchmark MARL dengan metrik return ternormalisasi dan konvergensi. (De Weerd et al. 2022) menggunakan simulasi *Colored Trails* dan menilai performa melalui skor agen serta kesejahteraan sosial. Secara keseluruhan, variasi lingkungan dan metrik ini menunjukkan bahwa evaluasi dalam literatur cenderung berfokus pada indikator payoff, konvergensi, atau tingkat kerja sama, sementara pengukuran eksplisit terhadap kualitas peramalan trajektori perilaku lawan dalam horizon multi-langkah masih relatif terbatas.

Sebagaimana terlihat pada Tabel 2.3, mayoritas studi mengevaluasi efektivitas pemodelan lawan melalui metrik kinerja agregat jangka panjang, seperti payoff rata-rata, tingkat kerja sama, stabilitas, serta konvergensi menuju equilibrium. Evaluasi semacam ini menilai keberhasilan berdasarkan hasil akhir interaksi, tanpa secara eksplisit mengkaji bagaimana kualitas prediksi perilaku lawan pada berbagai horizon mempengaruhi proses pengambilan keputusan strategis.

Selain itu, sebagian besar pendekatan yang melibatkan komponen prediktif melaporkan kinerja berdasarkan galat satu langkah (*one-step prediction error*). Meskipun metrik ini relevan untuk mengukur konsistensi lokal model terhadap data historis, ia tidak secara langsung mencerminkan kebutuhan perencanaan dalam *repeated games*. Dalam konteks permainan berulang seperti IPD, keputusan pada suatu langkah mempengaruhi respons lawan pada langkah-langkah berikutnya, sehingga pengambilan keputusan bersifat intrinsik multi-langkah.

Ketergantungan pada objektif prediksi satu langkah berpotensi menimbulkan ketidaksesuaian antara objektif statistik dan objektif strategis. Model yang dioptimalkan untuk meminimalkan galat satu langkah belum tentu menghasilkan estimasi lintasan perilaku lawan yang stabil ketika digunakan untuk perencanaan lintas-horizon. Dalam skema *recursive forecasting*, kesalahan prediksi awal dapat terpropagasi dan mempengaruhi estimasi payoff kumulatif secara non-linear. Namun demikian, literatur yang ada jarang menguji secara eksplisit bagaimana kualitas prediksi multi-langkah berhubungan dengan performa strategis agen.

Lebih lanjut, belum banyak studi yang secara sistematis membandingkan implikasi penggunaan prediksi satu langkah, *recursive multi-step forecasting*, dan *direct multi-step forecasting* terhadap payoff strategis. Analisis mengenai keberadaan horizon prediksi optimal (k^*) yang memberikan trade-off terbaik antara stabilitas prediksi

Tabel 2.3 Lingkungan evaluasi dan metrik dalam penelitian

Ref.	Lingkungan Evaluasi	Metrik
Qiao et al. 2024	Self-play simetris	MSE selama pelatihan offline; akurasi memori laten
L. Zhu et al. 2025	Jaringan scale-free dengan strategi zero-determinant	Frekuensi kerja sama (C) dan eksploitasi (E)
Lv et al. 2023	Opponent adaptif (dirata-ratakan pada beberapa opponent)	Nilai reward
Gómez et al. 2025	Simulator teamwork-game khusus	Produktivitas tim agregat; konvergensi ke Nash equilibrium; kontribusi individu
Di et al. 2023	Simulator evolutionary game	Tingkat kerja sama; fraksi kooperator
Perera et al. 2025	Repeated matrix games dengan populasi sintetis	Payoff rata-rata; robustness; generalisasi
Li et al. 2025	Repeated zero-sum games	Galat prediksi; payoff kumulatif
Freire et al. 2023	Repeated matrix games	Efektivitas; stabilitas; akurasi prediksi
Hu et al. 2023	Simulasi repeated matrix game	Payoff rata-rata; kecepatan konvergensi
Elhamer et al. 2020	Simulasi continuous-space	Tingkat kerja sama; stabilitas klaster
Wang et al. 2019	Lingkungan SPD 2D khusus	Reward rata-rata; kesejahteraan sosial
Jin et al. 2025	Benchmark MARL	Return ternormalisasi; konvergensi
De Weerd et al. 2022	Simulasi Colored Trails	Skor agen; kesejahteraan sosial

Tabel 2.4 Ringkasan Penelitian Terkait

Ref	Nama Model	Temuan Utama
Qiao et al. 2024	Online Opponent Modeling (O2M)	O2M mampu beradaptasi lebih baik dan memperoleh rata-rata reward lebih tinggi dibandingkan baseline.
L. Zhu et al. 2025	Zero Determinant Strategy under Evolutionary Dynamic	Proporsi akhir kerja sama melebihi strategi Extort, menunjukkan keunggulan dinamika evolusioner.
Lv et al. 2023	Hierarchical Gifting DQN	Mendeteksi perubahan strategi lawan secara real-time dan dinamis menyesuaikan insentif kerja sama.
Gómez et al. 2025	Teamwork Game + MA-MAB	Mereproduksi pola mirip manusia (social loafing, compensation).
Di et al. 2023	Environment-Strategy Coupling Model	Kopling antara umpan balik lingkungan dan dinamika strategi secara signifikan meningkatkan stabilitas kerja sama kelompok.
Perera et al. 2025	Ensemble-Training Cooperative Agent	Robust dan memiliki generalisasi lebih baik namun biaya komputasi lebih tinggi dan potensi estimasi reward intrinsik sub-optimal.
Li et al. 2025	LSTM-Strategy	RNN mampu mengaproksimasi dinamika no-regret yang halus secara akurat serta memungkinkan eksploitasi yang menguntungkan pada tingkat non-stasioneritas rendah.
Freire et al. 2023	Internal Model	Konvergensi lebih cepat dan stabil dibanding TD-learning standar; performa menurun ketika perilaku lawan bergantung pada aksi agen sendiri (misalnya Tit-for-Tat).
Hu et al. 2023	Symmetric Learning Awareness (SLA)	Keseimbangan yang lebih stabil dan menghindari perilaku siklik pada metode gradien standar; pemodelan eksplisit meningkatkan konvergensi.
El-hamer et al. 2020	Extended Social Particle Swarm (SPS) Model	Ukuran populasi dan laju pembaruan informasi membentuk pola kerja sama dinamis dan beragam.
Wang et al. 2019	Deep Multiagent Reinforcement Learning (untuk SPD)	Mencapai kerja sama mutual; adaptif terhadap perubahan strategi lawan.
Jin et al. 2025	Suggestion Sharing (SS)	Meningkatkan kerja sama dibanding value sharing dan policy sharing.
De Weerd et al. 2022	Higher-order Theory of Mind (ToM k , $k \geq 2$)	ToM tingkat tinggi berpengaruh signifikan; <i>diminishing returns</i> setelah ToM-3.

dan manfaat strategis juga masih terbatas.

Berdasarkan sintesis tersebut, terdapat celah penelitian yang signifikan, yaitu belum adanya analisis sistematis mengenai ketidaksesuaian antara objektif prediksi satu langkah dan kebutuhan perencanaan strategis multi-langkah dalam *repeated games*. Secara khusus, hubungan antara akurasi prediksi lintas-horizon, propagasi kesalahan dalam skema rekursif, dan dampaknya terhadap payoff strategis belum dievaluasi secara terintegrasi dan terkontrol.

Penelitian ini berangkat dari celah tersebut dengan memfokuskan analisis pada evaluasi kinerja prediksi multi-langkah serta implikasinya terhadap pengambilan keputusan strategis dalam IPD, tanpa memosisikan arsitektur model sebagai kontribusi utama, melainkan sebagai instrumen untuk mengisolasi efek horizon forecasting.

BAB III

LANDASAN TEORI

3.1 Dilema Sosial

Dilema sosial merupakan situasi di mana keputusan rasional secara individual menghasilkan luaran yang tidak optimal secara kolektif(Axelrod dan Hamilton 1981). Secara formal, kondisi ini dapat dinyatakan sebagai:

$$\sum_{i=1}^n u_i(a_i, a_{-i}) < \sum_{i=1}^n u_i(a'_i, a'_{-i})$$

di mana n adalah jumlah pemain, u_i adalah fungsi utilitas pemain i , a_i adalah aksi rasional individu dan a'_i adalah profil aksi yang memaksimalkan kesejahteraan kolektif.

Formulasi ini menjelaskan adanya konflik antara rasionalitas individu dan optimalitas sosial. Namun, ekspresi agregat tersebut belum menyediakan struktur analitis yang cukup untuk memodelkan interaksi strategis antar agen secara eksplisit.

3.2 Game Theory

teori permainan memberikan kerangka formal yang memodelkan pemain, strategi, dan payoff secara terstruktur (Bonanno 2024), dalam bentuk normal didefinisikan sebagai:

$$G = (N, A, U)$$

dengan N himpunan pemain, $A = A_1 \times A_2$ himpunan profil strategi atau *Action space*, dan $U = (u_1, u_2)$ fungsi payoff atau *utility*.

Nash Equilibrium adalah profil strategi a^* yang memenuhi:

$$u_i(a_i^*, a_{-i}^*) \geq u_i(a_i, a_{-i}^*) \quad \forall a_i \in A_i$$

Menunjukkan pilihan aksi selain a_i^* tidak dapat memberikan keuntungan lebih besar dari strategi keseimbangan. Kerangka ini memungkinkan analisis rasionalitas strategis dalam interaksi statik. Namun, model bentuk normal bersifat satu tahap dan mengasumsikan struktur payoff tetap.

3.3 Prisoner's Dilemma

Prisoner's Dilemma merepresentasikan konflik rasionalitas individu dan kolektif secara eksplisit (Axelrod dan Hamilton 1981). Aksi yang dapat dipilih adalah *Cooperate* (C) atau *Defect* (D). Struktur payoff Prisoner's Dilemma diberikan oleh:

	C	D
C	(R, R)	(S, T)
D	(T, S)	(P, P)

Tabel 3.1 Payoff Matrix Prisoner's Dilemma

Dengan R (Reward) adalah payoff jika kedua pemain bekerja sama, T (Temptation) adalah payoff bagi pemain yang berkhianat sementara yang lain bekerja sama, S (Sucker's payoff) adalah payoff bagi pemain yang bekerja sama sementara yang lain berkhianat, dan P (Punishment) adalah payoff jika kedua pemain berkhianat. dengan ketidaksamaan:

$$T > R > P > S \quad \text{dan} \quad 2R > T + S.$$

Dalam permainan satu tahap, strategi dominan adalah defeksi (D), sehingga keseimbangan Nash berada pada (D, D) meskipun (C, C) lebih optimal secara kolektif. Namun, interaksi nyata jarang terjadi hanya satu kali.

3.4 Prisoner's Dilemma Berulang


Permainan PD diperluas menjadi bentuk berulang disebut Iterated Prisoner's Dilemma (IPD), permainan diulang selama T atau *Turn* tahap dengan payoff kumulatif atau terdiskonto. Dalam IPD, strategi dapat bergantung pada histori interaksi, memungkinkan untuk pembalasan dan kerja sama yang berkelanjutan. IPD relevan untuk mempelajari dinamika manusia seperti: pembentukan hubungan, konflik berkepanjangan, siklus saling membalas, dan pemulihan kepercayaan.

berberapa strategi terkenal dalam IPD meliputi:

- *Tit-for-Tat*: Mulai dengan bekerja sama, kemudian meniru aksi lawan pada langkah sebelumnya.
- *Cooperator*: Selalu bekerja sama.
- *Defector*: Selalu berkhianat.

- *Random*: Memilih secara acak antara bekerja sama dan berkhianat.

beberapa algoritma tersebut dapat dipahami melalui gambar 3.1 finite state machine.



Gambar 3.1 Finite Automata untuk strategi IPD.

3.4.1 Horizon Terbatas

Pada formulasi horizon terbatas dengan panjang permainan tetap T , utilitas total pemain didefinisikan sebagai penjumlahan utilitas pada setiap ronde:

$$U_i = \sum_{t=1}^T u_i(a_i^t, a_{-i}^t) \quad (3.1)$$

Pada model ini, tidak digunakan faktor diskonto. Namun, secara teoretis, pendekatan ini cenderung menghasilkan strategi defeksi melalui mekanisme *backward induction* (Bonanno 2024).

3.4.2 Definisi Riwayat Interaksi pada mekanisme online

Dalam konteks iterated game dua pemain, riwayat hingga waktu t tidak hanya terdiri dari aksi satu pemain, tetapi pasangan aksi kedua pemain pada setiap putaran. Secara formal, riwayat didefinisikan sebagai:

$$h_t = ((a_i^1, a_{-i}^1), (a_i^2, a_{-i}^2), \dots, (a_i^t, a_{-i}^t))$$

dengan a_i^k menyatakan aksi pemain i pada waktu k , dan a_{-i}^k menyatakan aksi lawan pada waktu yang sama (Bonanno 2024).

Dalam pengaturan iteratif, riwayat tidak tersedia secara sekaligus, melainkan terbentuk secara *online*. Pada setiap putaran t , riwayat diperbarui secara inkremental sebagai:

$$h_t = (h_{t-1}, (a_i^t, a_{-i}^t))$$

dengan $h_0 = \emptyset$.

Formulasi ini menegaskan bahwa agen tidak memiliki akses terhadap trajektori interaksi di masa depan, dan hanya dapat menggunakan informasi yang telah terobservasi hingga waktu berjalan. Dengan kata lain, proses pengambilan keputusan berlangsung dalam kerangka kausal dan sekuensial (Bonanno 2024).

riwayat interaksi menyediakan rekaman lengkap atas realisasi aksi kedua pemain. *Namun*, riwayat hanya merepresentasikan keluaran observabel dari proses pengambilan keputusan lawan, bukan mekanisme generatif yang mendasarinya. Agen tidak memiliki akses langsung terhadap strategi internal, parameter keputusan, ataupun aturan adaptasi yang digunakan oleh lawan (Bonanno 2024).

Dengan demikian, meskipun seluruh pasangan aksi teramati secara bertahap, struktur strategi lawan tetap bersifat laten. Kondisi ini menyebabkan interaksi dalam IPD tidak memenuhi asumsi informasi lengkap sebagaimana pada analisis keseimbangan statik klasik (Bonanno 2024).

Oleh karena itu, permasalahan strategis dalam IPD dengan agen adaptif berada dalam kerangka permainan dengan informasi tidak lengkap, di mana agen harus melakukan inferensi terhadap strategi lawan secara bertahap seiring pertambahan riwayat (Bonanno 2024).

3.4.3 Informasi tidak lengkap dan Pembentukan kepercayaan

Dalam permainan dengan informasi tidak lengkap, ketidakpastian terhadap strategi lawan direpresentasikan melalui distribusi probabilitas atas kemungkinan tipe atau parameter strategi. Alih-alih mengasumsikan strategi tetap dan diketahui, agen memelihara suatu *belief state* yang diperbarui seiring bertambahnya histori interaksi.

Secara konseptual, belief state pada waktu t dapat dituliskan sebagai:

$$b_t = P(\theta \mid h_t)$$

dengan θ merepresentasikan representasi laten dari strategi lawan, dan h_t adalah histori interaksi hingga waktu t .

Formulasi ini menegaskan bahwa pengambilan keputusan dalam IPD adaptif bukan sekadar persoalan memilih aksi optimal terhadap strategi tetap, melainkan proses pembaruan belief secara sekuensial terhadap dinamika perilaku lawan. Dengan demikian, fokus analisis bergeser dari pencarian equilibrium statik menuju inferensi dinamis berbasis histori (Bonanno 2024).

3.5 Pemodelan Lawan

Pemodelan lawan atau *pemodelan lawan* memungkinkan untuk mempelajari perilaku ataupun strategi lawan (Shoham 2009).

Diberikan riwayat interaksi penuh:

$$h_t = ((a_i^1, a_{-i}^1), \dots, (a_i^t, a_{-i}^t)) \quad (3.2)$$

model parametrik f_θ mempelajari distribusi kondisional:


$$p_{\theta}(a_{t+1}^{-i} \mid h_t)$$

Pendekatan regresi linear sederhana mampu memodelkan hubungan statik, namun memiliki keterbatasan dalam menangkap dependensi temporal dan pola nonlinier (Hochreiter dan Schmidhuber 1997).

3.6 Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM) merupakan pengembangan dari Recurrent Neural Network (RNN) yang dirancang untuk menangkap dependensi jangka panjang melalui mekanisme memori eksplisit (Hochreiter dan Schmidhuber 1997). Dalam konteks *pemodelan lawan*, LSTM digunakan untuk membangun representasi laten terhadap strategi lawan berdasarkan histori interaksi.

Diberikan input x_t (observasi pada waktu t , misalnya aksi lawan), hidden state sebelumnya h_{t-1} (representasi laten sebelumnya), dan parameter bobot W , U , serta bias b , setiap komponen LSTM bekerja secara berurutan sebagai berikut.



Gambar 3.2 Diagram LSTM.

3.6.1 Forget Gate

Forget gate mengontrol sejauh mana informasi pada state memori sebelumnya dipertahankan atau diabaikan pada waktu t . Secara formal, nilai gerbang pelupaan f_t dihitung melalui fungsi aktivasi sigmoid terhadap kombinasi linear antara input saat ini x_t , hidden state sebelumnya h_{t-1} , serta bias b_f . Parameter W_f dan U_f masing-masing merepresentasikan matriks bobot yang memetakan input dan hidden state ke ruang gerbang. Karena fungsi sigmoid menghasilkan keluaran pada rentang $(0, 1)$, setiap elemen dalam f_t berperan sebagai koefisien penskalaan yang mengatur proporsi informasi dari cell state sebelumnya yang akan dipertahankan. Nilai yang mendekati 1 menunjukkan bahwa informasi tersebut dipertahankan hampir sepenuhnya, sedangkan nilai yang mendekati 0 menyebabkan informasi tersebut dilupakan. Dengan demikian, forget gate memungkinkan model menyesuaikan horizon memori secara adaptif, sehingga dependensi temporal jangka panjang dapat dipertahankan atau dihapus sesuai kebutuhan dinamika data.

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f) \quad (3.3)$$

3.6.2 Input Gate

Input $x_t \in \mathbb{R}^d$ merepresentasikan observasi saat ini, sedangkan $h_{t-1} \in \mathbb{R}^h$ adalah ringkasan historis interaksi sebelumnya. Namun, tidak semua informasi baru relevan atau stabil untuk memperbarui belief terhadap strategi lawan. Oleh karena itu, input gate $i_t \in [0, 1]^h$ mengontrol seberapa besar setiap dimensi informasi baru akan diterima ke dalam memori, dengan $\sigma(\cdot)$ sebagai fungsi sigmoid dan W_i, U_i, b_i sebagai parameter yang dipelajari.

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i) \quad (3.4)$$

3.6.3 Candidate Cell State

Informasi mentah dari x_t tidak langsung disimpan karena dapat mengandung noise atau pola sementara yang belum representatif. Namun, model tetap membutuhkan representasi kandidat dari informasi baru tersebut. Oleh karena itu, $\tilde{c}_t \in [-1, 1]^h$ dibentuk melalui transformasi non-linear $\tanh(\cdot)$ sebagai kandidat memori baru, dengan parameter W_c, U_c, b_c .

$$\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c) \quad (3.5)$$

3.6.4 Cell State (Memori Jangka Panjang)

Cell state $c_t \in \mathbb{R}^h$ merupakan jalur utama propagasi informasi jangka panjang dalam LSTM yang berfungsi sebagai *latent belief representation* terhadap strategi lawan. Namun, memori ini harus mampu menjaga stabilitas sekaligus tetap adaptif terhadap informasi baru. Oleh karena itu, pembaruannya dirumuskan sebagai:

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \quad (3.6)$$

Operator $\odot$ menyatakan perkalian elemen-per-elemen. Komponen $f_t \odot c_{t-1}$ mempertahankan informasi lama yang masih relevan, sedangkan $i_t \odot \tilde{c}_t$ menambahkan informasi baru secara selektif. Struktur aditif ini penting karena menjaga stabilitas gradien dan memungkinkan pembelajaran dependensi jangka panjang.

3.6.5 Output Gate

Meskipun c_t menyimpan informasi lengkap, tidak seluruhnya relevan untuk prediksi saat ini. Namun, model perlu mengekstrak bagian informasi yang paling informatif untuk pengambilan keputusan. Oleh karena itu, output gate $o_t \in [0, 1]^h$ mengontrol seberapa besar informasi dari cell state akan diekspos ke hidden state, dengan parameter W_o, U_o, b_o .

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o) \quad (3.7)$$

Pada persamaan di 3.7, $x_t \in \mathbb{R}^d$ menyatakan vektor input pada waktu t dengan dimensi fitur d , sedangkan $h_{t-1} \in \mathbb{R}^h$ adalah hidden state pada waktu sebelumnya dengan dimensi laten h . Matriks bobot $W_o \in \mathbb{R}^{h \times d}$ memetakan input ke ruang gerbang keluaran, dan $U_o \in \mathbb{R}^{h \times h}$ memetakan hidden state sebelumnya ke ruang yang sama. Vektor bias $b_o \in \mathbb{R}^h$ memungkinkan pergeseran affine dalam transformasi linear tersebut. Fungsi aktivasi sigmoid $\sigma(\cdot)$ diterapkan secara elemen-per-elemen sehingga menghasilkan $o_t \in (0, 1)^h$, yaitu vektor koefisien yang mengatur proporsi informasi dari cell state c_t yang akan diekspos ke hidden state saat ini. Dengan demikian, output gate berperan sebagai mekanisme penyaringan adaptif yang menentukan komponen representasi memori internal yang relevan untuk menghasilkan representasi laten h_t

dan prediksi pada waktu t .

3.6.6 Hidden State Update

Cell state c_t mengandung representasi lengkap jangka panjang, namun terlalu kaya untuk digunakan secara langsung. Oleh karena itu, hidden state $h_t \in \mathbb{R}^h$ dibentuk sebagai representasi laten terfilter yang lebih terfokus, yang kemudian digunakan untuk memprediksi aksi lawan atau sebagai input ke modul pengambilan keputusan.

$$h_t = o_t \odot \tanh(c_t) \quad (3.8)$$

Struktur ini memungkinkan model mempertahankan dependensi jangka panjang sekaligus tetap adaptif terhadap perubahan strategi lawan. Oleh karena itu, LSTM sangat sesuai untuk digunakan dalam permainan berulang seperti Iterated Prisoner's Dilemma, di mana perilaku lawan bergantung pada histori interaksi. Namun, karena LSTM hanya menghasilkan prediksi satu langkah ke depan, model ini belum secara eksplisit mempertimbangkan konsekuensi jangka panjang, sehingga masih berpotensi menghasilkan kebijakan yang suboptimal.

3.7 Prediksi Multi-Langkah

Model LSTM menghasilkan distribusi prediktif satu langkah ke depan $p(a_{t+1}^{-i} | h_t)$. Namun, dalam permainan berulang, nilai suatu aksi tidak hanya ditentukan oleh respons lawan pada tahap berikutnya, melainkan oleh konsekuensi jangka panjang sepanjang lintasan interaksi (Nashed dan Zilberstein 2022).

3.7.1 Peramalan Rekursif dan Simulasi Monte Carlo (Horizon Tetap)

Untuk memperoleh estimasi lintasan masa depan sepanjang horizon tetap H , model perilaku lawan digunakan secara autoregresif. Pada setiap langkah ke- k , prediksi aksi lawan dihasilkan dari distribusi:

$$\hat{a}_{t+k}^{-i} \sim p_{\theta}(\cdot | \hat{h}_{t+k-1}), \quad k = 1, \dots, H$$

Pada formulasi di atas, t menyatakan waktu keputusan saat ini, sedangkan $H \in \mathbb{N}$ adalah horizon prediksi tetap yang menentukan panjang lintasan masa depan yang dipertimbangkan. Indeks k merepresentasikan langkah prediksi ke- k relatif

terhadap waktu t . Simbol $\hat{a}_{t+k}^{-i}$ menyatakan aksi lawan yang diprediksi pada waktu $t + k$, dengan superskrip $-i$ menunjukkan pemain lawan terhadap agen i . Distribusi prediktif $p_\theta(\cdot \mid \hat{h}_{t+k-1})$ merupakan model parametrik dengan parameter θ yang mengaproksimasi probabilitas aksi lawan bersyarat pada riwayat yang tersedia. Notasi $\hat{h}_{t+k-1}$ menyatakan riwayat interaksi yang telah diperluas secara rekursif hingga waktu $t + k - 1$, termasuk aksi-aksi yang sebelumnya diprediksi atau direalisasikan selama proses rollout.

Proses ini menghasilkan distribusi atas lintasan aksi sepanjang horizon terbatas:

$$\hat{\tau}_t^{(H)} = \{\hat{a}_{t+1}^{-i}, \hat{a}_{t+2}^{-i}, \dots, \hat{a}_{t+H}^{-i}\}$$

Lintasan prediksi sepanjang horizon H dinotasikan sebagai $\hat{\tau}_t^{(H)}$, yaitu himpunan berurutan dari aksi lawan yang diproyeksikan mulai dari $t + 1$ hingga $t + H$. Karena ruang kemungkinan lintasan bertumbuh secara eksponensial terhadap H , ekspektasi nilai tidak dihitung secara tertutup, melainkan didekati melalui simulasi Monte Carlo.

Karena jumlah kemungkinan lintasan tumbuh secara eksponensial terhadap H , ekspektasi payoff tidak dihitung secara analitik, melainkan diaproksimasi menggunakan simulasi Monte Carlo.

Untuk suatu aksi awal a_t , estimasi nilai diperoleh melalui M simulasi independen:

$$\hat{Q}_H(a_t) = \frac{1}{M} \sum_{m=1}^M \sum_{k=0}^{H-1} u_i^{(m)}(a_i^{t+k}, a_{-i}^{t+k}) \quad (3.9)$$

dengan:

- H : horizon prediksi tetap,
- M : jumlah rollout Monte Carlo,
- $u_i^{(m)}$: payoff agen pada simulasi ke- m .

Karena horizon bersifat terbatas, faktor diskonto tidak diperlukan, dan nilai aksi merepresentasikan akumulasi payoff sepanjang jendela prediksi tetap.

Dengan demikian, evaluasi aksi dilakukan melalui aproksimasi ekspektasi atas distribusi lintasan terbatas, yang sepenuhnya ditentukan oleh model belief dan horizon yang telah ditetapkan.

3.7.2 Teacher Forcing

Pada model sekuens autoregresif seperti RNN atau LSTM, prediksi pada waktu t bergantung pada output pada waktu sebelumnya. Dinamika umum model dapat dituliskan sebagai:

$$h_t = f(h_{t-1}, y_{t-1}; \theta),$$

$$\hat{y}_t = g(h_t; \theta),$$

dengan:

- h_t : hidden state pada waktu t ,
- y_{t-1} : input autoregresif pada waktu sebelumnya,
- $\hat{y}_t$: prediksi model pada waktu t ,
- θ : parameter model yang dipelajari.

Dalam skema *teacher forcing*, selama proses pelatihan, input autoregresif tidak berasal dari prediksi model, melainkan digantikan oleh nilai ground-truth y_{t-1}^* . Dengan demikian, dinamika pelatihan menjadi:

$$h_t = f(h_{t-1}, y_{t-1}^*; \theta).$$

Fungsi kerugian didefinisikan sebagai:

$$\mathcal{L}(\theta) = \sum_{t=1}^T \ell(\hat{y}_t, y_t^*), \quad (3.10)$$

dengan:

- T : panjang sekuens pelatihan,
- $\ell(\hat{y}_t, y_t^*)$: fungsi loss (misalnya cross-entropy atau MSE) yang mengukur selisih antara prediksi dan target sebenarnya.

Teacher forcing mempercepat konvergensi dan menghasilkan estimasi gradien yang lebih stabil, karena distribusi input selama pelatihan sesuai dengan distribusi data observasi.

Namun, pada fase inferensi (deployment), model tidak lagi memiliki akses ke ground-truth. Prediksi harus dihasilkan secara rekursif menggunakan output sebelumnya:

$$h_t = f(h_{t-1}, \hat{y}_{t-1}; \theta).$$

Perbedaan antara distribusi input saat pelatihan (menggunakan y_{t-1}^*) dan saat inferensi (menggunakan $\hat{y}_{t-1}$) menimbulkan fenomena yang dikenal sebagai *exposure bias*. Akibatnya, kesalahan kecil pada satu langkah dapat terpropagasi dan terakumulasi, menyebabkan *compounding error* yang semakin signifikan pada horizon prediksi yang panjang.

3.7.3 Fungsi Objektif Negative Log-Likelihood

Untuk mengevaluasi kualitas prediksi sekuensial lawan dalam horizon multi-step, digunakan metrik *Negative Log-Likelihood* (NLL) sebagai proper scoring rule yang konsisten terhadap estimasi distribusi probabilistik (D. Zhu et al. 2018).

Misalkan pada waktu t tersedia riwayat interaksi

$$h_t = \{(a_i^1, a_{-i}^1), \dots, (a_i^t, a_{-i}^t)\}.$$

Model pemodelan lawan menghasilkan distribusi probabilitas atas aksi lawan pada langkah berikutnya, yang dinotasikan sebagai:

$$P_\theta(a_{-i}^{t+1} \mid h_t)$$

dengan θ merepresentasikan parameter model (misalnya parameter LSTM).

Untuk prediksi multi-step sepanjang horizon H , model digunakan secara autoregresif, sehingga distribusi pada langkah ke- k bergantung pada riwayat yang telah diperluas hingga waktu tersebut. Secara umum, probabilitas gabungan untuk urutan aksi aktual lawan $a_{-i}^{t+1:t+H}$ diberikan oleh:

$$P_\theta(a_{-i}^{t+1:t+H} \mid h_t) = \prod_{k=1}^H P_\theta(a_{-i}^{t+k} \mid \hat{h}_{t+k-1}) \quad (3.11)$$

dengan:

- a_{-i}^{t+k} : aksi aktual lawan pada waktu $t + k$,

- $\hat{h}_{t+k-1}$: riwayat yang digunakan model pada langkah ke- k , yang terdiri dari riwayat asli h_t yang diperluas secara rekursif menggunakan observasi aktual hingga waktu $t + k - 1$,
- H : panjang horizon prediksi multi-step.

Negative Log-Likelihood untuk satu segmen horizon sepanjang H kemudian didefinisikan sebagai:

$$\mathcal{L}_{\text{NLL}}^{(H)} = - \sum_{k=1}^H \log P_{\theta}(a_{-i}^{t+k} \mid \hat{h}_{t+k-1}) \quad (3.12)$$

Nilai NLL yang lebih kecil menunjukkan bahwa model memberikan probabilitas yang lebih tinggi terhadap aksi aktual yang benar-benar terjadi. Karena NLL merupakan proper scoring rule, metrik ini tidak hanya mengevaluasi ketepatan klasifikasi, tetapi juga kualitas kalibrasi probabilitas yang dihasilkan model.

Dalam konteks IPD dengan lawan adaptif, penggunaan NLL multi-step memungkinkan pengukuran efek *compounding error* akibat prediksi rekursif. Jika distribusi prediksi menjadi semakin bias pada horizon yang lebih panjang, maka akumulasi log-loss akan meningkat secara signifikan, mencerminkan degradasi kualitas belief seiring waktu.

3.7.4 Rank Order Centroid (ROC)

Metode *Rank Order Centroid* (ROC) merupakan teknik pembobotan dalam *multi-criteria decision making* (MCDM) yang digunakan ketika hanya informasi peringkat (ranking) kriteria yang tersedia, tanpa nilai bobot numerik eksplisit. Metode ini diperkenalkan oleh Barron dan Barrett sebagai pendekatan aproksimasi sederhana terhadap bobot yang diperoleh dari metode *swing weighting* atau metode pembobotan berbasis utilitas (Barron dan Barrett 1996).

Misalkan terdapat n kriteria yang telah diurutkan berdasarkan tingkat kepentingannya, dengan kriteria peringkat pertama dianggap paling penting. Bobot ROC untuk kriteria ke- i didefinisikan sebagai rata-rata dari kebalikan peringkat mulai dari posisi tersebut hingga peringkat terakhir, yaitu:

$$w_i = \frac{1}{n} \sum_{j=i}^n \frac{1}{j}, \quad \text{untuk } i = 1, 2, \dots, n. \quad (3.13)$$

Dengan demikian, bobot yang dihasilkan memenuhi sifat:

$$w_1 \geq w_2 \geq \cdots \geq w_n, \quad \text{dan} \quad \sum_{i=1}^n w_i = 1.$$

Pendekatan ini mengasumsikan bahwa seluruh vektor bobot yang konsisten dengan urutan peringkat memiliki peluang yang sama, sehingga bobot ROC merepresentasikan nilai ekspektasi dari distribusi seragam atas seluruh kemungkinan bobot yang memenuhi urutan tersebut (Barron dan Barrett 1996).

Keunggulan utama metode ROC adalah kesederhanaannya dan kemampuannya menghasilkan estimasi bobot yang cukup representatif meskipun hanya tersedia informasi ordinal. Beberapa studi menunjukkan bahwa bobot ROC sering kali memberikan performa yang mendekati metode pembobotan yang lebih kompleks, khususnya ketika informasi numerik detail sulit diperoleh (Stillwell et al. 1981).

Dalam konteks penelitian ini, metode ROC digunakan untuk memberikan pembobotan berbeda pada prediksi lintasan (trajektori) berdasarkan urutan waktu, di mana prediksi pada langkah awal diberikan bobot lebih besar dibandingkan langkah berikutnya.

BAB IV


ANALISIS DAN PERANCANGAN

4.1 Deskripsi Umum

Penelitian ini bertujuan mengembangkan algoritma pembelajaran *online* untuk skenario *Iterated Prisoner's Dilemma* (IPD) dengan lawan yang dapat bersifat adaptif maupun non-stasioner.

Fokus utama penelitian adalah pada pemodelan lawan multi-langkah rekursif. Model prediktif dilatih untuk mengestimasi distribusi aksi lawan berdasarkan riwayat interaksi, tanpa menggunakan informasi reward sebagai sinyal pembelajaran.

Model prediksi tersebut kemudian digunakan sebagai komponen dalam simulasi *multi-step Monte Carlo rollout* untuk mengestimasi nilai aksi agen.



Gambar 4.1 Diagram metodologi.

4.2 Formulasi Masalah

Penelitian ini mempertimbangkan skenario *Iterated Prisoner's Dilemma* (IPD) dengan horizon tetap T .

Pada setiap langkah waktu $t = 1, \dots, T$, agen dan lawan masing-masing memilih aksi:

$$a_t^{agent}, a_t^{opp} \in \{C, D\}.$$

Reward diperoleh berdasarkan matriks payoff standar IPD.

Lawan diasumsikan dapat bersifat adaptif maupun non-stasioner, namun algoritma internalnya tidak diketahui. Lawan dapat berupa strategi tetap, strategi reaktif, atau strategi adaptif.

Agen tidak memiliki akses terhadap parameter internal, fungsi utilitas, maupun mekanisme pembelajaran lawan. Satu-satunya informasi yang tersedia adalah riwayat interaksi:

$$H_t = \{a_1^{agent}, a_1^{opp}, \dots, a_t^{agent}, a_t^{opp}\}.$$

Tujuan agen adalah memilih aksi yang memaksimalkan reward kumulatif selama horizon T , dengan memanfaatkan modul pemodelan lawan yang dilatih secara terpisah dari sinyal reward.

Model pemodelan lawan menghasilkan distribusi prediktif

$$p(a_{t+1}^{opp} \mid H_t),$$

yang kemudian digunakan dalam simulasi multi-langkah untuk mengestimasi nilai aksi kandidat agen.

4.3 Rancangan Algoritma Metode

4.3.1 Gambaran Umum

Algoritma yang digunakan dalam penelitian ini menggunakan LSTM dan Monte Carlo Simulation untuk memprediksi aksi lawan dalam horizon multi-langkah diperlihatkan pada gambar ???. Metode dimulai dengan Spesifikasi lingkungan simulasi dengan konfigurasi permainan, antarmuka permainan serta representasi riwayat yang digunakan. Selanjutnya, dilakukan desain populasi strategi lawan yang mencakup berbagai tipe strategi untuk memastikan keberagaman dinamika interaksi. Prosedur simulasi generasi data kemudian dijalankan untuk menghasilkan trajektori interaksi antara agen dan lawan berdasarkan konfigurasi yang telah ditetapkan. Trajektori yang dihasilkan kemudian diproses dalam tahap representasi dan persiapan dataset.

Setelah persiapan data selesai dilakukan perancangan model prediksi lawan menggunakan arsitektur LSTM untuk menangkap dependensi temporal dalam interaksi dilakukan pembentukan komponen LSTM seperti forget gate, input gate, dan output gate. Kemudian Model akan dikembangkan lebih lanjut agar dapat melakukan prediksi multi-langkah menggunakan konsep Monte Carlo Simulation secara recursive.

Selanjutnya model dilatih menggunakan protokol pelatihan yang mencakup pelatihan satu langkah dan pelatihan multi-langkah untuk pelatihan satu langkah akan

menggunakan fungsi objektif cross entropy loss satu langkah, sedangkan untuk pelatihan multi-langkah akan menggunakan fungsi objektif Negative-log-likelihood yang merupakan akumulasi cross-entropy sepanjang horizon dengan pembobotan Rank Order Centroid (ROC) di mana langkah terdekat diberi bobot lebih besar dibanding langkah yang lebih jauh dan sebaliknya.

Setelah model dilatih, dilakukan validasi model dengan melakukan hyperparameter tuning untuk memilih konfigurasi terbaik berdasarkan performa trajektorial dengan fungsi objektif yang dimaksimalkan adalah *confusion matrix*.


Setelah model terbaik dipilih, dilakukan pengujian model pada test set untuk mengukur generalisasi akhir model terhadap distribusi yang tidak terlihat selama pelatihan. Pengujian dilakukan baik pada skenario strategi yang telah terlihat selama pelatihan maupun pada strategi yang sepenuhnya baru, guna menguji kemampuan generalisasi terhadap dinamika interaksi yang tidak dikenal sebelumnya dengan *confusion matrix* sebagai metrik evaluasi.

Kemudian dilakukan interpretasi dan Analisis dari data pengujian yang didapatkan melalui pembelajaran ablasi. Analisis eksperimen difokuskan pada pengujian hipotesis utama penelitian, yaitu adanya potensi misalignment antara objektif prediksi satu langkah dan kebutuhan konsistensi trajektori dalam repeated games.

4.3.2 Spesifikasi Lingkungan Simulasi IPD

Penelitian ini membangun model prediktif aksi lawan pada permainan berulang dan memanfaatkannya untuk estimasi nilai aksi melalui simulasi multi-langkah (*Monte Carlo rollout*).

Konfigurasi Permainan Permainan yang digunakan adalah *Iterated Prisoner's Dilemma* (IPD) dua pemain dengan dua aksi diskrit yang tersedia, yaitu *C* (Cooperate) dan *D* (Defect), Struktur payoff mengikuti formulasi klasik Prisoner's Dilemma dengan Nilai numerik yang digunakan sesuai pada 3.3 Permainan dijalankan dengan horizon tetap sepanjang $T = 100$ langkah per episode. Penggunaan horizon tetap bertujuan untuk mengisolasi analisis stabilitas prediksi multi-langkah tanpa pengaruh terminasi stokastik. Kemudian diberikan Trembling Hand dengan probabilitas $\epsilon = 0.05$ untuk menghindari trajektori deterministik yang sepenuhnya dapat diprediksi, serta untuk menguji robustnes model terhadap deviasi lokal yang dapat menyebabkan propagasi error pada prediksi multi-langkah.



Gambar 4.2 Rancangan Algoritma Metode.

Antarmuka Permainan Akan dibuat antarmuka permainan yang memungkinkan interaksi antara agen dan lawan dalam bentuk sekuens aksi. Antarmuka ini akan menyediakan fungsi untuk menjalankan episode permainan, merekam histori interaksi, dan mengembalikan reward kumulatif berdasarkan matriks payoff. Permainan ini akan menggunakan antarmuka FE dan BE dari repositori github (ref gitub ncase 2017) yang telah dimodifikasi untuk kebutuhan penelitian ini.

Representasi Riwayat Interaksi Riwayat interaksi antara agen dan lawan direpresentasikan sebagai sekuens pasangan aksi sepanjang episode. Setiap langkah waktu t menghasilkan pasangan aksi (a_t^{agent}, a_t^{opp}) . Representasi ini memungkinkan model untuk menangkap pola interaksi temporal dan dependensi antar langkah waktu. Riwayat interaksi ini akan digunakan sebagai input untuk model prediksi lawan, yang kemudian menghasilkan distribusi prediktif atas aksi lawan pada langkah berikutnya. Serta ditambahkan variabel strategi agen dan lawan yang digunakan untuk mengidentifikasi strategi yang digunakan oleh agen dan lawan pada setiap langkah waktu. Variabel ini akan digunakan untuk mereproduksi trajectory langkah saat training, validasi, dan evaluasi model, untuk mengurangi bias yang mungkin muncul akibat perbedaan



Gambar 4.3 Trust oleh Ncase 2017.

strategi yang digunakan oleh agen dan lawan pada saat training, validasi, dan evaluasi model. sebagai contoh jika menggunakan strategi tft saja akan bias terhadap pelatihan untuk model akan memodelkan interaksi dengan trajectory tft meskipun agent bukan tft.

4.3.3 Desain Populasi Strategi Lawan

Desain populasi strategi lawan dalam penelitian ini bertujuan untuk membentuk lingkungan interaksi yang heterogen, sehingga model prediksi diuji pada spektrum perilaku yang representatif terhadap dinamika Iterated Prisoner's Dilemma (IPD). Landasan konseptual mengenai karakteristik masing-masing strategi telah dijelaskan pada bagian 3.4, sehingga pada bagian ini difokuskan pada rasionalisasi desain eksperimental dan konfigurasi populasi.

Populasi lawan terdiri atas seluruh strategi pada bagian 3.4 yang mencakup strategi deterministik berbasis memori (misalnya TFT, Grim Trigger), strategi adaptif berbasis pembelajaran daring (misalnya Hedge, OMD), serta strategi dengan pola siklik (misalnya Cycle). Keberagaman ini dirancang untuk menguji kemampuan model dalam menangkap berbagai dinamika interaksi, termasuk transisi rezim perilaku, pola siklik, dan adaptasi terhadap perubahan strategi lawan. Heterogenitas populasi dirancang untuk menguji tiga aspek utama model prediksi:

1. **Kemampuan identifikasi rezim perilaku**, khususnya pada strategi dengan titik perubahan (misalnya Grim Trigger).

2. **Kemampuan memodelkan dependensi temporal lebih dari satu langkah**, terutama pada strategi yang menghasilkan pola siklik.
3. **Kemampuan menangani dinamika adaptif non-deterministik**, seperti pada Hedge dan OMD.

Dengan komposisi ini, model tidak hanya diuji pada stabilitas jangka pendek (one-step prediction), tetapi juga pada konsistensi trajektori prediksi dalam horizon multi-langkah.

Setiap strategi dalam populasi diberikan proporsi yang seimbang pada tahap generasi data untuk menghindari bias distribusi kelas. Dalam setiap simulasi, lawan dipilih secara acak dari himpunan strategi dengan probabilitas seragam. Pendekatan ini memastikan bahwa performa model tidak dipengaruhi oleh dominasi strategi tertentu dalam dataset pelatihan maupun pengujian.

Jika diperlukan, eksperimen tambahan dapat dilakukan dengan distribusi tidak seimbang untuk menguji robustnes model terhadap pergeseran distribusi populasi (distribution shift).

4.3.4 Prosedur dan Simulasi Generasi Data

Data penelitian diperoleh melalui simulasi Iterated Prisoner's Dilemma (IPD) menggunakan populasi strategi lawan yang telah didefinisikan pada bagian sebelumnya pada 4.3.3. Prosedur ini bertujuan untuk menghasilkan trajektori interaksi temporal yang dapat digunakan sebagai dasar pembentukan dataset prediksi multi-langkah.

Setiap simulasi dijalankan dalam bentuk episode dengan panjang horizon tetap sebesar $T = 100$ langkah waktu. Pada setiap langkah t , agent dan lawan secara simultan memilih aksi $a_t \in \{C, D\}$. Satu episode menghasilkan sekuens interaksi: Setiap interaksi permainan direpresentasikan sebagai sebuah trajektori yang memuat identitas strategi lawan serta sekuens aksi kedua pemain. Misalkan $\mathcal{S}$ adalah himpunan strategi lawan yang digunakan dalam eksperimen. Untuk setiap strategi $s \in \mathcal{S}$, dilakukan simulasi sebanyak R ronde independen.

Setiap ronde ke- r menghasilkan satu trajektori

$$\tau^{(s,r)} = \left(s, \{(a_1^{agent}, a_1^{opp}), (a_2^{agent}, a_2^{opp}), \dots, (a_T^{agent}, a_T^{opp})\} \right),$$

di mana strategi s bersifat tetap sepanjang trajektori dan tidak berubah antar waktu.

Keseluruhan dataset didefinisikan sebagai

$$\mathcal{D} = \bigcup_{s \in \mathcal{S}} \bigcup_{r=1}^R \tau^{(s,r)}.$$

Untuk setiap tipe strategi lawan, jumlah ronde R ditetapkan konstan guna menjaga keseimbangan distribusi data antar strategi serta memastikan stabilitas variasi trajektori yang diamati.

Untuk menghindari trajektori deterministik yang sepenuhnya dapat diprediksi, diterapkan mekanisme *trembling hand* dengan probabilitas $\epsilon = 0.05$. Pada setiap langkah waktu, baik agent maupun lawan memiliki peluang sebesar 5% untuk secara acak membalik aksi yang dipilih.

Secara formal, jika aksi asli adalah a_t , maka aksi aktual yang dieksekusi $\tilde{a}_t$ didefinisikan sebagai:

$$\tilde{a}_t = \begin{cases} a_t, & \text{dengan probabilitas } 1 - \epsilon, \\ \text{flip}(a_t), & \text{dengan probabilitas } \epsilon. \end{cases}$$

Penambahan noise ini memiliki dua fungsi utama:

1. Menghindari konvergensi deterministik sempurna pada strategi berbasis memori seperti TFT atau Grim Trigger.
2. Menguji robustnes model terhadap deviasi lokal yang dapat menyebabkan propagasi error pada prediksi multi-langkah.

Untuk setiap episode, seluruh pasangan aksi agent dan lawan pada setiap langkah waktu disimpan sebagai satu trajektori lengkap. Dataset akhir terdiri atas kumpulan trajektori:

$$\mathcal{D} = \{\tau^{(1)}, \tau^{(2)}, \dots, \tau^{(N)}\},$$

dengan setiap trajektori $\tau^{(i)}$ berupa urutan pasangan aksi sepanjang 100 langkah waktu.

Struktur data ini memungkinkan pembentukan sampel pelatihan dalam bentuk:

- Prediksi satu langkah ke depan,

- Prediksi multi-langkah dengan horizon k ,
- Prediksi trajektori penuh berbasis conditioning pada histori parsial.

Karena data dihasilkan melalui interaksi berulang dalam horizon panjang dengan adanya noise, trajektori yang terbentuk mencerminkan kombinasi antara:

- dinamika deterministik strategi,
- transisi rezim akibat hukuman atau adaptasi,
- deviasi stokastik akibat trembling hand.

Kombinasi ini penting untuk mengevaluasi fenomena akumulasi error pada prediksi multi-langkah serta menguji apakah model yang dioptimalkan untuk objektif satu langkah mampu mempertahankan konsistensi trajektori dalam horizon yang lebih panjang.

4.3.5 Representasi dan Persiapan Dataset

Bagian ini menjelaskan bagaimana trajektori hasil simulasi dikonversi menjadi format yang dapat digunakan untuk pelatihan model prediksi.

Representasi Dasar Aksi dan Strategi Lawan Setiap episode interaksi tidak hanya menyimpan histori aksi, tetapi juga identitas strategi lawan dalam bentuk enumerasi diskret.

Misalkan:

$$s^{opp} \in \mathcal{S}_{opp}$$

adalah label strategi lawan, dengan

$$\mathcal{S}_{opp} = \{S_1, S_2, \dots, S_K\}.$$

Pada setiap langkah waktu t , interaksi direpresentasikan sebagai vektor dua dimensi:

$$x_t = \begin{bmatrix} a_t^{agent} \\ a_t^{opp} \end{bmatrix}, \quad a_t^{agent}, a_t^{opp} \in \{C, D\}.$$

Untuk kebutuhan komputasional, aksi dikodekan dalam bentuk numerik biner, misalnya:

$$C = 0, \quad D = 1.$$

Satu episode sepanjang T langkah direpresentasikan sebagai matriks:

$$X = [x_1, x_2, \dots, x_T]^\top \in \mathbb{R}^{T \times 2}.$$

Dengan demikian, setiap trajektori merupakan deret waktu dua kanal (*two-channel time series*) yang memuat histori aksi kedua pemain.

Jika strategi lawan digunakan sebagai fitur eksplisit dalam model, maka dilakukan transformasi one-hot:

$$\phi(s^{opp}) \in \{0, 1\}^K.$$

Input pada setiap waktu t menjadi:

$$\tilde{x}_t = \begin{bmatrix} a_t^{agent} \\ a_t^{opp} \\ \phi(s^{opp}) \end{bmatrix}.$$

Dalam hal ini, satu episode direpresentasikan sebagai:

$$\tilde{X} \in \mathbb{R}^{T \times (2+K)}.$$

Jika strategi tidak diberikan sebagai fitur, maka s^{opp} tetap disimpan sebagai metadata untuk keperluan analisis, evaluasi per strategi, dan studi ablation, namun tidak dimasukkan ke dalam tensor input model.

Padding Awal Sebelum Turn Pertama Untuk mengakomodasi skenario prediksi berbasis *lag window* sepanjang k langkah, ditambahkan padding awal sepanjang k langkah sebelum turn pertama.

Didefinisikan vektor nol sebagai:

$$\mathbf{O} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Maka trajektori yang telah dipadding menjadi:

$$\tilde{X} = [\underbrace{\mathbf{O}, \mathbf{O}, \dots, \mathbf{O}}_{k \text{ kali}}, x_1, x_2, \dots, x_T]^\top.$$

Padding ini memastikan bahwa pada saat $t = 1$, model tetap menerima window historis sepanjang k langkah, meskipun histori aktual permainan belum tersedia.

Secara konseptual, padding nol merepresentasikan kondisi sebelum permainan dimulai, sehingga model dapat mempelajari dinamika strategi awal tanpa kehilangan konsistensi dimensi input.

Augmentasi Simetri Peran Untuk meningkatkan keberagaman distribusi interaksi dan mengurangi bias peran (*role bias*), dilakukan augmentasi data melalui pertukaran dimensi:

$$x'_t = \begin{bmatrix} a_t^{opp} \\ a_t^{agent} \end{bmatrix}.$$

Artinya, setiap trajektori asli τ menghasilkan satu trajektori tambahan τ' dengan peran agent dan lawan dipertukarkan.

Augmentasi ini berasumsi bahwa struktur permainan bersifat simetris terhadap pertukaran pemain. Secara eksperimental, langkah ini bertujuan untuk:

- meningkatkan ukuran dataset,
- mendorong model mempelajari pola interaksi, bukan identitas tetap pemain,
- meningkatkan generalisasi terhadap variasi distribusi lawan.

Pembentukan Pasangan Input–Target Dari trajektori yang telah dipadding $\tilde{X}$, dibentuk pasangan input-target berbasis window sepanjang k langkah sebelumnya.

Untuk prediksi satu langkah:

$$(\tilde{x}_{t-k}, \dots, \tilde{x}_{t-1}) \rightarrow a_t^{opp}.$$

Untuk prediksi multi-langkah dengan horizon h :

$$(\tilde{x}_{t-k}, \dots, \tilde{x}_{t-1}) \rightarrow (a_t^{opp}, \dots, a_{t+h-1}^{opp}).$$

Dengan pendekatan ini, setiap sampel pelatihan selalu memiliki dimensi input tetap sebesar $k \times 2$, termasuk pada fase awal permainan.

Pengacakan dan Pembagian Data Seluruh sampel yang terbentuk kemudian dia-cak secara acak (*random shuffle*) untuk menghilangkan korelasi urutan antar episode. Setelah proses pengacakan, dataset dibagi menjadi:

- 70% data pelatihan (*training set*),
- 15% data validasi (*validation set*),
- 15% data uji (*test set*).

Pembagian dilakukan pada level trajektori (bukan pada level langkah waktu) untuk mencegah kebocoran informasi temporal antar subset. Dengan demikian, tidak terdapat fragmen dari satu episode yang muncul sekaligus pada data pelatihan dan validasi.

Implikasi terhadap Evaluasi Model Representasi dua kanal, padding awal, dan augmentasi simetri memungkinkan model menangkap dependensi silang antar aksi pemain sejak fase awal permainan.

Pemisahan berbasis trajektori memastikan evaluasi dilakukan pada distribusi interaksi yang benar-benar tidak terlihat selama pelatihan, sehingga mengurangi risiko overfitting berbasis memorisasi pola spesifik episode.

4.3.6 Perancangan Model Prediksi Lawan

Model prediksi lawan dibangun menggunakan arsitektur Long Short-Term Memory (LSTM) sebagai encoder temporal untuk menangkap dependensi historis dalam interaksi IPD. Arsitektur terdiri atas:

- Satu lapisan LSTM dengan *hidden size* 64,
- Lapisan linear sebagai proyeksi ke ruang aksi lawan,
- Fungsi softmax untuk menghasilkan distribusi probabilitas atas aksi $\{C, D\}$.

Diberikan histori hingga waktu t :

$$h_t = \text{LSTM}(x_1, \dots, x_t), \quad \hat{y}_{t+1} = \text{softmax}(Wh_t + b),$$

dengan $\hat{y}_{t+1}$ distribusi prediksi aksi lawan.

Model Satu Langkah Model satu langkah dioptimalkan untuk memprediksi aksi lawan pada waktu $t + 1$ berdasarkan histori hingga waktu t .

Fungsi objektif yang digunakan adalah *cross-entropy loss* satu langkah:

$$\mathcal{L}_{1-step} = - \sum_{t=1}^{T-1} y_{t+1} \log \hat{y}_{t+1}.$$

Optimisasi ini mendorong model memaksimalkan akurasi prediksi lokal tanpa mempertimbangkan konsistensi trajektori jangka panjang.

Model Multi Langkah Berbeda dengan model satu langkah, model multi langkah dirancang untuk mempelajari prediksi trajektori lawan sepanjang horizon k secara eksplisit.

Pada skenario ini, pelatihan dilakukan menggunakan *teacher forcing*. Artinya, pada setiap langkah dalam horizon, input yang diberikan ke LSTM tetap menggunakan aksi aktual (ground-truth), bukan hasil prediksi model.

Untuk setiap histori awal hingga waktu t , model menghasilkan distribusi:

$$(\hat{y}_{t+1}, \hat{y}_{t+2}, \dots, \hat{y}_{t+k}),$$

dengan input rekursif:

$$x_{t+i} = \begin{bmatrix} a_{t+i}^{agent, oracle} \\ a_{t+i}^{opp, groundtruth} \end{bmatrix}.$$

Oracle pada konteks ini merepresentasikan agent yang diketahui secara deterministik dalam simulasi. Oracle digunakan untuk menghasilkan aksi agent yang konsisten terhadap trajektori ground-truth lawan selama proses pelatihan.

Fungsi loss multi langkah didefinisikan sebagai akumulasi cross-entropy sepanjang horizon:

$$\mathcal{L}_{multi-step} = - \sum_{i=1}^k y_{t+i} \log \hat{y}_{t+i}.$$

Dengan formulasi ini, model secara eksplisit dioptimalkan untuk mempertahankan konsistensi prediksi sepanjang beberapa langkah, bukan hanya pada langkah berikutnya.

Perbedaan Konseptual Kedua Model Perbedaan utama antara kedua pendekatan terletak pada:

- **Ruang optimisasi:** satu langkah bersifat lokal, sedangkan multi langkah bersifat trajektorial.
- **Distribusi error:** model multi langkah menerima sinyal kesalahan dari seluruh horizon k , sehingga lebih sensitif terhadap dinamika jangka menengah.
- **Tujuan pembelajaran:** model satu langkah meminimalkan error prediksi langsung, sedangkan model multi langkah meminimalkan deviasi trajektori.

Evaluasi Generalisasi Untuk menguji robustnes dan generalisasi, kedua model dievaluasi pada strategi lawan yang tidak terlihat selama pelatihan. Evaluasi dilakukan pada:

- akurasi satu langkah,
- akurasi trajektori multi langkah,
- degradasi performa seiring bertambahnya horizon prediksi.

Pendekatan ini memungkinkan analisis empiris terhadap potensi misalignment antara objektif satu langkah dan kebutuhan prediksi trajektori dalam repeated games.

4.3.7 Protokol Pelatihan

Pelatihan model dilakukan dalam dua skema utama: (1) pelatihan satu langkah dan (2) pelatihan multi langkah. Kedua skema menggunakan arsitektur yang sama, namun berbeda dalam objektif optimisasi dan mekanisme pembentukan loss.

Pelatihan Satu Langkah Pada tahap ini, model dioptimalkan untuk memprediksi aksi lawan pada waktu $t + 1$ berdasarkan histori hingga waktu t .

Fungsi objektif yang digunakan adalah *cross-entropy loss* satu langkah yang didefinisikan pada

Optimisasi dilakukan menggunakan algoritma Adam dengan parameter pembelajaran yang ditetapkan sebelumnya. Pelatihan berlangsung selama sejumlah epoch tertentu dengan *batch size* tetap, serta validasi dilakukan pada setiap epoch untuk memantau konvergensi dan mencegah overfitting.

Model yang dihasilkan merepresentasikan baseline prediksi lokal tanpa optimisasi eksplisit terhadap konsistensi trajektori.

Pelatihan Multi Langkah Pada tahap ini, model dilatih untuk memprediksi trajektori aksi lawan sepanjang horizon k menggunakan mekanisme *teacher forcing*.

Untuk setiap histori hingga waktu t , model menghasilkan prediksi:

$$(\hat{y}_{t+1}, \hat{y}_{t+2}, \dots, \hat{y}_{t+k}).$$

Selama pelatihan, input pada setiap langkah dalam horizon menggunakan aksi ground-truth (teacher forcing). Namun, untuk membentuk trajektori interaksi dua arah, digunakan oracle agent untuk menghasilkan aksi respon terhadap aksi lawan pada setiap langkah. Dengan demikian, dinamika interaksi tetap konsisten terhadap kebijakan agent yang diasumsikan diketahui.

Fungsi Loss Multi Langkah Loss dasar didefinisikan sebagai akumulasi cross-entropy sepanjang horizon:

$$\mathcal{L}_{multi} = - \sum_{i=1}^k w_i y_{t+i} \log \hat{y}_{t+i},$$

dengan w_i merupakan bobot pada langkah ke- i .

Skema Pembobotan Rank Order Centroid (ROC) Untuk mengontrol kontribusi error pada tiap langkah, digunakan pembobotan berbasis Rank Order Centroid (ROC).

Bobot ROC untuk horizon k didefinisikan sebagai:

$$w_i = \frac{1}{k} \sum_{j=i}^k \frac{1}{j},$$

yang kemudian dinormalisasi sehingga:

$$\sum_{i=1}^k w_i = 1.$$

Dua varian pembobotan digunakan:

- **ROC Newest:** langkah terdekat ($i = 1$) diberi bobot terbesar.

- **ROC Latest:** langkah terjauh ($i = k$) diberi bobot terbesar (urutan dibalik).

Sebagai pembanding, digunakan juga skema tanpa ROC, yaitu bobot seragam:

$$w_i = \frac{1}{k}.$$

Konfigurasi Eksperimen Model dilatih dengan kombinasi berikut:

- Teacher Forcing + uniform, $k = 10$,
- Teacher Forcing + ROC Newest, $k = 10$
- Teacher Forcing + ROC Latest, $k = 10$

Seluruh loss dinormalisasi terhadap jumlah langkah horizon agar dapat dibandingkan secara adil antar konfigurasi k .

Evaluasi Closed-Loop Meskipun pelatihan menggunakan teacher forcing, evaluasi dilakukan secara rekursif (*closed-loop rollout*). Pada tahap ini:

1. Model memprediksi aksi lawan pada langkah berikutnya.
2. Oracle agent menghasilkan aksi respon berdasarkan prediksi tersebut.
3. Pasangan aksi hasil prediksi dimasukkan kembali sebagai input.
4. Proses diulang hingga horizon k .

Loss trajektori kemudian dihitung terhadap ground-truth untuk menilai akumulasi error akibat propagasi prediksi sendiri.

Pendekatan ini memungkinkan analisis empiris terhadap potensi misalignment antara objektif satu langkah dan kebutuhan prediksi trajektori dalam repeated games.

4.3.8 Protokol Pelatihan

Pelatihan model dilakukan dalam dua skema utama: (1) pelatihan satu langkah dan (2) pelatihan multi langkah. Kedua skema menggunakan arsitektur yang sama, namun berbeda dalam objektif optimisasi dan mekanisme pembentukan loss.

Pelatihan Satu Langkah Pada tahap ini, model dioptimalkan untuk memprediksi aksi lawan pada waktu $t + 1$ berdasarkan histori hingga waktu t .

Fungsi objektif yang digunakan adalah *cross-entropy loss* satu langkah:

$$\mathcal{L}_{1-step} = -\frac{1}{T-1} \sum_{t=1}^{T-1} y_{t+1} \log \hat{y}_{t+1}.$$

Optimisasi dilakukan menggunakan algoritma Adam dengan parameter pembelajaran yang ditetapkan sebelumnya. Pelatihan berlangsung selama sejumlah epoch tertentu dengan *batch size* tetap, serta validasi dilakukan pada setiap epoch untuk memantau konvergensi dan mencegah overfitting.

Model yang dihasilkan merepresentasikan baseline prediksi lokal tanpa optimisasi eksplisit terhadap konsistensi trajektori.

Pelatihan Multi Langkah Pada tahap ini, model dilatih untuk memprediksi trajektori aksi lawan sepanjang horizon k menggunakan mekanisme *teacher forcing*.

Untuk setiap histori hingga waktu t , model menghasilkan prediksi:

$$(\hat{y}_{t+1}, \hat{y}_{t+2}, \dots, \hat{y}_{t+k}).$$

Selama pelatihan, input pada setiap langkah dalam horizon menggunakan aksi ground-truth (teacher forcing). Namun, untuk membentuk trajektori interaksi dua arah, digunakan oracle agent untuk menghasilkan aksi respon terhadap aksi lawan pada setiap langkah. Dengan demikian, dinamika interaksi tetap konsisten terhadap kebijakan agent yang diasumsikan diketahui.

Fungsi Loss Multi Langkah Loss dasar didefinisikan sebagai akumulasi cross-entropy sepanjang horizon:

$$\mathcal{L}_{multi} = -\sum_{i=1}^k w_i y_{t+i} \log \hat{y}_{t+i},$$

dengan w_i merupakan bobot pada langkah ke- i .

Skema Pembobotan Rank Order Centroid (ROC) Untuk mengontrol kontribusi error pada tiap langkah, digunakan pembobotan berbasis Rank Order Centroid (ROC).

Bobot ROC untuk horizon k didefinisikan sebagai:

$$w_i = \frac{1}{k} \sum_{j=i}^k \frac{1}{j},$$

yang kemudian dinormalisasi sehingga:

$$\sum_{i=1}^k w_i = 1.$$

Dua varian pembobotan digunakan:

- **ROC Newest:** langkah terdekat ($i = 1$) diberi bobot terbesar.
- **ROC Latest:** langkah terjauh ($i = k$) diberi bobot terbesar (urutan dibalik).

Sebagai pembanding, digunakan juga skema tanpa ROC, yaitu bobot seragam:

$$w_i = \frac{1}{k}.$$

Konfigurasi Eksperimen Model dilatih dengan kombinasi berikut:

- Teacher Forcing + uniform, $k = 10$,
- Teacher Forcing + ROC Newest, $k = 10$
- Teacher Forcing + ROC Latest, $k = 10$

Seluruh loss dinormalisasi terhadap jumlah langkah horizon agar dapat dibandingkan secara adil antar konfigurasi k .

Evaluasi Closed-Loop Meskipun pelatihan menggunakan teacher forcing, evaluasi dilakukan secara rekursif (*closed-loop rollout*). Pada tahap ini:

1. Model memprediksi aksi lawan pada langkah berikutnya.
2. Oracle agent menghasilkan aksi respon berdasarkan prediksi tersebut.
3. Pasangan aksi hasil prediksi dimasukkan kembali sebagai input.
4. Proses diulang hingga horizon k .

Loss trajektori kemudian dihitung terhadap ground-truth untuk menilai akumulasi error akibat propagasi prediksi sendiri.

4.3.9 Protokol Validasi

Validasi dilakukan untuk memilih konfigurasi hiperparameter terbaik berdasarkan performa prediksi trajektorial pada data yang tidak digunakan selama pelatihan.

Evaluasi dilakukan pada *validation set* dengan tetap mempertahankan pemisahan berbasis trajektori, sehingga tidak terdapat fragmen episode yang muncul pada data pelatihan.

Fokus evaluasi adalah konsistensi prediksi multi-langkah terhadap aksi lawan. Untuk setiap horizon h , dihitung:

- *Confusion matrix* per langkah prediksi,
- Akurasi per langkah,
- Akurasi kumulatif sepanjang horizon.

Misalkan target horizon adalah h , maka akurasi kumulatif didefinisikan sebagai:

$$Acc_{cum} = \frac{1}{h} \sum_{i=1}^h Acc_i,$$

dengan Acc_i adalah akurasi pada langkah prediksi ke- i .

Karena jumlah kombinasi hiperparameter yang diuji cukup besar, proses tuning dilakukan secara hierarkis dalam empat tahap utama:

1. Tuning Stabilitas Optimisasi,
2. Tuning Temporal Modelling,
3. Tuning Kapasitas Model,
4. Tuning Fungsi Loss.

Pada setiap tahap, parameter lain dikunci pada nilai terbaik hasil tahap sebelumnya.

Konfigurasi Default Konfigurasi awal (baseline) yang digunakan sebelum tuning adalah sebagai berikut:

1. Steps (horizon) = 10,
2. Window size (k) = 10,
3. Hidden units = 64,
4. Jumlah layer = 1,
5. Dropout = 0.0,
6. Teacher Forcing = True,
7. Pembobotan ROC = Uniform,
8. Epoch = 25.

Pada setiap tahap tuning, hanya parameter yang sedang diuji yang divariasikan, sementara parameter lain dipertahankan pada konfigurasi terbaik sementara.

Tahap 1: Tuning Stabilitas Optimisasi Tahap ini bertujuan memastikan proses pelatihan konvergen secara stabil dan tidak mengalami divergensi gradien.

Parameter yang diuji:

1. Learning Rate $\in \{0.001, 0.0005, 0.0001\}$,
2. Batch Size $\in \{16, 32, 64, 128\}$.

Kriteria pemilihan didasarkan pada stabilitas kurva loss serta akurasi validasi tertinggi.

Tahap 2: Tuning Temporal Modelling Tahap ini mengevaluasi kemampuan model dalam menangkap dependensi temporal.

Parameter yang diuji:

1. Window size (k) $\in \{5, 10, 15\}$,
2. Steps (horizon prediksi) $\in \{1, 5, 10\}$.

Evaluasi difokuskan pada degradasi akurasi sepanjang horizon serta kestabilan prediksi multi-langkah.

Tahap 3: Tuning Kapasitas Model Tahap ini menguji kapasitas representasional model terhadap kompleksitas pola interaksi.

Parameter yang diuji:

1. Hidden units $\in \{32, 64, 128\}$,
2. Jumlah layer $\in \{1, 2\}$,
3. Dropout $\in \{0.0, 0.1, 0.5\}$.

Pemilihan konfigurasi mempertimbangkan trade-off antara performa validasi dan indikasi overfitting.

Tahap 4: Tuning Fungsi Loss dan Skema Pembobotan Tahap terakhir mengevaluasi pengaruh mekanisme pembelajaran sekuensial terhadap kualitas prediksi trajektorial.

Parameter yang diuji:

1. Teacher Forcing $\in \{\text{True}, \text{False}\}$,
2. Skema Pembobotan ROC:
 - (a) Uniform,
 - (b) Bobot lebih besar pada langkah awal,
 - (c) Bobot lebih besar pada langkah akhir.

Jika h adalah horizon prediksi, maka fungsi loss berbobot didefinisikan sebagai:

$$\mathcal{L} = \sum_{i=1}^h w_i \cdot \mathcal{L}_i, \quad \text{dengan} \quad \sum_{i=1}^h w_i = 1.$$

Skema bobot awal menekankan akurasi pada fase pembukaan trajektori, sedangkan skema bobot akhir menekankan stabilitas prediksi jangka panjang.

Konfigurasi akhir dipilih berdasarkan performa validasi terbaik sebelum dievaluasi secara final pada *test set*.

4.3.10 Protokol Evaluasi

Evaluasi dilakukan dalam dua skema utama, yaitu evaluasi terpisah (*decoupled evaluation*) dan evaluasi terpasang (*coupled evaluation*). Kedua skema ini dirancang untuk mengukur perbedaan performa model pada prediksi lokal satu langkah dan pada dinamika interaksi trajektorial multi-langkah.

Evaluasi Terpasang (Coupled) Evaluasi terpasang dilakukan menggunakan prediksi multi langkah secara rekursif (*closed-loop rollout*). Pada skema ini, model:

1. Memprediksi aksi lawan pada langkah berikutnya,
2. Oracle agent menghasilkan respon terhadap prediksi tersebut,
3. Hasil pasangan aksi dimasukkan kembali sebagai input,
4. Proses diulang hingga horizon k .

Dengan pendekatan ini, terbentuk trajektori prediksi sepanjang horizon k yang kemudian dibandingkan dengan trajektori ground-truth.

Metrik evaluasi meliputi:

- **Akurasi Multi Langkah:**

$$\text{Acc}_k = \frac{1}{k} \sum_{i=1}^k \mathbf{1}(\hat{a}_{t+i}^{\text{opp}} = a_{t+i}^{\text{opp}}),$$

yang mengukur konsistensi prediksi sepanjang horizon.

- **Dynamic Regret**, yaitu selisih antara reward kumulatif yang diperoleh agent berdasarkan trajektori prediksi dibandingkan dengan reward pada trajektori aktual:

$$\text{Regret}_k = R_k^{\text{oracle}} - R_k^{\text{pred}}.$$

- **Reward Kumulatif**, yaitu total payoff agent sepanjang horizon k berdasarkan interaksi dengan trajektori prediksi.

Metrik-metrik ini menangkap dampak kesalahan prediksi terhadap kualitas interaksi strategis dalam repeated game.

Validasi dan Pengujian Perbandingan performa dilakukan pada:

- **Validation set**, untuk memilih konfigurasi terbaik berdasarkan performa trajektorial.
- **Test set**, untuk mengukur generalisasi akhir model terhadap distribusi yang tidak terlihat selama pelatihan.

Evaluasi dilakukan baik pada skenario strategi yang telah terlihat selama pelatihan maupun pada strategi yang sepenuhnya baru, guna menguji kemampuan generalisasi terhadap dinamika interaksi yang tidak dikenal sebelumnya.

4.3.11 Analisis Eksperimen

Analisis eksperimen difokuskan pada pengujian hipotesis utama penelitian, yaitu adanya potensi misalignment antara objektif prediksi satu langkah dan kebutuhan konsistensi trajektori dalam repeated games.

Sensitivitas terhadap Perubahan Fase Strategi Strategi dengan perubahan rezim (misalnya strategi dengan mekanisme hukuman permanen atau semi-permanen) dianalisis secara khusus untuk mengukur:

- Waktu deteksi perubahan fase,
- Lonjakan error pasca transisi,
- Dampak kesalahan awal terhadap trajektori jangka menengah.

Analisis ini bertujuan untuk mengidentifikasi apakah model mampu menangkap dinamika non-stasioner dan apakah pembobotan ROC mempengaruhi stabilitas prediksi pada fase transisi.

Strategi Deterministik vs Adaptif Strategi deterministik dan strategi adaptif dianalisis secara terpisah untuk mengukur robustnes model terhadap dinamika yang berbeda.

Perbandingan dilakukan berdasarkan:

- Confusion matrix per kategori strategi,

- Rata-rata NLL,
- Dynamic regret,
- Average payoff.

Hipotesis yang diuji adalah bahwa strategi adaptif menghasilkan degradasi performa yang lebih besar pada skema one-step dibandingkan model multi-step berbobot, khususnya pada horizon lebih panjang.

Pelaporan Hasil Hasil eksperimen disajikan dalam bentuk tabel komparatif yang memuat:

- Confusion matrix untuk evaluasi terpisah,
- Nilai rata-rata dan standar deviasi NLL,
- Dynamic regret pada horizon $k = 5$ dan $k = 10$,
- Average payoff agent pada evaluasi terpasang.

Selain tabel agregat, analisis per-strategi juga ditampilkan untuk mengidentifikasi pola kegagalan spesifik.

Interpretasi hasil difokuskan pada hubungan antara objektif pelatihan (one-step vs multi-step dengan variasi ROC) dan performa trajektorial aktual dalam interaksi repeated game.

BAB V

JADWAL PENELITIAN

5.1 Jadwal Penelitian

Penelitian ini direncanakan berlangsung selama dua bulan (8 minggu) dengan pembagian tahapan yang terstruktur sesuai dengan fokus utama penelitian, yaitu:

1. Analisis stabilitas prediksi multi-langkah (multi-step forecasting)

Penyusunan jadwal dilakukan berdasarkan dependensi antar komponen sistem, dimulai dari pembangunan lingkungan deterministik, implementasi model prediktif, hingga evaluasi stabilitas dan analisis perencanaan berbasis rollout.

5.1.1 Rencana Waktu Pelaksanaan

Rencana waktu pelaksanaan penelitian selama enam bulan ditunjukkan pada Tabel berikut.

Tabel 5.1 Rencana Jadwal Penelitian (2 Bulan / 8 Minggu)

Kegiatan	M1	M2	M3	M4	M5	M6	M7	M8
Spesifikasi lingkungan IPD	✓	✓						
Desain Populasi Strategi Lawan	✓	✓						
Prosedur simulasi dan generasi data		✓	✓					
Representasi dan persiapan dataset			✓	✓				
Perancangan model prediksi (arsitektur)			✓	✓				
Implementasi protokol pelatihan				✓	✓			
Validasi (Confusion Matrix, NLL, CE)						✓		
Evaluasi (Confusion Matrix, NLL, CE)						✓		
Analisis eksperimen dan komparasi model							✓	✓
Penulisan dan revisi laporan	✓	✓	✓	✓	✓	✓	✓	✓

5.1.2 Dependensi dan Risiko

Beberapa dependensi penting dalam penelitian ini:

- Implementasi rollout planning bergantung pada stabilitas model prediktif pada evaluasi open-loop.
- Evaluasi closed-loop tidak dapat dilakukan sebelum estimator nilai $\hat{Q}$ tervalidasi.
- Studi ablasi dilakukan setelah konfigurasi utama sistem stabil.

Risiko utama penelitian meliputi:

- Akumulasi error prediksi pada horizon panjang

- Kompleksitas komputasi akibat $\mathcal{O}(N \cdot n \cdot k \cdot M)$
- Ketidakstabilan model pada lawan non-stasioner

Strategi mitigasi meliputi pengujian bertahap (offline $\rightarrow$ open-loop $\rightarrow$ closed-loop), monitoring konvergensi estimator, serta pembatasan parameter eksperimen untuk menjaga efisiensi komputasi.

BAB VI

KESIMPULAN DAN SARAN

Penelitian ini mengkaji potensi ketidaksesuaian antara formulasi prediksi satu-langkah dalam *opponent modelling* dan kebutuhan perencanaan strategis multi-langkah dalam permainan berulang seperti *Iterated Prisoner's Dilemma*. Melalui implementasi modul prediksi yang difokuskan pada *k-step forecasting*, penelitian ini mengevaluasi bagaimana horizon prediksi memengaruhi akurasi estimasi distribusi aksi lawan serta dinamika kesalahan prediksi antar-langkah.

Hasil eksperimen diharapkan menunjukkan bahwa perluasan horizon prediksi memberikan representasi yang lebih informatif terhadap pola strategi lawan yang bergantung pada beberapa langkah interaksi, meskipun tetap terdapat trade-off dalam bentuk peningkatan kompleksitas dan potensi propagasi kesalahan. Temuan ini mengindikasikan bahwa pemilihan objektif pembelajaran dalam *opponent modelling* perlu mempertimbangkan keselarasan dengan horizon perencanaan strategis yang digunakan agen.

Secara keseluruhan, penelitian ini diharapkan memberikan dasar eksperimental untuk memahami peran horizon prediksi dalam interaksi strategis berulang, tanpa melakukan asumsi terhadap struktur internal atau parametrik dari algoritma lawan.

DAFTAR PUSTAKA

- Axelrod, R. dan Hamilton, W. D. (1981), *The Evolution of Cooperation*,
- Barron, F. H. dan Barrett, B. E. (1996), Decision quality using ranked attribute weights, *Management Science* 42.11, pp. 1515–1523.
- Bonanno, G., 2024, *Game theory: volume 1: basic concepts*, Kindle Direct Publishing, Place of publication not identified.
- De Weerd, H., Verbrugge, R., dan Verheij, B. (Oct. 2022), Higher-order theory of mind is especially useful in unpredictable negotiations, *Autonomous Agents and Multi-Agent Systems* 36.2, p. 30.
- Di, C., Zhou, Q., Shen, J., Wang, J., Zhou, R., dan Wang, T. (2023), The coupling effect between the environment and strategies drives the emergence of group cooperation, *Chaos, Solitons & Fractals* 176, p. 114138.
- Elhamer, Z., Suzuki, R., dan Arita, T. (2020), The effects of population size and information update rates on the emergent patterns of cooperative clusters in a large-scale social particle swarm model, *Artificial Life and Robotics* 25.1, Type: Article, pp. 149–158.
- Freire, I. T., Arsiwalla, X. D., Puigbò, J. Y., dan Verschure, P. (2023), Modeling Theory of Mind in Dyadic Games Using Adaptive Feedback Control, *Information (Switzerland)* 14.8, Type: Article.
- Gómez, A. L. d. A., Sierra, C., dan Sabater-Mir, J. (2025), Grounded predictions of teamwork as a one-shot game: A multiagent multi-armed bandits approach, *Artificial Intelligence* 341, p. 104307.
- Hernandez-Leal, P., Kartal, B., dan Taylor, M. E. (Nov. 2019), A Survey and Critique of Multiagent Deep Reinforcement Learning, *Autonomous Agents and Multi-Agent Systems* 33.6, pp. 750–797.
- Hochreiter, S. dan Schmidhuber, J. (Nov. 1, 1997), Long Short-Term Memory, *Neural Computation* 9.8, pp. 1735–1780.
- Hu, Y., Han, C., Li, H., dan Guo, T. (2023), Modeling opponent learning in multiagent repeated games, *Applied Intelligence* 53.13, Type: Article, pp. 17194–17210.

- Jin, Y., Wei, S., dan Montana, G. (Aug. 2025), Achieving collective welfare in multi-agent reinforcement learning via suggestion sharing, *Machine Learning* 114.8, p. 190.
- Li, K., Huang, W., Li, C., dan Deng, X. (2025), Exploiting a No-Regret Opponent in Repeated Zero-Sum Games, *Journal of Shanghai Jiaotong University (Science)* 30.2, Type: Article, pp. 385–398.
- Lv, M., Liu, J., Guo, B., Ding, Y., Zhang, Y., dan Yu, Z. (Sept. 2023), Inducing Coordination in Multi-Agent Repeated Game through Hierarchical Gifting Policies, *2023 IEEE 20th International Conference on Mobile Ad Hoc and Smart Systems (MASS)*, 2023 IEEE 20th International Conference on Mobile Ad Hoc and Smart Systems (MASS), ISSN: 2155-6814, pp. 279–287.
- Nashed, S. B. dan Zilberstein, S. (2022), A Survey on Opponent Modeling in Adversarial Domains,
- Perera, I., Nijs, F. de, dan Garcia, J. (2025), Learning to cooperate against ensembles of diverse opponents, *Neural Computing and Applications* 37.23, Type: Article, pp. 18835–18849.
- Qiao, X., Han, C., dan Guo, T. (Dec. 2024), O2M: Online Opponent Modeling in Online General-Sum Matrix Games, *2024 4th International Conference on Artificial Intelligence, Robotics, and Communication (ICAIRC)*, 2024 4th International Conference on Artificial Intelligence, Robotics, and Communication (ICAIRC), pp. 358–361.
- Shoham, Y. (2009), Multiagent Systems: Algorithmic, Game-Theoretic, and Logical Foundations,
- Stillwell, W. G., Seaver, D. A., dan Edwards, W. (1981), Preference modeling with ordinal data, *Organizational Behavior and Human Performance* 28.1, pp. 62–81.
- Wang, W., Wang, Y., Hao, J., dan Taylor, M. E. (2019), Achieving cooperation through deep multiagent reinforcement learning in sequential prisoner’s dilemmas, *ACM International Conference Proceeding Series*, Type: Conference paper.
- Zhu, D., Yao, H., Jiang, B., dan Yu, P. (Apr. 27, 2018), *Negative Log Likelihood Ratio Loss for Deep Neural Network Classification*.

Zhu, L., Zhu, Y., dan Xia, C. (May 2025), Evolutionary Dynamics of Cooperation and Extortion on Networks With Fitness-Dependent Rules, *2025 Joint International Conference on Automation-Intelligence-Safety (ICAIS) & International Symposium on Autonomous Systems (ISAS)*, 2025 Joint International Conference on Automation-Intelligence-Safety (ICAIS) & International Symposium on Autonomous Systems (ISAS), ISSN: 2996-3850, pp. 1–6.

LAMPIRAN