


SKRIPSI

**PEMODELAN LAWAN BERBASIS FORECASTING MULTI-LANGKAH
YANG TERPISAH DARI OPTIMISASI REWARD PADA ITERATED
PRISONER'S DILEMMA**

***MULTI-STEP FORECASTING-BASED OPPONENT MODELLING
DECOUPLED FROM REWARD OPTIMIZATION IN THE ITERATED
PRISONER'S DILEMMA***



FAQIH MAHARDIKA
21/482551/PA/21039

**PROGRAM STUDI ILMU KOMPUTER
DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA**


2026

SKRIPSI

**PEMODELAN LAWAN BERBASIS FORECASTING MULTI-LANGKAH
YANG TERPISAH DARI OPTIMISASI REWARD PADA ITERATED
PRISONER'S DILEMMA**

***MULTI-STEP FORECASTING-BASED OPPONENT MODELLING
DECOUPLED FROM REWARD OPTIMIZATION IN THE ITERATED
PRISONER'S DILEMMA***

Diajukan untuk memenuhi salah satu syarat memperoleh derajat
Sarjana Sains Ilmu Komputer



FAQIH MAHARDIKA
21/482551/PA/21039

**PROGRAM STUDI ILMU KOMPUTER
DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA**

2026

HALAMAN PENGESAHAN

SKRIPSI

PEMODELAN LAWAN BERBASIS FORECASTING MULTI-LANGKAH YANG TERPISAH DARI OPTIMISASI REWARD PADA ITERATED PRISONER'S DILEMMA

Telah dipersiapkan dan disusun oleh

FAQIH MAHARDIKA
21/482551/PA/21039

Telah dipertahankan di depan Tim Penguji
pada tanggal 8 Mei 2026

Susunan Tim Penguji

Dr. Sri Mulyana, M.Kom.
Pembimbing

Bob, M.Sc.
Ketua Penguji

Eve, Ph.D.
Anggota Penguji

PERNYATAAN

Dengan ini saya menyatakan bahwa dalam Skripsi ini tidak terdapat karya yang pernah diajukan untuk memperoleh gelar kesarjanaan di suatu Perguruan Tinggi, dan sepanjang pengetahuan saya juga tidak terdapat karya atau pendapat yang ditulis atau diterbitkan oleh orang lain, kecuali yang secara tertulis diacu dalam naskah ini dan disebutkan dalam daftar pustaka.

Yogyakarta, 8 Mei 2026

Faqih Mahardika

DAFTAR ISI

Halaman Judul	ii
Halaman Pengesahan	iii
Halaman Pernyataan	iv
DAFTAR ISI	v
DAFTAR TABEL	viii
DAFTAR GAMBAR	ix
I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Batasan Penelitian	2
1.4 Tujuan Penelitian	3
1.5 Manfaat Penelitian	3
1.6 Sistematika Penelitian	4
II TINJAUAN PUSTAKA	5
2.1 Synthesis / Discussion	5
2.1.1 Asumsi Perilaku Lawan dalam <i>Opponent Modelling</i> untuk <i>Repeated Games</i>	5
2.1.2 Pendekatan metodologis dalam <i>opponent modelling</i> untuk <i>Re-</i> <i>peated Games</i>	7
2.1.3 Bagaimana efektivitas strategi <i>opponent modelling</i> dievaluasi dalam <i>Repeated Games</i> ?	11
III LANDASAN TEORI	15
3.1 Dilema Sosial	15
3.2 Game Theory	15
3.3 Prisoner's Dilemma	16
3.4 Iterated Prisoner's Dilemma	16
3.4.1 Finite Horizon	16

3.4.2	Definisi History Interaksi pada mekanisme online	17
3.4.3	Incomplete Information dan Pembentukan Belief	18
3.5	Pemodelan Lawan	18
3.6	RNN	19
3.6.1	Recurrent Neural Network untuk Opponent Modelling	19
3.6.2	Latent Belief Representation	19
3.7	Long Short-Term Memory (LSTM)	20
3.7.1	Forget Gate	20
3.7.2	Input Gate	21
3.7.3	Candidate Cell State	22
3.7.4	Cell State (Memori Jangka Panjang)	22
3.7.5	Output Gate	22
3.7.6	Hidden State Update	23
3.8	Prediksi Multi-Langkah	23
3.8.1	Forecasting Rekursif dan Monte Carlo Rollout (Fixed Horizon)	23
3.8.2	Dari Akurasi Prediksi ke Kinerja Strategis	24
3.8.3	Decoupled Opponent Modelling	27
3.8.4	Risiko Propagasi Kesalahan pada Forecasting Rekursif	27
3.8.5	Teacher Forcing	28
3.8.6	Scheduled Sampling	29
3.8.7	Fungsi Objektif Negative Log-Likelihood	30
3.9	Optimisasi	32
3.9.1	Pelatihan LSTM dengan Backpropagation Through Time	32
IV	ANALISIS DAN PERANCANGAN	34
4.1	Deskripsi Umum	34
4.2	Formulasi Masalah	34
4.3	Metodologi Penelitian	35
4.3.1	Setup Permainan	35
4.3.2	Arsitektur Model	36
V	JADWAL PENELITIAN	44
5.1	Jadwal Penelitian	44
5.1.1	Tahapan Penelitian	44
5.1.2	Rencana Waktu Pelaksanaan	47
5.1.3	Dependensi dan Risiko	48

VI KESIMPULAN DAN SARAN	49
DAFTAR PUSTAKA	50
LAMPIRAN	53

DAFTAR TABEL

2.1	Ringkasan Penelitian Terkait	6
2.2	Asumsi perilaku lawan berdasarkan dependensi perilaku yang dapat diamati.	8
2.3	Lingkungan evaluasi dan metrik dalam penelitian	12
5.1	Rencana Jadwal Penelitian (2 Bulan / 8 Minggu)	47

DAFTAR GAMBAR

2.1	Diagram metodologi.	9
3.1	Diagram metodologi.	21

INTISARI

PEMODELAN LAWAN BERBASIS FORECASTING MULTI-LANGKAH YANG TERPISAH DARI OPTIMISASI REWARD PADA ITERATED PRISONER'S DILEMMA

oleh

Faqih Mahardika

21/482551/PA/21039

Kerja sama dan konflik merupakan karakteristik fundamental dari interaksi dalam masyarakat, sistem biologis, dan lingkungan agen-artifisial, di mana agen secara berulang menghadapi pertukaran strategis antara kepentingan diri jangka pendek ataupun hasil kolektif jangka panjang. *Opponent Modelling* memiliki peran dasar dalam konteks tersebut dengan memungkinkan agen untuk menginferensi, mengantisipasi, dan beradaptasi terhadap perilaku pihak lain, dengan pengaplikasiannya mencakup negosiasi, interaksi pasar, hingga sistem kecerdasan buatan multi-agen. Meskipun informatif untuk kinerja jangka panjang, metrik-metrik tersebut umumnya diterapkan pada horizon interaksi yang tidak dibatasi atau cukup panjang, sehingga membatasi pemahaman mengenai efisiensi dan ketepatan waktu dalam proses identifikasi serta adaptasi terhadap lawan secara langsung. Tinjauan ini menemukan adanya kesenjangan struktural dalam praktik evaluasi yang ada dan menekankan perlunya kerangka penilaian yang sadar akan horizon (*horizon-aware*) agar lebih merefleksikan keterbatasan interaksi berulang di dunia nyata.

Cooperation and conflict are fundamental features of interaction in human societies, biological systems, and artificial-agent environments, where agents repeatedly face strategic trade-offs between short-term self-interest and long-term collective outcomes. Opponent modelling plays a central role in such settings by enabling agents to infer, anticipate, and adapt to the behavior of others, with applications ranging from negotiation and market interactions to multi-agent artificial intelligence systems. This literature review synthesizes prior work on opponent modelling in repeated strategic games, using the Iterated Prisoner’s Dilemma as a canonical instantiation of repeated social dilemmas rather than as a restrictive domain. The review analyzes existing approaches along three dimensions: assumptions about opponent behavior, opponent-modelling methodologies, and evaluation practices. The surveyed literature exhibits substantial diversity in opponent behavior assumptions, including stationary, reactive, learning-based, and population-mediated opponents, often embedded implicitly within experimental setups. Methodologically, approaches span gradient-based learning, deep reinforcement learning, recursive belief reasoning, evolutionary dynamics, and system identification. Evaluation practices predominantly emphasize outcome-based metrics such as cooperation rate, average payoff, and equilibrium-related measures. While informative for long-horizon performance, these metrics are typically applied under unconstrained interaction horizons, limiting insight into the efficiency and timeliness of opponent identification and adaptation. This review highlights a structural gap in existing evaluations and underscores the need for horizon-aware assessment frameworks that better reflect the constraints of real-world repeated interactions.

BAB I

PENDAHULUAN

1.1 Latar Belakang

Interaksi strategis berulang merupakan permasalahan fundamental dalam *multi-agent reinforcement learning* (MARL) Hernandez-Leal et al. 2019. Dalam lingkungan multi-agen, setiap agen tidak hanya beradaptasi terhadap lingkungan, tetapi juga terhadap agen lain yang turut belajar. Kondisi ini menjadikan dinamika pembelajaran bersifat non-stasioner dan sangat bergantung pada pola interaksi historis.

Iterated Prisoner's Dilemma (IPD) Axelrod dan Hamilton 1981 merupakan kerangka klasik untuk menganalisis dinamika tersebut. Dalam IPD, strategi tidak hanya ditentukan oleh aksi pada satu langkah, tetapi oleh pola respons yang berkembang sepanjang beberapa putaran. Banyak strategi deterministik maupun adaptif—seperti *Tit-for-Tat* dan variasinya—memperlihatkan struktur perilaku yang baru terlihat dalam rentang beberapa langkah interaksi.

Dalam literatur *opponent modelling*, pendekatan yang umum digunakan adalah prediksi satu langkah ke depan (*one-step prediction*) Nashed dan Zilberstein 2022. Model dilatih untuk meminimalkan kesalahan prediksi terhadap aksi lawan pada langkah berikutnya. Meskipun pendekatan ini konsisten dengan formulasi supervised learning standar, terdapat potensi ketidaksesuaian antara objektif pelatihan satu-langkah dan kebutuhan pengambilan keputusan dalam permainan berulang.

Dalam repeated games, keputusan agen pada waktu t tidak hanya bergantung pada distribusi aksi lawan pada waktu $t + 1$, tetapi juga pada konsekuensi strategis dalam beberapa langkah berikutnya. Strategi tertentu mungkin tidak optimal secara satu-langkah, namun menguntungkan secara multi-langkah. Dengan demikian, akurasi prediksi satu-langkah tidak selalu berbanding lurus dengan kualitas perencanaan strategis.

Selain itu, penggunaan prediksi secara recursive untuk menghasilkan trajectory multi-langkah berpotensi menimbulkan propagasi kesalahan (*error propagation*). Kesalahan kecil pada prediksi awal dapat terakumulasi dan mengurangi kualitas estimasi pada horizon yang lebih panjang. Hal ini menimbulkan pertanyaan metodologis mengenai bagaimana horizon prediksi (k) sebaiknya dipilih dan bagaimana kualitas prediksi pada berbagai horizon memengaruhi kinerja strategis agen.

Berdasarkan kondisi tersebut, terdapat kebutuhan untuk secara sistematis menganalisis hubungan antara horizon prediksi dan kualitas pengambilan keputusan dalam IPD. Secara khusus, penting untuk mengevaluasi apakah prediksi multi-langkah jangka pendek (k -step forecasting) memberikan representasi strategi lawan yang lebih selaras dengan kebutuhan perencanaan dibandingkan prediksi satu-langkah.

Dalam penelitian ini, pemisahan modul pemodelan lawan dari optimisasi reward diposisikan sebagai keputusan arsitektural untuk mengisolasi efek horizon forecasting terhadap kualitas prediksi dan dampaknya terhadap performa strategis. Dengan pemisahan ini, analisis dapat difokuskan pada hubungan antara akurasi prediksi multi-langkah, propagasi kesalahan, dan perolehan payoff dalam permainan berulang.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, penelitian ini merumuskan permasalahan sebagai berikut:

1. Apakah objektif prediksi satu-langkah (*one-step prediction*) selaras dengan kebutuhan perencanaan strategis multi-langkah dalam permainan berulang seperti IPD?
2. Bagaimana merancang dan mengimplementasikan prediksi trajectory aksi lawan dalam horizon terbatas (k -step forecasting), serta bagaimana pengaruh pemilihan horizon k terhadap kualitas prediksi dan perolehan payoff strategis?
3. Bagaimana membandingkan pendekatan prediksi recursive dan direct multi-step dalam hal propagasi kesalahan dan dampaknya terhadap performa agen?

1.3 Batasan Penelitian

Agar ruang lingkup penelitian tetap terfokus dan implementasi eksperimental terkendali, penelitian ini dibatasi pada:

1. Lingkungan *Iterated Prisoner's Dilemma* (IPD) dengan struktur payoff standar dan interaksi berulang dalam horizon tetap.
2. Lawan adaptif yang algoritmanya tidak diketahui oleh agen, namun dibatasi pada kelas pembelajaran daring seperti *Hedge*, *Online Mirror Descent*, serta pendekatan reinforcement learning berbasis pembaruan kebijakan.

3. Analisis difokuskan pada prediksi trajectory aksi lawan dalam horizon terbatas (k -step forecasting), tanpa membahas konvergensi jangka panjang atau sifat asimtotik strategi.
4. Penelitian tidak melakukan inferensi terhadap struktur algoritma internal lawan, melainkan memodelkan distribusi aksi berdasarkan observasi historis.
5. Evaluasi difokuskan pada hubungan antara akurasi prediksi multi-langkah, propagasi kesalahan, dan perolehan payoff strategis, tanpa merancang algoritma eksplorasi baru.

1.4 Tujuan Penelitian

Penelitian ini bertujuan untuk:

1. Menganalisis kesesuaian antara objektif prediksi satu-langkah (*one-step prediction*) dan kebutuhan perencanaan strategis multi-langkah dalam permainan berulang seperti IPD.
2. Mengembangkan dan mengimplementasikan mekanisme prediksi trajectory aksi lawan dalam horizon terbatas (k -step forecasting).
3. Mengevaluasi pengaruh panjang horizon prediksi (k) terhadap akurasi prediksi, propagasi kesalahan, dan perolehan payoff strategis.
4. Membandingkan pendekatan recursive forecasting dan direct multi-step forecasting dalam konteks stabilitas prediksi dan dampaknya terhadap performa agen.

1.5 Manfaat Penelitian

Manfaat dan kontribusi yang diharapkan dari penelitian ini adalah sebagai berikut:

1. Memberikan analisis konseptual dan empiris mengenai potensi ketidaksesuaian antara objektif prediksi satu-langkah dan kebutuhan perencanaan strategis dalam permainan berulang.

2. Menyediakan evaluasi sistematis mengenai pengaruh horizon prediksi (k) terhadap kualitas trajectory forecasting dan dampaknya terhadap strategic payoff.
3. Memberikan perbandingan empiris antara pendekatan recursive dan direct multi-step forecasting dalam konteks interaksi strategis berulang.
4. Menyediakan dasar eksperimental untuk memahami hubungan antara prediction accuracy dan kualitas pengambilan keputusan dalam repeated games.

1.6 Sistematika Penelitian

1. Bab 1: Pendahuluan: Latar belakang, rumusan masalah, batasan, tujuan, manfaat, dan sistematika penelitian.
2. Bab 2: Tinjauan Pustaka: Kajian literatur terkait opponent modelling, IPD, dan pendekatan pembelajaran daring.
3. Bab 3: Kerangka Teoritis: Formulasi masalah, definisi formal belief dan forecasting loss, serta arsitektur umum.
4. Bab 4: Metode Penelitian: Desain eksperimen, algoritma, dan prosedur evaluasi.
5. Bab 5: Jadwal Penelitian: gant chart, depedensi, dan risiko.
6. Bab 6: Kesimpulan dan Saran.

BAB II

TINJAUAN PUSTAKA

Sebanyak 13 studi dimasukkan ke dalam tinjauan sistematis final. Judul dan karakteristik dari studi-studi tersebut disajikan pada Tabel ???. Studi-studi ini mencerminkan keberagaman paradigma dalam *opponent modelling*, mulai dari pendekatan berbasis dinamika evolusioner, pembelajaran penguatan multi-agen, hingga pemodelan eksplisit berbasis representasi internal lawan.

Meskipun tujuan umum yang diangkat relatif serupa—yakni meningkatkan kinerja agen dalam interaksi strategis berulang—mekanisme yang digunakan untuk menangani dinamika perilaku lawan sangat bervariasi. Secara khusus, perbedaan utama terletak pada apakah dinamika perilaku lawan dimodelkan secara eksplisit sebagai proses prediktif yang terpisah, atau secara implisit terintegrasi ke dalam proses optimisasi reward kebijakan agen.

2.1 Synthesis / Discussion

Bagian ini mensintesis temuan utama dari studi yang ditinjau dengan tujuan mengidentifikasi pola asumsi perilaku lawan serta implikasinya terhadap desain metodologis *opponent modelling* dalam *repeated games*. Sintesis difokuskan pada dimensi perilaku yang dapat diamati dari riwayat interaksi, alih-alih pada asumsi internal seperti struktur optimisasi reward atau arsitektur pembelajaran yang digunakan.

Pendekatan ini penting karena dalam banyak karya terdahulu, pemodelan perilaku lawan sering kali tidak dipisahkan secara konseptual dari proses optimisasi kebijakan agen. Akibatnya, representasi perilaku lawan terenkapsulasi di dalam parameter kebijakan atau fungsi nilai, sehingga sulit untuk mengevaluasi kualitas prediksi perilaku secara independen dari reward yang dicapai. Untuk mengidentifikasi celah tersebut secara sistematis, tinjauan ini mengabstraksikan asumsi perilaku lawan pada tingkat eksternal yang dapat diinferensi dari *interaction traces*.

2.1.1 Asumsi Perilaku Lawan dalam *Opponent Modelling* untuk *Repeated Games*

Untuk mengoperasionalkan asumsi perilaku lawan secara konsisten pada pengaturan permainan yang beragam, tinjauan ini mengkarakterisasi perilaku berda-

Tabel 2.1 Ringkasan Penelitian Terkait

Ref	Nama Model	Temuan Utama
Qiao et al. 2024	Online Opponent Modeling (O2M)	O2M mampu beradaptasi lebih baik dan memperoleh rata-rata reward lebih tinggi dibandingkan baseline.
2	Zero Determinant Strategy under Evolutionary Dynamic	Proporsi akhir kerja sama melebihi strategi Extort, menunjukkan keunggulan dinamika evolusioner.
3	Hierarchical Gifting DQN	Mendeteksi perubahan strategi lawan secara real-time dan dinamis menyesuaikan insentif kerja sama.
4	Teamwork Game + MA-MAB	Mereproduksi pola mirip manusia (social loafing, compensation).
5	Environment-Strategy Coupling Model	Kopling antara umpan balik lingkungan dan dinamika strategi secara signifikan meningkatkan stabilitas kerja sama kelompok.
6	Ensemble-Training Cooperative Agent	Robust dan memiliki generalisasi lebih baik namun biaya komputasi lebih tinggi dan potensi estimasi reward intrinsik sub-optimal.
7	LSTM-Strategy	RNN mampu mengaproksimasi dinamika no-regret yang halus secara akurat serta memungkinkan eksploitasi yang menguntungkan pada tingkat non-stasioneritas rendah.
8	Internal Model	Konvergensi lebih cepat dan stabil dibanding TD-learning standar; performa menurun ketika perilaku lawan bergantung pada aksi agen sendiri (misalnya Tit-for-Tat).
9	Symmetric Learning Awareness (SLA)	Keseimbangan yang lebih stabil dan menghindari perilaku siklik pada metode gradien standar; pemodelan eksplisit meningkatkan konvergensi.
10	Extended Social Particle Swarm (SPS) Model	Ukuran populasi dan laju pembaruan informasi membentuk pola kerja sama dinamis dan beragam.
11	Deep Multiagent Reinforcement Learning (untuk SPD)	Mencapai kerja sama mutual; adaptif terhadap perubahan strategi lawan.
12	Suggestion Sharing (SS)	Meningkatkan kerja sama dibanding value sharing dan policy sharing.
13	Higher-order Theory of Mind (ToM k , $k \geq 2$)	ToM tingkat tinggi berpengaruh signifikan; <i>diminishing returns</i> setelah ToM-3.

sarkan dependensi yang dapat diamati dari riwayat interaksi. Secara khusus, aksi lawan dianalisis berdasarkan apakah ia:

1. Bervariasi lintas kondisi lingkungan dalam permainan yang sama,
2. Dimediasi oleh dinamika tingkat populasi,
3. Merespons secara langsung aksi agen,
4. Menunjukkan divergensi aksi pada riwayat interaksi terkini yang ekuivalen.

Kriteria-kriteria ini sepenuhnya berbasis observasi eksternal dan tidak mengasumsikan akses terhadap model internal, mekanisme pembelajaran, maupun fungsi objektif lawan. Dengan demikian, kategorisasi ini bukan taksonomi formal algoritma, melainkan kerangka analitis untuk memungkinkan perbandingan lintas paradigma pembelajaran.

Dalam studi yang tidak menyatakan asumsi perilaku secara eksplisit, klasifikasi diturunkan secara konservatif dari desain eksperimen dan dinamika interaksi yang dilaporkan. Hasil kategorisasi dirangkum pada Tabel 2.2.

Sejumlah pola konsisten muncul dari Tabel 2.2. Mayoritas studi terkini mengasumsikan lawan yang responsif terhadap aksi agen serta menunjukkan divergensi perilaku pada riwayat interaksi yang setara. Hal ini mencerminkan pergeseran fokus riset dari optimisasi terhadap strategi lawan yang tetap menuju interaksi dengan lawan yang adaptif dan dinamis.

2.1.2 Pendekatan metodologis dalam *opponent modelling* untuk *Repeated Games*

Distribusi asumsi perilaku lawan pada Tabel 2.2 mencerminkan pergeseran metodologis yang lebih luas dalam riset *opponent modelling*, dari pengaturan dengan asumsi lawan yang tetap dan terkontrol menuju lawan yang adaptif, heterogen, dan berperilaku tidak stasioner. Namun, karakterisasi berbasis asumsi perilaku semata belum menjelaskan bagaimana kompleksitas tersebut dihadapi secara komputasional di sisi agen. Untuk itu, Tabel 2.1 mereorganisasi studi-studi terdahulu berdasarkan paradigma pemodelan dominan dan mekanisme pembelajaran yang digunakan oleh agen.

Tabel 2.2 Asumsi perilaku lawan berdasarkan dependensi perilaku yang dapat diamati.

Env.	Pop.	Agent	Div.	Kategori Perilaku Lawan	Ref.
—	—	✓	—	Reactive	Jin et al. 2025
—	✓	—	—	Population-Conformist	Gómez et al. 2025
—	✓	✓	—	Contextual Reactive	Elhamer et al. 2020
—	—	✓	✓	Learning Opponent	Qiao et al. 2024; Lv et al. 2023; Li et al. 2025; Freire et al. 2023; Hu et al. 2023; Wang et al. 2019; De Weerd et al. 2022
—	✓	✓	✓	Population-Contextual Strategic	Perera et al. 2025
✓	✓	—	✓	Heterogeneous Collective Behavior	Zhu et al. 2025
✓	✓	✓	✓	Environment-Conditioned Strategic	Di et al. 2023

Catatan:


Env. — perilaku bervariasi lintas lingkungan dalam permainan yang sama;

Pop. — perilaku dimediasi oleh interaksi tingkat populasi;

Agent — perilaku merespons secara langsung aksi agen;

Div. — divergensi aksi terjadi pada riwayat interaksi terkini yang ekuivalen.

Tanda centang menunjukkan adanya dependensi.



Gambar 2.1 Diagram metodologi.

Pendekatan-pendekatan tersebut dapat dibedakan lebih lanjut berdasarkan apakah adaptasi terhadap lawan ditangani secara eksplisit atau implisit. Paradigma *opponent modelling* yang eksplisit—seperti *gradient-based opponent shaping* Qiao et al. 2024; Hu et al. 2023; Wang et al. 2019, *recursive belief reasoning* Freire et al. 2023; De Weerd et al. 2022, serta *system identification* Li et al. 2025—secara langsung membangun representasi internal perilaku lawan untuk memprediksi atau memengaruhi respons lawan di masa depan. Sebaliknya, pendekatan implisit, termasuk *reactive reinforcement learning* Lv et al. 2023, *population-based training* Perera et al. 2025, *dinamika evolusioner* Zhu et al. 2025; Di et al. 2023; Elhamer et al. 2020, dan *bandit-based learning-in-games* Gómez et al. 2025, beradaptasi terhadap lawan tanpa mempertahankan model perilaku lawan yang terpisah.

Meskipun pendekatan berbasis *reinforcement learning* dan *policy-gradient* mendominasi literatur terkini, paradigma tersebut umumnya mengintegrasikan pemodelan lawan ke dalam proses optimisasi kebijakan agen. Representasi dinamika lawan terenkapsulasi dalam parameter kebijakan atau fungsi nilai, sehingga sulit untuk dievaluasi secara terpisah. Konsekuensinya, kualitas prediksi perilaku lawan tidak dapat dianalisis secara independen dari performa reward agen, dan kemampuan untuk melakukan proyeksi eksplisit terhadap respons lawan pada beberapa langkah ke

depan menjadi terbatas.

Meskipun asumsi perilaku lawan semakin kompleks, pendekatan metodologis yang digunakan sering kali tetap mengintegrasikan pemodelan lawan secara langsung ke dalam proses optimisasi reward. Dalam konfigurasi semacam ini, dinamika perilaku lawan tidak dipelajari sebagai proses prediktif yang berdiri sendiri, melainkan sebagai bagian dari parameter kebijakan agen. Konsekuensinya, kemampuan agen untuk mengantisipasi evolusi perilaku lawan dalam beberapa langkah ke depan tidak selalu dianalisis secara eksplisit.

Kondisi ini menunjukkan adanya ruang konseptual untuk pendekatan yang memperlakukan perilaku lawan sebagai proses sekuensial yang dapat dipelajari secara terpisah dari optimisasi reward, serta dievaluasi berdasarkan kualitas prediksi terhadap lintasan aksi di masa depan, bukan semata-mata berdasarkan payoff agregat jangka panjang. Pendekatan semacam ini secara alami menekankan pentingnya *forecasting* multi-langkah dalam menghadapi dinamika interaksi berulang, terutama ketika keputusan pada fase awal interaksi memiliki implikasi strategis terhadap lintasan berikutnya.

Dalam konteks ini, pendekatan berbasis model sekuensial memori seperti *Long Short-Term Memory* (LSTM) menawarkan alternatif metodologis yang berbeda. LSTM dapat dipandang sebagai pendekatan yang memodelkan perilaku lawan sebagai proses dinamis berbasis riwayat interaksi. Aksi agen diperlakukan sebagai sinyal ekso-gen, sementara urutan aksi lawan dipelajari sebagai keluaran yang bergantung pada dependensi temporal jangka pendek maupun jangka panjang.

Berbeda dengan paradigma yang menggabungkan pemodelan lawan ke dalam optimisasi kebijakan, pendekatan ini secara eksplisit melakukan *decoupling* antara model prediktif perilaku lawan dan mekanisme pengambilan keputusan agen. Model LSTM dilatih untuk meminimalkan kesalahan prediksi perilaku lawan tanpa melibatkan sinyal reward agen. Dengan demikian, kualitas model lawan dapat dievaluasi secara independen menggunakan metrik prediksi sekuensial, sebelum diintegrasikan ke dalam proses pengambilan keputusan.

Selain itu, struktur rekuren pada LSTM memungkinkan *forecast* multi-langkah (*multi-step forecasting*) terhadap aksi lawan memanfaatkan skema prediksi rekursif atau *rolling horizon*. Kemampuan ini relevan dalam *repeated games*, di mana keputusan optimal agen sering kali bergantung pada ekspektasi terhadap respons lawan tidak hanya pada langkah berikutnya, tetapi juga pada beberapa langkah interaksi selanjutnya. Dengan menyediakan estimasi lintasan perilaku lawan pada horizon ter-

batas, agen dapat melakukan evaluasi strategi secara lebih prospektif dibandingkan pendekatan satu-langkah.

Karakteristik *decoupling* dan kemampuan *multi-step forecasting* tersebut menjadikan pendekatan berbasis LSTM metodologis berbeda dari pendekatan berbasis pembelajaran kebijakan terintegrasi. Secara khusus, pemisahan ini meningkatkan transparansi analitis, fleksibilitas integrasi dengan berbagai skema pengambilan keputusan (misalnya *best response*, simulasi berbasis skenario, atau perencanaan horizon terbatas), serta memungkinkan eksperimen terkontrol untuk menganalisis pengaruh kualitas prediksi lawan terhadap performa agen.

Literatur yang sepenuhnya memisahkan pembelajaran model lawan dari sinyal reward kebijakan masih relatif terbatas, khususnya dalam konteks *repeated games* dengan lawan adaptif dan tidak stasioner. Oleh karena itu, pendekatan ini tidak hanya berkontribusi secara implementatif, tetapi juga memperjelas posisi metodologis antara pemodelan prediktif perilaku lawan dan optimisasi strategi agen.

2.1.3 Bagaimana efektivitas strategi *opponent modelling* dievaluasi dalam *Repeated Games*?

Praktik evaluasi secara implisit mendefinisikan apa yang dianggap sebagai keberhasilan dalam interaksi multi-agent yang adaptif, baik dalam bentuk hasil kerja sama, ketahanan terhadap eksploitasi, stabilitas perilaku, maupun akurasi prediksi. Tabel 2.3 merangkum lingkungan evaluasi dan metrik yang digunakan dalam penelitian-penelitian terdahulu, dengan tujuan mengidentifikasi pola evaluasi yang berulang serta aspek-aspek yang relatif terabaikan.

Sebagaimana terlihat pada Tabel 2.3, sebagian besar studi mengevaluasi efektivitas *opponent modelling* melalui metrik kinerja agregat jangka panjang, seperti payoff rata-rata, tingkat kerja sama, stabilitas, serta konvergensi menuju equilibrium. Metrik-metrik tersebut menilai keberhasilan terutama dari hasil akhir interaksi, bukan dari kualitas representasi perilaku lawan yang dibangun selama proses interaksi.

Dalam banyak pendekatan berbasis *reinforcement learning*, pemodelan lawan terintegrasi langsung dengan optimisasi kebijakan. Konsekuensinya, evaluasi model lawan tidak dilakukan secara terpisah dari performa reward agen. Akurasi representasi perilaku lawan dinilai secara implisit melalui peningkatan payoff, sehingga sulit untuk mengisolasi kontribusi model prediktif terhadap keputusan agen.

Literatur yang secara eksplisit melakukan *decoupling* antara evaluasi model

Tabel 2.3 Lingkungan evaluasi dan metrik dalam penelitian

Ref.	Lingkungan Evaluasi	Metrik
Qiao et al. 2024	Self-play simetris	MSE selama pelatihan offline; akurasi memori laten
Zhu et al. 2025	Jaringan scale-free dengan strategi zero-determinant	Frekuensi kerja sama (C) dan eksploitasi (E)
Lv et al. 2023	Opponent adaptif (dirata-ratakan pada beberapa opponent)	Nilai reward
Gómez et al. 2025	Simulator teamwork-game khusus	Produktivitas tim agregat; konvergensi ke Nash equilibrium; kontribusi individu
Di et al. 2023	Simulator evolutionary game	Tingkat kerja sama; fraksi kooperator
Perera et al. 2025	Repeated matrix games dengan populasi sintetis	Payoff rata-rata; robustness; generalisasi
Li et al. 2025	Repeated zero-sum games	Galat prediksi; payoff kumulatif
Freire et al. 2023	Repeated matrix games	Efektivitas; stabilitas; akurasi prediksi
Hu et al. 2023	Simulasi repeated matrix game	Payoff rata-rata; kecepatan konvergensi
Elhamer et al. 2020	Simulasi continuous-space	Tingkat kerja sama; stabilitas klaster
Wang et al. 2019	Lingkungan SPD 2D khusus	Reward rata-rata; kesejahteraan sosial
Jin et al. 2025	Benchmark MARL	Return ternormalisasi; konvergensi
De Weerd et al. 2022	Simulasi Colored Trails	Skor agen; kesejahteraan sosial

perilaku lawan dan evaluasi kebijakan agen masih relatif terbatas. Dalam pendekatan yang terintegrasi, tidak selalu jelas apakah peningkatan kinerja disebabkan oleh kualitas pemodelan lawan, eksplorasi kebijakan, atau faktor adaptasi lainnya. Hal ini menyulitkan analisis kausal terhadap peran model lawan dalam meningkatkan efektivitas strategi.

Selain itu, sebagian besar evaluasi prediktif yang dilaporkan berfokus pada galat satu-langkah (*one-step prediction error*). Padahal, dalam konteks *repeated games*, keputusan optimal agen sering kali bergantung pada ekspektasi terhadap respons lawan dalam beberapa langkah ke depan. Dengan demikian, kemampuan melakukan *forecast multi-langkah* terhadap perilaku lawan merupakan dimensi evaluasi yang krusial namun relatif kurang dieksplorasi secara sistematis. Evaluasi yang terbatas pada prediksi satu-langkah tidak sepenuhnya mencerminkan kegunaan model dalam mendukung perencanaan strategi horizon terbatas.

Dalam pendekatan berbasis LSTM yang digunakan pada penelitian ini, model perilaku lawan dilatih secara terpisah untuk meminimalkan kesalahan prediksi sekuensial tanpa melibatkan sinyal reward agen. Pemisahan ini memungkinkan dua tingkat evaluasi yang berbeda namun saling melengkapi: (1) evaluasi kualitas model lawan melalui metrik prediksi sekuensial, termasuk performa *multi-step forecasting*, dan (2) evaluasi kebijakan agen ketika prediksi tersebut diintegrasikan dalam mekanisme pengambilan keputusan.

Pendekatan evaluasi semacam ini membuka ruang analisis yang lebih terstruktur terhadap hubungan antara akurasi prediksi dan performa strategis. Secara khusus, penelitian ini menyoroti dua celah dalam literatur:

1. Keterbatasan studi yang secara eksplisit memisahkan (*decouple*) pembelajaran dan evaluasi model perilaku lawan dari optimisasi kebijakan agen.
2. Minimnya analisis sistematis terhadap kemampuan *multi-step forecasting* dalam mendukung pengambilan keputusan pada *repeated games* dengan lawan adaptif dan tidak stasioner.

Dengan menempatkan evaluasi model lawan sebagai komponen analitis yang berdiri sendiri, serta menekankan pentingnya prediksi lintasan perilaku pada beberapa langkah ke depan, penelitian ini berupaya memperjelas kontribusi metodologis pendekatan berbasis LSTM dalam kerangka *opponent modelling*. Pendekatan ini tidak hanya mengevaluasi apakah agen mencapai payoff yang tinggi, tetapi juga bagaima-

na dan sejauh mana kualitas representasi perilaku lawan berperan dalam pencapaian tersebut.

BAB III

LANDASAN TEORI

3.1 Dilema Sosial

Dilema sosial merupakan situasi di mana keputusan rasional secara individual menghasilkan luaran yang tidak optimal secara kolektif(Axelrod dan Hamilton 1981). Secara formal, kondisi ini dapat dinyatakan sebagai:

$$\sum_{i=1}^n u_i(a_i, a_{-i}) < \sum_{i=1}^n u_i(a'_i, a'_{-i}) \quad (3.1)$$

di mana n adalah jumlah pemain, a_i adalah aksi rasional individu dan a'_i adalah profil aksi yang memaksimalkan kesejahteraan kolektif.

Formulasi ini menjelaskan adanya konflik antara rasionalitas individu dan optimalitas sosial. Namun, ekspresi agregat tersebut belum menyediakan struktur analitis yang cukup untuk memodelkan interaksi strategis antar agen secara eksplisit.

3.2 Game Theory

teori permainan memberikan kerangka formal yang memodelkan pemain, strategi, dan payoff secara terstruktur Bonanno 2024, dalam bentuk normal didefinisikan sebagai:

$$G = (N, A, U) \quad (3.2)$$

dengan N himpunan pemain, $A = A_1 \times A_2$ himpunan profil strategi atau *Action space*, dan $U = (u_1, u_2)$ fungsi payoff atau *utility*.

Nash Equilibrium adalah profil strategi a^* yang memenuhi:

$$u_i(a_i^*, a_{-i}^*) \geq u_i(a_i, a_{-i}^*) \quad \forall a_i \in A_i \quad (3.3)$$

Menunjukkan pilihan aksi selain a_i^* tidak dapat memberikan keuntungan lebih besar dari strategi keseimbangan. Kerangka ini memungkinkan analisis rasionalitas strategis dalam interaksi statik. Namun, model bentuk normal bersifat satu tahap dan mengasumsikan struktur payoff tetap.

3.3 Prisoner's Dilemma

Prisoner's Dilemma merepresentasikan konflik rasionalitas individu dan kolektif secara eksplisit (Axelrod dan Hamilton 1981). Aksi yang dapat dipilih adalah *Cooperate* (C) atau *Defect* (D). Struktur payoff Prisoner's Dilemma diberikan oleh:

$$\begin{array}{c|cc} & C & D \\ \hline C & (R, R) & (S, T) \\ D & (T, S) & (P, P) \end{array} \quad (3.4)$$

Dengan R (Reward) adalah payoff jika kedua pemain bekerja sama, T (Temptation) adalah payoff bagi pemain yang berkhianat sementara yang lain bekerja sama, S (Sucker's payoff) adalah payoff bagi pemain yang bekerja sama sementara yang lain berkhianat, dan P (Punishment) adalah payoff jika kedua pemain berkhianat. dengan ketidaksamaan:

$$T > R > P > S, \quad 2R > T + S \quad (3.5)$$

Dalam permainan satu tahap, strategi dominan adalah defeksi (D), sehingga keseimbangan Nash berada pada (D, D) meskipun (C, C) lebih optimal secara kolektif.

Namun, interaksi nyata jarang terjadi hanya satu kali.

3.4 Iterated Prisoner's Dilemma

Permainan PD diperluas menjadi bentuk berulang disebut Iterated Prisoner's Dilemma (IPD), permainan diulang selama T atau *Turn* tahap dengan payoff kumulatif atau terdiskonto. Dalam IPD, strategi dapat bergantung pada histori interaksi, memungkinkan untuk pembalasan dan kerja sama yang berkelanjutan. IPD relevan untuk mempelajari dinamika manusia seperti: pembentukan hubungan, konflik berkepanjangan, siklus saling membalas, dan pemulihan kepercayaan.

3.4.1 Finite Horizon

Pada formulasi finite horizon dengan panjang permainan tetap T , utilitas total pemain didefinisikan sebagai penjumlahan utilitas pada setiap ronde:

$$U_i = \sum_{t=1}^T u_i(a_i^t, a_{-i}^t) \quad (3.6)$$

Pada model ini, tidak digunakan faktor diskonto. Namun, secara teoretis, pendekatan ini cenderung menghasilkan strategi defeksi melalui mekanisme *backward induction* (Bonanno 2024).

3.4.2 Definisi History Interaksi pada mekanisme online

Dalam konteks iterated game dua pemain, history hingga waktu t tidak hanya terdiri dari aksi satu pemain, tetapi pasangan aksi kedua pemain pada setiap putaran. Secara formal, history didefinisikan sebagai:

$$h_t = ((a_i^1, a_{-i}^1), (a_i^2, a_{-i}^2), \dots, (a_i^t, a_{-i}^t)) \quad (3.7)$$

dengan a_i^k menyatakan aksi pemain i pada waktu k , dan a_{-i}^k menyatakan aksi lawan pada waktu yang sama (Bonanno 2024).

Dalam pengaturan iteratif, history tidak tersedia secara sekaligus, melainkan terbentuk secara *online*. Pada setiap putaran t , history diperbarui secara inkremental sebagai:

$$h_t = (h_{t-1}, (a_i^t, a_{-i}^t)) \quad (3.8)$$

dengan $h_0 = \emptyset$.

Formulasi ini menegaskan bahwa agen tidak memiliki akses terhadap trajectory interaksi di masa depan, dan hanya dapat menggunakan informasi yang telah terobservasi hingga waktu berjalan. Dengan kata lain, proses pengambilan keputusan berlangsung dalam kerangka kausal dan sekuensial.

History interaksi menyediakan rekaman lengkap atas realisasi aksi kedua pemain. Namun, history hanya merepresentasikan keluaran observabel dari proses pengambilan keputusan lawan, bukan mekanisme generatif yang mendasarinya. Agen tidak memiliki akses langsung terhadap strategi internal, parameter keputusan, ataupun aturan adaptasi yang digunakan oleh lawan.

Dengan demikian, meskipun seluruh pasangan aksi teramati secara bertahap, struktur strategi lawan tetap bersifat laten. Kondisi ini menyebabkan interaksi dalam IPD tidak memenuhi asumsi informasi lengkap sebagaimana pada analisis keseimbangan statik klasik (Bonanno 2024).

Oleh karena itu, permasalahan strategis dalam IPD dengan agen adaptif berada dalam kerangka permainan dengan informasi tidak lengkap, di mana agen harus melakukan inferensi terhadap strategi lawan secara bertahap seiring pertambahan history (Bonanno 2024).

3.4.3 Incomplete Information dan Pembentukan Belief

Dalam permainan dengan informasi tidak lengkap, ketidakpastian terhadap strategi lawan direpresentasikan melalui distribusi probabilitas atas kemungkinan tipe atau parameter strategi. Alih-alih mengasumsikan strategi tetap dan diketahui, agen memelihara suatu *belief state* yang diperbarui seiring bertambahnya histori interaksi.

Secara konseptual, belief state pada waktu t dapat dituliskan sebagai:

$$b_t = P(\theta \mid h_t) \quad (3.9)$$

dengan θ merepresentasikan representasi laten dari strategi lawan, dan h_t adalah histori interaksi hingga waktu t .

Formulasi ini menegaskan bahwa pengambilan keputusan dalam IPD adaptif bukan sekadar persoalan memilih aksi optimal terhadap strategi tetap, melainkan proses pembaruan belief secara sekuensial terhadap dinamika perilaku lawan. Dengan demikian, fokus analisis bergeser dari pencarian equilibrium statik menuju inferensi dinamis berbasis histori (Bonanno 2024).

3.5 Pemodelan Lawan

Pemodelan lawan atau *opponent modelling* memungkinkan untuk mempelajari perilaku ataupun strategi lawan (Shoham 2009).

Diberikan riwayat interaksi penuh:

$$h_t = ((a_i^1, a_{-i}^1), \dots, (a_i^t, a_{-i}^t)) \quad (3.10)$$

model parametrik f_θ mempelajari distribusi kondisional:

$$p_\theta(a_{t+1}^{-i} \mid h_t) \quad (3.11)$$

Pendekatan regresi linear sederhana mampu memodelkan hubungan statik, namun memiliki keterbatasan dalam menangkap dependensi temporal dan pola nonlini-

er.

3.6 RNN

Arsitektur berbasis jaringan saraf dapat menangkap dependensi temporal dan nonlinier untuk memodelkan dinamika yang lebih kompleks (Hochreiter dan Schmidhuber 1997).

3.6.1 Recurrent Neural Network untuk Opponent Modelling

RNN digunakan untuk memodelkan dinamika perilaku lawan berdasarkan urutan observasi. State tersembunyi diperbarui pada setiap waktu sebagai berikut:

$$h_t = \phi(Wx_t + Uh_{t-1} + b) \quad (3.12)$$

di mana:

- x_t adalah input pada waktu t , yang merepresentasikan observasi interaksi (misalnya aksi pemain dan lawan pada ronde sebelumnya),
- h_t adalah hidden state yang merepresentasikan belief terhadap strategi lawan hingga waktu t ,
- h_{t-1} adalah hidden state pada waktu sebelumnya,
- W adalah matriks bobot untuk input,
- U adalah matriks bobot rekuren yang menghubungkan state sebelumnya,
- b adalah bias,
- ϕ adalah fungsi aktivasi non-linear.

3.6.2 Latent Belief Representation

Dalam konteks opponent modelling, state tersembunyi h_t pada RNN diinterpretasikan sebagai representasi laten dari belief terhadap strategi lawan. Secara formal, belief terhadap aksi lawan pada waktu t dapat dimodelkan sebagai distribusi probabilitas bersyarat:

$$b_t(a_{-i}) = P(a_{-i}^t | h_t) \quad (3.13)$$

di mana h_t merupakan representasi laten yang merangkum seluruh histori interaksi hingga waktu t . Untuk memperoleh estimasi distribusi aksi lawan, digunakan fungsi pemetaan sebagai berikut:

$$\hat{b}_t = \text{softmax}(Vh_t) \quad (3.14)$$

di mana:

- $b_t(a_{-i})$ adalah belief terhadap aksi lawan,
- h_t adalah latent belief representation,
- V adalah matriks bobot output,
- $\hat{b}_t$ adalah estimasi distribusi probabilitas aksi lawan.

Dengan demikian, h_t tidak secara eksplisit merepresentasikan strategi lawan, melainkan embedding laten yang digunakan untuk mengaproksimasi belief tersebut dalam pemodelan lawan. Namun, pada RNN dengan dependensi jangka panjang menimbulkan masalah *vanishing/exploding gradient* yaitu gradient yang menumpuk panjang dan mengecil/membesar membuat model tidak dapat belajar dependensi jangka panjang dengan baik.


3.7 Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM) merupakan pengembangan dari Recurrent Neural Network (RNN) yang dirancang untuk menangkap dependensi jangka panjang melalui mekanisme memori eksplisit (Hochreiter dan Schmidhuber 1997). Dalam konteks *opponent modelling*, LSTM digunakan untuk membangun representasi laten terhadap strategi lawan berdasarkan histori interaksi.

Diberikan input x_t (observasi pada waktu t , misalnya aksi lawan), hidden state sebelumnya h_{t-1} (representasi laten sebelumnya), dan parameter bobot W , U , serta bias b , setiap komponen LSTM bekerja secara berurutan sebagai berikut.

3.7.1 Forget Gate

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f) \quad (3.15)$$



Gambar 3.1 Diagram metodologi.

Cell state sebelumnya c_{t-1} menyimpan histori panjang interaksi yang membentuk belief terhadap lawan. Namun, tidak semua informasi lama tetap relevan karena strategi lawan dapat berubah. Oleh karena itu, forget gate $f_t \in [0, 1]^h$ menentukan bagian mana dari memori lama yang perlu dipertahankan atau dilupakan secara adaptif.

3.7.2 Input Gate

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i) \quad (3.16)$$

Input $x_t \in \mathbb{R}^d$ merepresentasikan observasi saat ini, sedangkan $h_{t-1} \in \mathbb{R}^h$ adalah ringkasan historis interaksi sebelumnya. Namun, tidak semua informasi baru relevan atau stabil untuk memperbarui belief terhadap strategi lawan. Oleh karena itu, input gate $i_t \in [0, 1]^h$ mengontrol seberapa besar setiap dimensi informasi baru akan diterima ke dalam memori, dengan $\sigma(\cdot)$ sebagai fungsi sigmoid dan W_i, U_i, b_i sebagai parameter yang dipelajari.

3.7.3 Candidate Cell State

$$\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c) \quad (3.17)$$

Informasi mentah dari x_t tidak langsung disimpan karena dapat mengandung noise atau pola sementara yang belum representatif. Namun, model tetap membutuhkan representasi kandidat dari informasi baru tersebut. Oleh karena itu, $\tilde{c}_t \in [-1, 1]^h$ dibentuk melalui transformasi non-linear $\tanh(\cdot)$ sebagai kandidat memori baru, dengan parameter W_c, U_c, b_c .

3.7.4 Cell State (Memori Jangka Panjang)

Cell state $c_t \in \mathbb{R}^h$ merupakan jalur utama propagasi informasi jangka panjang dalam LSTM yang berfungsi sebagai *latent belief representation* terhadap strategi lawan. Namun, memori ini harus mampu menjaga stabilitas sekaligus tetap adaptif terhadap informasi baru. Oleh karena itu, pembaruannya dirumuskan sebagai:

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \quad (3.18)$$

Operator $\odot$ menyatakan perkalian elemen-per-elemen. Komponen $f_t \odot c_{t-1}$ mempertahankan informasi lama yang masih relevan, sedangkan $i_t \odot \tilde{c}_t$ menambahkan informasi baru secara selektif. Struktur aditif ini penting karena menjaga stabilitas gradien dan memungkinkan pembelajaran dependensi jangka panjang.

3.7.5 Output Gate

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o) \quad (3.19)$$

Meskipun c_t menyimpan informasi lengkap, tidak seluruhnya relevan untuk prediksi saat ini. Namun, model perlu mengekstrak bagian informasi yang paling informatif untuk pengambilan keputusan. Oleh karena itu, output gate $o_t \in [0, 1]^h$ mengontrol seberapa besar informasi dari cell state akan diekspos ke hidden state, dengan parameter W_o, U_o, b_o .

3.7.6 Hidden State Update

$$h_t = o_t \odot \tanh(c_t) \quad (3.20)$$

Cell state c_t mengandung representasi lengkap jangka panjang, namun terlalu kaya untuk digunakan secara langsung. Oleh karena itu, hidden state $h_t \in \mathbb{R}^h$ dibentuk sebagai representasi laten terfilter yang lebih terfokus, yang kemudian digunakan untuk memprediksi aksi lawan atau sebagai input ke modul pengambilan keputusan.

Struktur ini memungkinkan model mempertahankan dependensi jangka panjang sekaligus tetap adaptif terhadap perubahan strategi lawan. Oleh karena itu, LSTM sangat sesuai untuk digunakan dalam permainan berulang seperti Iterated Prisoner's Dilemma, di mana perilaku lawan bergantung pada histori interaksi. Namun, karena LSTM hanya menghasilkan prediksi satu langkah ke depan, model ini belum secara eksplisit mempertimbangkan konsekuensi jangka panjang, sehingga masih berpotensi menghasilkan kebijakan yang suboptimal.

3.8 Prediksi Multi-Langkah

Model LSTM menghasilkan distribusi prediktif satu langkah ke depan $p(a_{t+1}^{-i} | h_t)$. Namun, dalam permainan berulang, nilai suatu aksi tidak hanya ditentukan oleh respons lawan pada tahap berikutnya, melainkan oleh konsekuensi jangka panjang sepanjang lintasan interaksi.

3.8.1 Forecasting Rekursif dan Monte Carlo Rollout (Fixed Horizon)

Untuk memperoleh estimasi lintasan masa depan sepanjang horizon tetap H , model perilaku lawan digunakan secara autoregresif. Pada setiap langkah ke- k , prediksi aksi lawan dihasilkan dari distribusi:

$$\hat{a}_{t+k}^{-i} \sim p_{\theta}(\cdot | \hat{h}_{t+k-1}), \quad k = 1, \dots, H \quad (3.21)$$

dengan $\hat{h}_{t+k-1}$ merupakan history yang diperluas secara rekursif menggunakan aksi yang telah direalisasikan pada langkah-langkah sebelumnya.

Proses ini menghasilkan distribusi atas lintasan aksi sepanjang horizon terbatas:

$$\hat{\tau}_t^{(H)} = \{\hat{a}_{t+1}^{-i}, \hat{a}_{t+2}^{-i}, \dots, \hat{a}_{t+H}^{-i}\} \quad (3.22)$$

Karena jumlah kemungkinan lintasan tumbuh secara eksponensial terhadap H , ekspektasi payoff tidak dihitung secara analitik, melainkan diaproksimasi menggunakan simulasi Monte Carlo.

Untuk suatu aksi awal a_t , estimasi nilai diperoleh melalui M simulasi independen:

$$\hat{Q}_H(a_t) = \frac{1}{M} \sum_{m=1}^M \sum_{k=0}^{H-1} u_i^{(m)}(a_i^{t+k}, a_{-i}^{t+k}) \quad (3.23)$$

dengan:

- H : horizon prediksi tetap,
- M : jumlah rollout Monte Carlo,
- $u_i^{(m)}$: payoff agen pada simulasi ke- m .

Karena horizon bersifat terbatas, faktor diskonto tidak diperlukan, dan nilai aksi merepresentasikan akumulasi payoff sepanjang jendela prediksi tetap.

Dengan demikian, evaluasi aksi dilakukan melalui aproksimasi ekspektasi atas distribusi lintasan terbatas, yang sepenuhnya ditentukan oleh model belief dan horizon yang telah ditetapkan.

3.8.2 Dari Akurasi Prediksi ke Kinerja Strategis

Namun demikian, akurasi prediksi distribusi aksi lawan tidak secara langsung menjamin kinerja strategis yang optimal. Tujuan agen dalam permainan berulang bukan sekadar meminimalkan kesalahan prediksi, melainkan memaksimalkan payoff kumulatif.

Dalam formulasi permainan, misalkan i menyatakan agen yang dikontrol, dan $-i$ menyatakan himpunan seluruh lawan. Aksi yang diambil agen pada waktu t dinotasikan sebagai $a_t^i \in A_i$, sedangkan aksi lawan dinotasikan sebagai $a_t^{-i} \in A_{-i}$. Fungsi utilitas $u_i(a_t^i, a_t^{-i})$ merepresentasikan payoff yang diterima agen i ketika ia memilih aksi a_t^i dan lawan memilih aksi a_t^{-i} . Dalam konteks *opponent modelling*, a_t^{-i} merupakan variabel yang tidak dapat dikontrol dan hanya dapat diperkirakan melalui belief yang dibangun model.

Cumulative Regret (Classical Regret) Untuk mengukur performa jangka panjang, digunakan metrik regret kumulatif (Nisan et al. 2008):

$$R_T = \max_{a_i \in A_i} \sum_{t=1}^T u_i(a_i, a_t^{-i}) - \sum_{t=1}^T u_i(a_t^i, a_t^{-i}) \quad (3.24)$$

Pada persamaan di atas, $\max_{a_i \in A_i}$ merepresentasikan aksi tetap terbaik (*best fixed action*) yang dipilih secara retrospektif setelah seluruh interaksi hingga horizon T diamati. Namun, aksi optimal ini tidak diketahui selama permainan berlangsung. Term pertama $\sum_{t=1}^T u_i(a_i, a_t^{-i})$ merepresentasikan total payoff yang akan diperoleh jika agen selalu memainkan aksi terbaik tersebut, sedangkan term kedua $\sum_{t=1}^T u_i(a_t^i, a_t^{-i})$ adalah payoff aktual dari aksi yang benar-benar diambil agen. Oleh karena itu, R_T mengukur kerugian akibat tidak mengetahui strategi optimal sejak awal.

Pada permainan berulang, optimalitas strategi tidak hanya ditentukan oleh kualitas aksi pada satu waktu, melainkan oleh konsistensi keputusan sepanjang interaksi (Bonanno 2024). Namun, regret kumulatif membandingkan performa agen terhadap satu aksi tetap terbaik (*best fixed action*), yang dipilih secara retrospektif.

Pendekatan ini bersifat terbatas, karena pembanding berupa aksi statis tidak mampu merepresentasikan strategi kondisional yang bergantung pada histori interaksi. Dalam permainan seperti Iterated Prisoner's Dilemma, strategi optimal sering kali berbentuk kebijakan adaptif, di mana aksi pada waktu tertentu bergantung pada perilaku lawan sebelumnya.

Akibatnya, aksi yang optimal secara per-langkah tidak selalu menghasilkan payoff kumulatif yang optimal, karena keputusan saat ini dapat mempengaruhi respons lawan di masa depan. Dengan demikian, evaluasi berbasis aksi tetap menjadi kurang representatif terhadap kualitas strategi dalam konteks permainan berulang. (Bonanno 2024)

Equilibrium Regret Oleh karena itu, digunakan konsep equilibrium regret, yang mengukur deviasi performa agen terhadap strategi ekuilibrium yang mempertimbangkan interaksi strategis antar agen.

Secara umum, equilibrium regret dapat didefinisikan sebagai selisih antara payoff yang diperoleh agen dengan payoff yang akan diperoleh jika agen mengikuti strategi ekuilibrium. (Bonanno 2024) Misalkan π_i^* adalah strategi ekuilibrium untuk agen i , dan π_i adalah strategi yang digunakan, maka equilibrium regret dapat ditu-

liskan sebagai:

$$R_T^{eq} = \sum_{t=1}^T (u_i(a_t^*, a_t^{-i}) - u_i(a_t^i, a_t^{-i})) \quad (3.25)$$

di mana a_t^* merupakan aksi yang dihasilkan oleh strategi ekuilibrium π_i^* pada waktu t .

Meskipun equilibrium regret memberikan pembandingan yang lebih representatif dibandingkan aksi tetap, pendekatan ini tetap mengasumsikan keberadaan strategi ekuilibrium yang stabil sepanjang interaksi. Namun, dalam praktiknya, agen berinteraksi dengan lawan yang adaptif, di mana strategi lawan dapat berubah sebagai respons terhadap histori permainan dan tindakan agen itu sendiri. Dengan demikian, bahkan strategi ekuilibrium atau respons terbaik yang relevan dapat bergeser equilibrium dari waktu ke waktu.

Dynamic Regret (Fixed Horizon) Dalam lingkungan adaptif, aksi optimal dapat berubah seiring perubahan perilaku lawan. Oleh karena itu, digunakan dynamic regret yang membandingkan performa agen dengan aksi optimal yang dihitung ulang pada setiap waktu berdasarkan horizon tetap H .

Dynamic regret didefinisikan sebagai:

$$R_T^{dyn} = \sum_{t=1}^T (Q_H(a_t^* | h_t) - Q_H(a_t^i | h_t)) \quad (3.26)$$

dengan aksi optimal pada waktu t diberikan oleh:

$$a_t^* = \arg \max_{a_i \in A_i} Q_H(a_i | h_t) \quad (3.27)$$

di mana $Q_H(a_i | h_t)$ merupakan estimasi nilai aksi berdasarkan rollout Monte Carlo sepanjang horizon tetap H .

Dengan formulasi ini, dynamic regret mengukur selisih performa agen terhadap keputusan optimal yang dihitung ulang pada setiap waktu, tanpa mengasumsikan strategi pembandingan yang statis.

Metrik ini lebih sesuai untuk mengevaluasi kinerja dalam lingkungan non-stasioner, karena comparator diperbolehkan berubah secara temporal.

3.8.3 Decoupled Opponent Modelling

Dalam konteks *opponent modelling*, terdapat dua komponen utama, yaitu model prediksi perilaku lawan dan kebijakan (*policy*) agen. Secara umum, kedua komponen ini dapat dirancang secara terintegrasi maupun terpisah.

Pendekatan terintegrasi mempelajari representasi lawan secara end-to-end bersama dengan *policy*, sehingga prediksi yang dihasilkan langsung digunakan dalam proses pengambilan keputusan. Pendekatan ini banyak digunakan dalam *reinforcement learning*, karena memungkinkan optimasi langsung terhadap tujuan akhir berupa reward kumulatif.

Namun, keterkaitan yang erat antara prediksi dan *policy* menyulitkan interpretasi kualitas model lawan secara terpisah. Kesalahan prediksi dapat terkompensasi oleh *policy*, atau sebaliknya, sehingga evaluasi berbasis performa akhir tidak selalu mencerminkan akurasi representasi lawan.

Sebagai alternatif, pendekatan *decoupled opponent modelling* memisahkan proses pembelajaran model lawan dari kebijakan agen. Dalam kerangka ini, model bertujuan untuk memperkirakan distribusi aksi lawan $p(a_t^{-i} \mid h_{0:t-1})$ berdasarkan riwayat interaksi $h_{0:t-1}$, tanpa secara langsung dioptimalkan terhadap reward agen.

Pemisahan ini memungkinkan evaluasi model dilakukan secara independen, misalnya melalui metrik probabilistik seperti *log-likelihood* atau *cross-entropy*. Namun, dalam skenario interaksi berulang, prediksi dilakukan secara berurutan sepanjang waktu, sehingga kesalahan prediksi pada satu langkah dapat mempengaruhi langkah berikutnya, fenomena yang dikenal sebagai *compounding error*.

Selain itu, dalam pengaturan *online*, prediksi distribusi aksi lawan tidak selalu dapat diverifikasi secara langsung pada setiap langkah, terutama ketika *policy* agen tidak secara eksplisit mengeksplorasi prediksi tersebut. Hal ini menyebabkan adanya kesenjangan antara evaluasi berbasis akurasi prediksi dan dampaknya terhadap kinerja strategis agen.

3.8.4 Risiko Propagasi Kesalahan pada Forecasting Rekursif

Pendekatan multi-step forecasting dilakukan secara rekursif, di mana prediksi pada waktu $t + 1$ digunakan sebagai input untuk memprediksi waktu $t + 2$, dan seterusnya hingga horizon tetap H .

Namun, pendekatan ini berpotensi menimbulkan *compounding error*, di mana kesalahan kecil pada prediksi awal dapat terakumulasi dan memperbesar deviasi

distribusi pada langkah-langkah berikutnya (Bengio et al. 2015).

Secara formal, jika model menghasilkan distribusi prediktif

$$\hat{P}(a_{-i}^{t+1} | h_t), \quad (3.28)$$

maka distribusi pada langkah ke- k diberikan oleh

$$\hat{P}(a_{-i}^{t+k} | \hat{h}_{t+k-1}), \quad (3.29)$$

dengan $\hat{h}_{t+k-1}$ merupakan history yang diperluas menggunakan prediksi sebelumnya. Karena $\hat{h}_{t+k-1}$ sendiri merupakan hasil prediksi model, maka terjadi *distribution shift* antara distribusi pelatihan dan distribusi saat inferensi rekursif.

Dalam kerangka horizon tetap H , nilai suatu aksi a_t didefinisikan sebagai ekspektasi akumulasi payoff sepanjang H langkah ke depan:

$$Q_H(a_t | h_t) = \mathbb{E} \left[\sum_{k=0}^{H-1} u_i(a_i^{t+k}, a_{-i}^{t+k}) \mid h_t \right]. \quad (3.30)$$

Formulasi ini menunjukkan bahwa evaluasi keputusan pada waktu t tidak hanya bergantung pada prediksi satu langkah, melainkan pada kualitas estimasi distribusi lintasan sepanjang horizon terbatas H . Akumulasi kesalahan prediksi dalam forecasting rekursif dapat menyebabkan bias pada estimasi Q_H , sehingga stabilitas pelatihan menjadi aspek krusial dalam pendekatan multi-langkah.

3.8.5 Teacher Forcing

Pada model sekuens autoregresif seperti RNN atau LSTM, prediksi pada waktu t bergantung pada output sebelumnya. Secara umum, dinamika sistem dituliskan sebagai:

$$h_t = f(h_{t-1}, y_{t-1}; \theta) \quad (3.31)$$

$$\hat{y}_t = g(h_t; \theta) \quad (3.32)$$

dengan h_t hidden state, y_{t-1} input autoregresif, $\hat{y}_t$ prediksi model, dan θ parameter yang dipelajari.

Dalam skema *teacher forcing*, input autoregresif selama pelatihan digantikan oleh ground-truth y_{t-1}^* :

$$h_t = f(h_{t-1}, y_{t-1}^*; \theta). \quad (3.33)$$

Fungsi kerugian didefinisikan sebagai:

$$\mathcal{L}(\theta) = \sum_{t=1}^T \ell(\hat{y}_t, y_t^*), \quad (3.34)$$

dengan $\ell(\cdot)$ fungsi loss yang sesuai.

Teacher forcing mempercepat konvergensi dan menghasilkan gradien yang lebih stabil, karena distribusi input selama pelatihan identik dengan distribusi data sebenarnya.

Namun, pada fase inferensi rekursif sepanjang horizon H , model menggunakan prediksinya sendiri:

$$h_t = f(h_{t-1}, \hat{y}_{t-1}; \theta). \quad (3.35)$$

Perbedaan distribusi ini menimbulkan *exposure bias*, yang menjadi sumber utama *compounding error* dalam forecasting multi-langkah. Semakin panjang horizon H , semakin besar potensi akumulasi kesalahan.

3.8.6 Scheduled Sampling

Meskipun *teacher forcing* mempercepat konvergensi pelatihan, pendekatan tersebut menimbulkan perbedaan distribusi antara fase pelatihan dan inferensi yang dikenal sebagai *exposure bias*. Pada saat inferensi, model tidak lagi menerima ground-truth y_{t-1}^* , melainkan prediksi sebelumnya $\hat{y}_{t-1}$, sehingga kesalahan dapat terakumulasi secara rekursif.

Untuk menjembatani kesenjangan distribusi tersebut, *scheduled sampling* memperkenalkan mekanisme pencampuran antara ground-truth dan prediksi model selama pelatihan.

Pada setiap langkah waktu t , input autoregresif didefinisikan sebagai variabel acak:

$$\tilde{y}_{t-1} = \begin{cases} y_{t-1}^*, & \text{dengan probabilitas } \epsilon_k \\ \hat{y}_{t-1}, & \text{dengan probabilitas } 1 - \epsilon_k \end{cases} \quad (3.36)$$

dengan $\epsilon_k \in [0, 1]$ merupakan probabilitas penggunaan teacher forcing pada

iterasi pelatihan ke- k .

Dinamika hidden state menjadi:

$$h_t = f(h_{t-1}, \tilde{y}_{t-1}; \theta) \quad (3.37)$$

dan prediksi tetap dihitung sebagai:

$$\hat{y}_t = g(h_t; \theta) \quad (3.38)$$

Nilai ϵ_k dijadwalkan menurun secara bertahap agar model secara progresif bertransisi dari rezim pelatihan berbasis ground-truth menuju rezim inferensi berbasis prediksi sendiri.

Beberapa skema penjadwalan umum adalah sebagai berikut:

Linear Decay

$$\epsilon_k = \max(\epsilon_{\min}, \epsilon_0 - \alpha k) \quad (3.39)$$

Exponential Decay

$$\epsilon_k = \epsilon_0 \gamma^k \quad (3.40)$$

Inverse Sigmoid Decay

$$\epsilon_k = \frac{\kappa}{\kappa + \exp\left(\frac{k}{\kappa}\right)} \quad (3.41)$$

dengan ϵ_0 probabilitas awal teacher forcing, α laju penurunan linear, $\gamma \in (0, 1)$ faktor peluruhan eksponensial, dan κ parameter bentuk kurva.

Dengan mekanisme ini, distribusi input selama pelatihan secara bertahap mendekati distribusi saat inferensi, sehingga model menjadi lebih stabil terhadap propagasi kesalahan pada prediksi multi-langkah.

3.8.7 Fungsi Objektif Negative Log-Likelihood

Untuk mengevaluasi kualitas prediksi sekuensial lawan dalam horizon multi-step, digunakan metrik *Negative Log-Likelihood* (NLL) sebagai proper scoring rule yang konsisten terhadap estimasi distribusi probabilistik.

Misalkan pada waktu t tersedia history interaksi $h_t = \{(a_i^1, a_{-i}^1), \dots, (a_i^t, a_{-i}^t)\}$. Model pemodelan lawan menghasilkan distribusi probabilitas atas aksi lawan pada langkah berikutnya, yang dinotasikan sebagai:

$$P_{\theta}(a_{-i}^{t+1} \mid h_t) \quad (3.42)$$

dengan θ merepresentasikan parameter model (misalnya parameter LSTM).

Untuk prediksi multi-step sepanjang horizon H , model digunakan secara autoregresif, sehingga distribusi pada langkah ke- k bergantung pada history yang telah diperluas hingga waktu tersebut. Secara umum, probabilitas gabungan untuk urutan aksi aktual lawan $a_{-i}^{t+1:t+H}$ diberikan oleh:

$$P_{\theta}(a_{-i}^{t+1:t+H} \mid h_t) = \prod_{k=1}^H P_{\theta}(a_{-i}^{t+k} \mid \hat{h}_{t+k-1}) \quad (3.43)$$

dengan:

- a_{-i}^{t+k} : aksi aktual lawan pada waktu $t + k$,
- $\hat{h}_{t+k-1}$: history yang digunakan model pada langkah ke- k , yang terdiri dari history asli h_t yang diperluas secara rekursif menggunakan observasi aktual hingga waktu $t + k - 1$,
- H : panjang horizon prediksi multi-step.

Negative Log-Likelihood untuk satu segmen horizon sepanjang H kemudian didefinisikan sebagai:

$$\mathcal{L}_{\text{NLL}}^{(H)} = - \sum_{k=1}^H \log P_{\theta}(a_{-i}^{t+k} \mid \hat{h}_{t+k-1}) \quad (3.44)$$

Nilai NLL yang lebih kecil menunjukkan bahwa model memberikan probabilitas yang lebih tinggi terhadap aksi aktual yang benar-benar terjadi. Karena NLL merupakan proper scoring rule, metrik ini tidak hanya mengevaluasi ketepatan klasifikasi, tetapi juga kualitas kalibrasi probabilitas yang dihasilkan model.

Dalam konteks IPD dengan lawan adaptif, penggunaan NLL multi-step memungkinkan pengukuran efek *compounding error* akibat prediksi rekursif. Jika distribusi prediksi menjadi semakin bias pada horizon yang lebih panjang, maka akumulasi log-loss akan meningkat secara signifikan, mencerminkan degradasi kualitas belief seiring waktu.

3.9 Optimisasi

3.9.1 Pelatihan LSTM dengan Backpropagation Through Time

Parameter LSTM $\theta = \{W, U, b\}$ dipelajari melalui minimisasi fungsi kerugian berbasis likelihood. Dalam konteks pemodelan lawan, model menghasilkan distribusi probabilitas atas aksi lawan pada setiap waktu t :

$$p_\theta(a_{-i}^t \mid h_{t-1}) \quad (3.45)$$

Diberikan urutan observasi sepanjang horizon T , fungsi kerugian total dirumuskan sebagai negative log-likelihood:

$$\mathcal{L}(\theta) = - \sum_{t=1}^T \log p_\theta(a_{-i}^t \mid h_{t-1}) \quad (3.46)$$

Untuk memperbarui parameter θ , gradien $\nabla_\theta \mathcal{L}$ dihitung menggunakan algoritma *Backpropagation Through Time* (BPTT).

Karena LSTM merupakan model rekuren, hidden state h_t dan cell state c_t bergantung secara rekursif pada seluruh state sebelumnya. Oleh karena itu, komputasi gradien memerlukan propagasi error dari waktu T kembali ke waktu awal melalui rantai dependensi temporal:

$$\frac{\partial \mathcal{L}}{\partial \theta} = \sum_{t=1}^T \frac{\partial \mathcal{L}}{\partial h_t} \frac{\partial h_t}{\partial \theta} \quad (3.47)$$

Gradien pada setiap waktu tidak hanya bergantung pada kontribusi langsung terhadap loss pada waktu tersebut, tetapi juga pada pengaruh tidak langsung melalui state rekursif di masa depan. Mekanisme cell state yang bersifat aditif:

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \quad (3.48)$$

memungkinkan aliran gradien yang lebih stabil dibandingkan RNN konvensional, karena turunan terhadap c_{t-1} mengandung komponen linear melalui faktor f_t . Struktur ini secara signifikan mengurangi permasalahan *vanishing gradient* dalam pembelajaran dependensi jangka panjang.

Dalam praktiknya, untuk efisiensi komputasi dan stabilitas numerik, BPTT sering diterapkan dalam bentuk *truncated BPTT*, di mana propagasi gradien dibatasi pada jendela waktu sepanjang $K < T$. Parameter kemudian diperbarui menggunakan

algoritma optimisasi berbasis gradien seperti Stochastic Gradient Descent (SGD) atau Adam.

BAB IV

ANALISIS DAN PERANCANGAN

4.1 Deskripsi Umum

Penelitian ini bertujuan mengembangkan algoritma pembelajaran *online* untuk skenario *Iterated Prisoner's Dilemma* (IPD) dengan lawan yang dapat bersifat adaptif maupun non-stasioner.

Fokus utama penelitian adalah pada pemodelan lawan yang sepenuhnya *terpisah* (*decoupled*) dari sinyal reward agen. Model prediktif dilatih untuk mengestimasi distribusi aksi lawan berdasarkan riwayat interaksi, tanpa menggunakan informasi reward sebagai sinyal pembelajaran.

Model prediksi tersebut kemudian digunakan sebagai komponen dalam simulasi *multi-step Monte Carlo rollout* untuk mengestimasi nilai aksi agen. Dengan demikian, proses pembentukan belief terhadap lawan dipisahkan secara eksplisit dari proses evaluasi utilitas agen.

Pendekatan ini memungkinkan analisis terhadap stabilitas prediksi multi-langkah serta dampaknya terhadap kualitas perencanaan aksi, tanpa mencampurkan bias utilitas ke dalam representasi model lawan.

4.2 Formulasi Masalah

Penelitian ini mempertimbangkan skenario *Iterated Prisoner's Dilemma* (IPD) dengan horizon tetap T .

Pada setiap langkah waktu $t = 1, \dots, T$, agen dan lawan masing-masing memilih aksi:

$$a_t^{agent}, a_t^{opp} \in \{C, D\}.$$

Reward diperoleh berdasarkan matriks payoff standar IPD.

Lawan diasumsikan dapat bersifat adaptif maupun non-stasioner, namun algoritma internalnya tidak diketahui. Lawan dapat berupa strategi tetap, strategi reaktif, atau agen pembelajaran daring seperti Q-learning atau pendekatan berbasis estimasi frekuensi.

Agan tidak memiliki akses terhadap parameter internal, fungsi utilitas, ma-

upun mekanisme pembelajaran lawan. Satu-satunya informasi yang tersedia adalah riwayat interaksi:

$$H_t = \{a_1^{agent}, a_1^{opp}, \dots, a_t^{agent}, a_t^{opp}\}.$$

Tujuan agen adalah memilih aksi yang memaksimalkan reward kumulatif selama horizon T , dengan memanfaatkan modul pemodelan lawan yang dilatih secara terpisah dari sinyal reward.

Model pemodelan lawan menghasilkan distribusi prediktif

$$p(a_{t+1}^{opp} \mid H_t),$$

yang kemudian digunakan dalam simulasi multi-langkah untuk mengestimasi nilai aksi kandidat agen.

4.3 Metodologi Penelitian

Penelitian ini membangun model prediktif aksi lawan pada permainan berulang dan memanfaatkannya untuk estimasi nilai aksi melalui simulasi multi-langkah (*Monte Carlo rollout*). Pendekatan ini memisahkan secara eksplisit proses pemodelan lawan dari sinyal reward agen.

4.3.1 Setup Permainan

Permainan yang digunakan adalah *Iterated Prisoner's Dilemma* (IPD) dua pemain dengan dua aksi diskrit:

$$A = \{C, D\} \tag{4.1}$$

di mana C menyatakan *Cooperate* dan D menyatakan *Defect*.

Matriks Payoff Struktur payoff mengikuti formulasi klasik Prisoner's Dilemma dengan parameter:

$$T > R > P > S \quad \text{dan} \quad 2R > T + S$$

Nilai numerik yang digunakan:

$$P = \begin{bmatrix} R & S \\ T & P \end{bmatrix} = \begin{bmatrix} 3 & 0 \\ 5 & 1 \end{bmatrix} \quad (4.2)$$

dengan:

- $T = 5$ (*Temptation*)
- $R = 3$ (*Reward*)
- $P = 1$ (*Punishment*)
- $S = 0$ (*Sucker*)

Pada setiap langkah t :

$$(a_t^{agent}, a_t^{opp}) \in \{C, D\}^2 \quad (4.3)$$

Reward ditentukan langsung berdasarkan matriks payoff P .

Horizon Permainan Permainan dijalankan dengan horizon tetap sepanjang $T = 100$ langkah per episode.

Penggunaan horizon tetap bertujuan untuk mengisolasi analisis stabilitas prediksi multi-langkah tanpa pengaruh terminasi stokastik.

Representasi Histori Riwayat interaksi hingga waktu t dinotasikan sebagai:

$$H_t = \{(a_1^{agent}, a_1^{opp}), \dots, (a_t^{agent}, a_t^{opp})\} \quad (4.4)$$

Tujuan model adalah mengestimasi distribusi aksi lawan berikutnya:

$$\hat{x}_{t+1} = \mathbb{P}(a_{t+1}^{opp} \mid H_t) \quad (4.5)$$

4.3.2 Arsitektur Model

Model terdiri dari dua komponen utama:

1. LSTM satu layer dengan hidden size 64 sebagai encoder temporal
2. Linear layer diikuti fungsi softmax untuk menghasilkan distribusi aksi lawan

Representasi Input Pada setiap langkah waktu t , model menerima vektor fitur:

$$x_t \in \mathbb{R}^d \quad (4.6)$$

yang terdiri dari:

- One-hot aksi agen a_t^{agent} (2 dimensi)
- One-hot aksi lawan a_t^{opp} (2 dimensi)
- Skor kumulatif agen hingga waktu t
- Skor kumulatif lawan hingga waktu t
- Parameter trembling-hand ϵ

Parameter lingkungan dimasukkan untuk memungkinkan generalisasi terbatas terhadap konfigurasi permainan berbeda, tanpa mengubah struktur model.

Dinamika LSTM State internal LSTM terdiri dari hidden state h_t dan cell state c_t :

$$(h_t, c_t) = \text{LSTM}(x_t, (h_{t-1}, c_{t-1})) \quad (4.7)$$

dengan:

$$h_t \in \mathbb{R}^{64}, \quad c_t \in \mathbb{R}^{64}$$

Hidden state h_t berfungsi sebagai representasi laten histori interaksi hingga waktu t .

Evaluasi Prediksi Satu-Langkah Kinerja model prediktif diukur menggunakan metrik:

- Cross-entropy loss
- Akurasi klasifikasi aksi lawan
- Brier score

Secara formal, untuk distribusi prediksi $\hat{x}_{t+1}$ dan aksi aktual a_{t+1}^{opp} , cross-entropy didefinisikan sebagai:

$$\mathcal{L}_{CE} = - \sum_{t=1}^T \log \hat{x}_{t+1}(a_{t+1}^{opp}) \quad (4.8)$$

Evaluasi ini bertujuan mengukur kualitas estimasi $\mathbb{P}(a_{t+1}^{opp} \mid H_t)$ secara lokal tanpa mempertimbangkan efek rekursif multi-langkah.

Evaluasi Prediksi Multi-Langkah Untuk mengukur stabilitas dinamika rekursif, model dievaluasi dalam skenario *free rollout* tanpa teacher forcing sepanjang horizon k .

Distribusi prediksi pada langkah τ didefinisikan sebagai:

$$\hat{x}_{t+\tau} = f_{\theta}(\hat{H}_{t+\tau-1}) \quad (4.9)$$

di mana $\hat{H}_{t+\tau-1}$ adalah histori sintetis yang dibentuk dari prediksi sebelumnya.

Dihitung deviasi kumulatif terhadap distribusi aktual:

$$\mathcal{D}_{multi} = \frac{1}{k} \sum_{\tau=1}^k D_{KL}(x_{t+\tau} \parallel \hat{x}_{t+\tau}) \quad (4.10)$$

Metrik ini mengukur akumulasi error akibat propagasi prediksi.

Evaluasi Nilai Aksi Kualitas estimasi nilai diuji dengan membandingkan $\hat{Q}(H_t, c)$ terhadap nilai aktual yang diperoleh melalui simulasi penuh hingga horizon T .

Mean Squared Error (MSE) digunakan:

$$\mathcal{L}_Q = \mathbb{E} \left[\left(\hat{Q}(H_t, c) - Q^{true}(H_t, c) \right)^2 \right] \quad (4.11)$$

Evaluasi ini mengisolasi kontribusi model prediktif terhadap kualitas estimasi nilai jangka pendek.

Evaluasi End-to-End Evaluasi akhir dilakukan dalam skenario interaksi tertutup (*closed-loop play*) selama T langkah.

Metrik utama:

- Rata-rata reward per langkah
- Total reward per episode
- Tingkat kooperasi jangka panjang
- Regret relatif terhadap oracle best-response

Regret didefinisikan sebagai:

$$\text{Regret} = \frac{1}{T} \sum_{t=1}^T (r_t^{\text{oracle}} - r_t^{\text{agent}}) \quad (4.12)$$

di mana oracle memiliki akses penuh terhadap tipe lawan.

Evaluasi Robustness Robustness diuji terhadap:

- Variasi panjang horizon T
- Variasi trembling-hand noise ϵ
- Lawan yang tidak terlihat saat pelatihan

Tujuan evaluasi ini adalah menguji stabilitas representasi *belief state* dan ketahanan estimasi rollout terhadap pergeseran distribusi lingkungan.

Lingkungan Evaluasi dan Tipe Lawan Evaluasi dilakukan dalam lingkungan *Iterated Prisoner's Dilemma* (IPD) dengan horizon tetap T . Berbagai tipe lawan digunakan untuk menguji robustnes model terhadap dinamika stasioner maupun adaptif.

- **Fixed Mixed Strategy**

Lawan memilih kooperasi dengan probabilitas tetap $p \in [0, 1]$ dan defeksi dengan probabilitas $1 - p$, independen terhadap histori:

$$\mathbb{P}(a_t^{\text{opp}} = C) = p. \quad (4.13)$$

Strategi ini stasioner dan tidak memiliki dependensi temporal.

- **Tit-for-Tat (TFT)**

Lawan memulai dengan kooperasi dan kemudian meniru aksi terakhir agen:

$$a_t^{opp} = \begin{cases} C, & t = 1 \\ a_{t-1}^{agent}, & t > 1. \end{cases} \quad (4.14)$$

Strategi ini deterministik dan sepenuhnya reaktif terhadap aksi agen sebelumnya.

- **Win-Stay Lose-Shift (WSLS)**

Lawan mempertahankan aksi sebelumnya jika payoff yang diterima pada langkah sebelumnya termasuk kategori “tinggi” (R atau T), dan mengganti aksi jika payoff rendah (P atau S):

$$a_t^{opp} = \begin{cases} a_{t-1}^{opp}, & r_{t-1}^{opp} \in \{R, T\} \\ \text{flip}(a_{t-1}^{opp}), & r_{t-1}^{opp} \in \{P, S\}. \end{cases} \quad (4.15)$$

Strategi ini bergantung pada outcome interaksi sebelumnya.

- **Fictitious Play**

Lawan membentuk estimasi distribusi aksi agen berdasarkan frekuensi historis:

$$\hat{\pi}_t(a) = \frac{1}{t-1} \sum_{i=1}^{t-1} \mathbf{1}(a_i^{agent} = a), \quad (4.16)$$

dan memilih aksi yang memaksimalkan ekspektasi payoff terhadap distribusi tersebut:

$$a_t^{opp} = \arg \max_{a \in \{C, D\}} \mathbb{E}_{a^{agent} \sim \hat{\pi}_t} [r(a, a^{agent})]. \quad (4.17)$$

Strategi ini adaptif namun berbasis estimasi frekuensi agregat.

- **Q-Learning Agent**

Lawan merupakan agen pembelajaran berbasis Q-learning dengan pembaruan:

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left(r_t + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t) \right), \quad (4.18)$$

dengan eksplorasi ϵ -greedy. Strategi ini bersifat non-stasioner selama episode dan dapat beradaptasi terhadap pola agen.

Parameter strategi (misalnya p , α , γ , atau ϵ) ditetapkan konstan dalam satu episode, namun dapat divariasikan antar eksperimen untuk menguji robustnes terhadap perubahan dinamika.

Evaluasi Model Prediktif (Offline) Evaluasi offline bertujuan mengukur kualitas model LSTM sebagai prediktor satu-langkah tanpa interaksi tertutup.

Metrik yang digunakan:

- One-step accuracy
- Cross-entropy loss
- Brier score
- Entropy prediktif:

$$\mathcal{H}(\hat{x}_{t+1}) = - \sum_a \hat{x}_{t+1}(a) \log \hat{x}_{t+1}(a) \quad (4.19)$$

Selain itu dilakukan perbandingan antara pelatihan dengan dan tanpa *scheduled sampling* untuk mengukur dampaknya terhadap stabilitas generalisasi.

Evaluasi Stabilitas Multi-Langkah (Open-loop) Model diuji dalam mode prediksi rekursif sepanjang horizon k tanpa intervensi agen.

Dianalisis:

- Akurasi prediksi sebagai fungsi k
- Pertumbuhan error terhadap peningkatan k
- Divergensi distribusi:

$$D_{KL}(x_{t+k} \parallel \hat{x}_{t+k}) \quad (4.20)$$

- Pertumbuhan variansi prediktif sebagai fungsi k

Analisis ini mengukur stabilitas dinamika laten dan akumulasi error akibat self-conditioning.

Evaluasi Estimasi Ketidakpastian Ketidakpastian epistemik dihitung menggunakan Monte Carlo dropout dengan M forward pass.

Untuk setiap waktu t dihitung:

- Rata-rata prediksi
- Variansi antar forward pass
- Entropy distribusi prediktif

Dianalisis korelasi antara variansi prediktif dan error aktual, serta pertumbuhan ketidakpastian terhadap peningkatan horizon k .

Evaluasi Kualitas Perencanaan Kualitas estimasi nilai $\hat{Q}$ dianalisis melalui sensitivitas terhadap parameter simulasi:

- Horizon rollout k
- Jumlah rollout per kandidat n
- Jumlah kandidat aksi N
- Jumlah forward pass MC dropout M

Secara teoritis:

$$\text{Var}(\hat{Q}) \propto \frac{1}{n}, \quad (4.21)$$

yang diverifikasi secara empiris untuk memastikan konvergensi estimator.

Evaluasi Performa Agen (Closed-loop) Evaluasi akhir dilakukan dalam interaksi tertutup selama T langkah.

Metrik utama:

- Rata-rata reward per episode
- Distribusi reward
- Regret relatif terhadap best response
- Tingkat kooperasi sepanjang episode
- Stabilitas pola interaksi temporal

Baseline Performa agen dibandingkan dengan baseline berikut:

- Agen greedy one-step (tanpa rollout)
- Agen rollout tanpa estimasi ketidakpastian
- Agen reaktif heuristik (misalnya TFT-like)
- Agen acak (random policy)

Perbandingan ini mengisolasi kontribusi rollout multi-langkah dan estimasi ketidakpastian.

Ablation Study Dilakukan studi ablasi terhadap komponen utama:

- Tanpa scheduled sampling
- Tanpa Monte Carlo dropout
- Horizon rollout minimal ($k = 1$)
- Variasi jumlah kandidat N

Ablasi ini mengidentifikasi komponen yang paling berkontribusi terhadap stabilitas dan performa akhir agen.

BAB V

JADWAL PENELITIAN

5.1 Jadwal Penelitian

Penelitian ini direncanakan berlangsung selama dua bulan (8 minggu) dengan pembagian tahapan yang terstruktur sesuai dengan fokus utama penelitian, yaitu:

1. Pemodelan lawan yang sepenuhnya terpisah dari sinyal reward (decoupled opponent modelling)
2. Analisis stabilitas prediksi multi-langkah (multi-step forecasting)

Penyusunan jadwal dilakukan berdasarkan dependensi antar komponen sistem, dimulai dari pembangunan lingkungan deterministik, implementasi model prediktif, hingga evaluasi stabilitas dan analisis perencanaan berbasis rollout.

5.1.1 Tahapan Penelitian

Secara umum, tahapan penelitian dibagi menjadi sembilan fase utama sebagai berikut:

1. Perancangan dan Validasi Lingkungan IPD Deterministik

Tahap awal mencakup implementasi lingkungan *Iterated Prisoner's Dilemma* (IPD) dengan konfigurasi:

- Implementasi matriks payoff klasik
- Fixed horizon ($T = 100$)
- Validasi konsistensi reward
- Verifikasi determinisme transisi permainan

Lingkungan dibuat sepenuhnya deterministik untuk mengisolasi analisis pada dinamika model prediktif, tanpa gangguan noise maupun terminasi stokastik.

2. Implementasi Tipe Lawan

Meliputi pembangunan berbagai tipe lawan untuk menguji kapasitas representasi model:

- Fixed mixed strategy
- Tit-for-Tat
- Win-Stay Lose-Shift
- Fictitious Play
- Q-Learning agent

Dilakukan validasi bahwa agen adaptif menunjukkan dinamika non-stasioner dalam episode.

3. Pengumpulan dan Validasi Dataset

Tahap ini mencakup:

- Simulasi 10.000 episode pelatihan
- Simulasi 2.000 episode validasi
- Simulasi 2.000 episode pengujian
- Verifikasi distribusi tipe lawan uniform
- Pemeriksaan pemisahan data pelatihan dan pengujian

Dataset dikumpulkan tanpa memasukkan sinyal reward sebagai target pemodelan, untuk menjaga prinsip decoupling.

4. Implementasi Model Decoupled LSTM

Meliputi:

- Implementasi arsitektur LSTM satu layer (hidden size 64)
- Implementasi linear layer + softmax
- Implementasi scheduled sampling
- Pemisahan eksplisit modul belief dari modul evaluasi reward

Tahap ini memastikan bahwa pembentukan belief tidak bergantung pada utilitas agen.

5. Pelatihan Model Prediktif

Meliputi:

- Pelatihan dengan loss cross-entropy one-step
- Teacher forcing dengan scheduled sampling
- Monitoring validation loss
- Penyimpanan model terbaik

6. Evaluasi Model Prediktif (One-step)

Evaluasi kapasitas lokal model menggunakan:

- Accuracy
- Cross-entropy loss
- Entropy prediktif

Tahap ini memverifikasi kapasitas representasi sebelum analisis multi-langkah dilakukan.

7. Evaluasi Stabilitas Multi-Langkah (Open-loop)

Merupakan tahap inti penelitian.

Meliputi:

- Prediksi rekursif hingga horizon $k = 10$
- Analisis pertumbuhan error terhadap horizon
- Analisis divergensi distribusi prediktif
- Analisis akumulasi error akibat self-conditioning

Tahap ini menguji apakah representasi laten stabil dalam prediksi jangka panjang.

8. Implementasi dan Evaluasi Rollout Planning

Meliputi:

- Implementasi estimator nilai aksi $\hat{Q}$
- Integrasi prediksi multi-step dalam Monte Carlo rollout
- Analisis sensitivitas terhadap horizon k
- Analisis stabilitas estimasi nilai terhadap jumlah simulasi n

Fokus utama adalah mengevaluasi dampak kualitas forecasting terhadap kualitas perencanaan.

9. Evaluasi Closed-loop dan Studi Ablasi

Tahap akhir meliputi:

- Simulasi episode penuh
- Evaluasi reward rata-rata
- Perbandingan dengan baseline greedy one-step
- Ablasi tanpa scheduled sampling
- Ablasi horizon $k = 1$

Tahap ini mengukur kontribusi nyata multi-step forecasting terhadap performa agen.

5.1.2 Rencana Waktu Pelaksanaan

Rencana waktu pelaksanaan penelitian selama enam bulan ditunjukkan pada Tabel berikut.

Tabel 5.1 Rencana Jadwal Penelitian (2 Bulan / 8 Minggu)

Kegiatan	M1	M2	M3	M4	M5	M6	M7	M8
Perancangan lingkungan IPD	✓	✓						
Implementasi tipe lawan	✓	✓						
Pengumpulan dan validasi dataset		✓	✓					
Implementasi model LSTM			✓	✓				
Pelatihan model				✓	✓			
Evaluasi model offline (one-step)					✓			
Evaluasi open-loop multi-step					✓	✓		
Implementasi Monte Carlo rollout						✓	✓	
Evaluasi closed-loop agen							✓	
Studi ablas							✓	
Analisis statistik dan visualisasi								✓
Penulisan dan revisi laporan	✓	✓	✓	✓	✓	✓	✓	✓

5.1.3 Dependensi dan Risiko

Beberapa dependensi penting dalam penelitian ini:

- Implementasi rollout planning bergantung pada stabilitas model prediktif pada evaluasi open-loop.
- Evaluasi closed-loop tidak dapat dilakukan sebelum estimator nilai $\hat{Q}$ tervalidasi.
- Studi ablasi dilakukan setelah konfigurasi utama sistem stabil.

Risiko utama penelitian meliputi:

- Akumulasi error prediksi pada horizon panjang
- Kompleksitas komputasi akibat $\mathcal{O}(N \cdot n \cdot k \cdot M)$
- Ketidakstabilan model pada lawan non-stasioner

Strategi mitigasi meliputi pengujian bertahap (offline $\rightarrow$ open-loop $\rightarrow$ closed-loop), monitoring konvergensi estimator, serta pembatasan parameter eksperimen untuk menjaga efisiensi komputasi.

BAB VI
KESIMPULAN DAN SARAN

DAFTAR PUSTAKA

- Axelrod, R. dan Hamilton, W. D. (1981), The Evolution of Cooperation,
- Bengio, S., Vinyals, O., Jaitly, N., dan Shazeer, N. (Sept. 23, 2015), *Scheduled Sampling for Sequence Prediction with Recurrent Neural Networks*.
- Bonanno, G., 2024, *Game theory: volume 1: basic concepts*, Kindle Direct Publishing, Place of publication not identified.
- De Weerd, H., Verbrugge, R., dan Verheij, B. (Oct. 2022), Higher-order theory of mind is especially useful in unpredictable negotiations, *Autonomous Agents and Multi-Agent Systems* 36.2, p. 30.
- Di, C., Zhou, Q., Shen, J., Wang, J., Zhou, R., dan Wang, T. (2023), The coupling effect between the environment and strategies drives the emergence of group cooperation, *Chaos, Solitons & Fractals* 176, p. 114138.
- Elhamer, Z., Suzuki, R., dan Arita, T. (2020), The effects of population size and information update rates on the emergent patterns of cooperative clusters in a large-scale social particle swarm model, *Artificial Life and Robotics* 25.1, Type: Article, pp. 149–158.
- Freire, I. T., Arsiwalla, X. D., Puigbò, J. Y., dan Verschure, P. (2023), Modeling Theory of Mind in Dyadic Games Using Adaptive Feedback Control, *Information (Switzerland)* 14.8, Type: Article.
- Gómez, A. L. d. A., Sierra, C., dan Sabater-Mir, J. (2025), Grounded predictions of teamwork as a one-shot game: A multiagent multi-armed bandits approach, *Artificial Intelligence* 341, p. 104307.
- Hernandez-Leal, P., Kartal, B., dan Taylor, M. E. (Nov. 2019), A Survey and Critique of Multiagent Deep Reinforcement Learning, *Autonomous Agents and Multi-Agent Systems* 33.6, pp. 750–797.
- Hochreiter, S. dan Schmidhuber, J. (Nov. 1, 1997), Long Short-Term Memory, *Neural Computation* 9.8, pp. 1735–1780.
- Hu, Y., Han, C., Li, H., dan Guo, T. (2023), Modeling opponent learning in multiagent repeated games, *Applied Intelligence* 53.13, Type: Article, pp. 17194–17210.

- Jin, Y., Wei, S., dan Montana, G. (Aug. 2025), Achieving collective welfare in multi-agent reinforcement learning via suggestion sharing, *Machine Learning* 114.8, p. 190.
- Li, K., Huang, W., Li, C., dan Deng, X. (2025), Exploiting a No-Regret Opponent in Repeated Zero-Sum Games, *Journal of Shanghai Jiaotong University (Science)* 30.2, Type: Article, pp. 385–398.
- Lv, M., Liu, J., Guo, B., Ding, Y., Zhang, Y., dan Yu, Z. (Sept. 2023), Inducing Coordination in Multi-Agent Repeated Game through Hierarchical Gifting Policies, *2023 IEEE 20th International Conference on Mobile Ad Hoc and Smart Systems (MASS)*, 2023 IEEE 20th International Conference on Mobile Ad Hoc and Smart Systems (MASS), ISSN: 2155-6814, pp. 279–287.
- Nashed, S. B. dan Zilberstein, S. (2022), A Survey on Opponent Modeling in Adversarial Domains,
- Nisan, N., Roughgarden, T., Tardos, É., dan Vazirani, V. V., eds. (2008), *Algorithmic game theory*, Repr., [Nachdr.], Cambridge: Cambridge Univ. Press, 754 pp.
- Perera, I., Nijs, F. de, dan Garcia, J. (2025), Learning to cooperate against ensembles of diverse opponents, *Neural Computing and Applications* 37.23, Type: Article, pp. 18835–18849.
- Qiao, X., Han, C., dan Guo, T. (Dec. 2024), O2M: Online Opponent Modeling in Online General-Sum Matrix Games, *2024 4th International Conference on Artificial Intelligence, Robotics, and Communication (ICAIRC)*, 2024 4th International Conference on Artificial Intelligence, Robotics, and Communication (ICAIRC), pp. 358–361.
- Shoham, Y. (2009), *Multiagent Systems: Algorithmic, Game-Theoretic, and Logical Foundations*,
- Wang, W., Wang, Y., Hao, J., dan Taylor, M. E. (2019), Achieving cooperation through deep multiagent reinforcement learning in sequential prisoner’s dilemmas, *ACM International Conference Proceeding Series*, Type: Conference paper.
- Zhu, L., Zhu, Y., dan Xia, C. (May 2025), Evolutionary Dynamics of Cooperation and Extortion on Networks With Fitness-Dependent Rules, *2025 Joint International Conference on Automation-Intelligence-Safety (ICAIS) & International Sym-*

posium on Autonomous Systems (ISAS), 2025 Joint International Conference on Automation-Intelligence-Safety (ICAIS) & International Symposium on Autonomous Systems (ISAS), ISSN: 2996-3850, pp. 1–6.

LAMPIRAN